



Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Μέθοδοι Ανίχνευσης Ανωμαλιών σε Δεδομένα Χρονοσειρών

ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ

ΤΟΥ

ΣΠΕΝΤΖΟΥΡΗ ΙΩΑΝΝΗ

Αριθμός Μητρώου

ge19038

Επιβλέπων Καθηγητής:

Δημήτριος Φουσκάκης

Καθηγητής, Τομέας Μαθηματικών

Αθήνα, Ιούνιος 2025

Εθνικό Μετσόβιο Πολυτεχνείο
Σχολή Εφαρμοσμένων Μαθηματικών και Φυσικών Επιστημών

Τριμελής Επιτροπή

Εγκρίθηκε από την τριμελή εξεταστική επιτροπή στις 24/06/2025.

.....
Δημήτριος Φουσκάκης
Καθηγητής
Τομέας Μαθηματικών
(Επιβλέπων)

.....
Μιχαήλ Λουλάκης
Καθηγητής
Τομέας Μαθηματικών
(Μέλος Επιτροπής)

.....
Αντώνιος Παπαντολέων
Αναπληρωτής Καθηγητής
Τομέας Μαθηματικών
(Μέλος Επιτροπής)

© (2025) Με την επιφύλαξη παντός νομίμου δικαιώματος. Απαγορεύεται η αντιγραφή, αναπαραγωγή, αποθήκευση ή διανομή της παρούσας εργασίας, εξ ολοκλήρου ή τμηματικά, για εμπορικούς σκοπούς χωρίς την έγγραφη άδεια του συγγραφέα. Επιτρέπεται η χρήση για εκπαιδευτικούς ή ερευνητικούς σκοπούς, υπό την προϋπόθεση αναφοράς της πηγής και διατήρησης του παρόντος μηνύματος. Οι απόψεις που εκφράζονται δεν αντικατοπτρίζουν απαραίτητα τις θέσεις του Τμήματος, του Επιβλέποντα, ή της επιτροπής που την ενέκρινε.

(Υπογραφή)

.....
Ιωάννης Σπεντζούρης

Ευχαριστίες

Θα ήθελα να εκφράσω τις θερμές μου ευχαριστίες στον επιβλέποντα καθηγητή μου, κ. Δημήτριο Φουσκάκη, για την εμπιστοσύνη που μου έδειξε και την ευκαιρία που μου έδωσε να ασχοληθώ με ένα επίκαιρο και ενδιαφέρον επιστημονικό θέμα.

Ευχαριστώ, επίσης, τα μέλη της τριμελούς εξεταστικής επιτροπής, τους κυρίους Μιχαήλ Λουλάκη και Αντώνιο Παπαντολέον, για την τιμή που μου έκαναν να συμμετάσχουν στην αξιολόγηση της εργασίας.

Ιδιαίτερη αναφορά αξίζει στον Καθηγητή του Τμήματος Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών, κ. Ευάγγελο Σπηλιώτη, για την πρόθυμη υποστήριξή του και τη βοήθεια που μου προσέφερε στο αντικείμενο της ανάλυσης χρονοσειρών.

Θα ήθελα, επίσης, να ευχαριστήσω θερμά τους κ. Ιωάννη Κοψίνη και Παναγιώτη Ζώγα, της εταιρείας Libra AI IKE, για τη συνεργασία, την καθοδήγηση και τις χρήσιμες παρατηρήσεις τους καθ' όλη τη διάρκεια της διπλωματικής.

Τέλος, θα ήθελα να εκφράσω την ευγνωμοσύνη μου στην οικογένειά μου και στους φίλους μου, που ήταν διαρκώς στο πλευρό μου καθ' όλη τη διάρκεια των σπουδών μου. Η στήριξή τους υπήρξε ανεκτίμητη και καθοριστική.

Αθήνα, Ιούνιος 2025
Ιωάννης Σπεντζούρης

Περίληψη

Η παρούσα διπλωματική εργασία εστιάζει στην ανίχνευση ανωμαλιών σε μονοδιάστατες χρονοσειρές, συνδυάζοντας θεωρητικές βάσεις με πρακτικές εφαρμογές για την προσέγγιση ενός κρίσιμου προβλήματος που απαντάται σε πληθώρα πεδίων, όπως η οικονομία, η βιομηχανία και η κυβερνοασφάλεια. Στο θεωρητικό μέρος της εργασίας παρουσιάζονται τα βασικά είδη ανωμαλιών, καθώς και θεμελιώδεις έννοιες της ανάλυσης χρονοσειρών, όπως τα χρονικά τους μοτίβα, η στασιμότητα, η αυτοσυσχέτιση και οι στάσιμες διαδικασίες, οι οποίες αποτελούν τη βάση για την ανάπτυξη των στατιστικών προσεγγίσεων.

Στη συνέχεια, γίνεται εκτενής ανασκόπηση των μεθοδολογιών ανίχνευσης ανωμαλιών, οι οποίες ταξινομούνται σε τρεις κύριες κατηγορίες:

Στατιστικές μέθοδοι, όπως το γραμμικό μοντέλο (*Linear Model*), η Εκθετική Εξομάλυνση Holt-Winters και τα μοντέλα SARIMA, τα οποία βασίζονται σε υποθέσεις για τη δομή και στατιστική συμπεριφορά της χρονοσειράς.

Μέθοδοι μηχανικής μάθησης, που περιλαμβάνουν τεχνικές γενικής ανίχνευσης ανωμαλιών όπως τα Δάση Απομόνωσης (*Isolation Forest*), τον Τοπικό Παράγοντα Αποκλίσεων (*Local Outlier Factor*), τις Μηχανές Υποστήριξης Μίας Κλάσης (*One-Class SVM*), τον αλγόριθμο ομαδοποίησης DBSCAN, το Προφίλ Πίνακα (*Matrix Profile*) και τον αλγόριθμο ενίσχυσης κλίσης XGBoost.

Μέθοδοι βαθιάς μάθησης, όπως τα Πολυστρωματικά Perceptron (*MLP*), τα Δίκτυα Μακράς Βραχύχρονης Μνήμης (*LSTM*) και οι Αυτοκωδικοποιητές (*Autoencoders*), οι οποίοι αξιοποιούν την ικανότητα των νευρωνικών δικτύων να μαθαίνουν πολύπλοκες, μη γραμμικές αναπαραστάσεις από τα δεδομένα.

Στο πρακτικό μέρος της εργασίας, τα δεδομένα αρχικά ομαδοποιούνται και προεπεξεργάζονται με τη χρήση τεχνικών όπως η κανονικοποίηση (ή τυποποίηση), προκειμένου να λειτουργήσουν πιο αποτελεσματικά οι αλγόριθμοι, που περιγράφηκαν προηγουμένως. Στη συνέχεια, εφαρμόζονται, και για την κάθε μέθοδο επιχειρείται η εύρεση των βέλτιστων υπερπαραμέτρων μέσω τεχνικών όπως η διασταυρωμένη επικύρωση σε χρονοσειρές (*Time Series Cross-Validation - TSCV*) στο εκπαιδευτικό σύνολο και η αναζήτηση πλέγματος (*grid search*) στο σύνολο δοκιμής, σύμφωνα με τα χαρακτηριστικά της κάθε μεθόδου.

Οι αλγόριθμοι αξιολογούνται σε δύο πραγματικά σύνολα δεδομένων: το *Yahoo Webscope S5* (υποσύνολο A1), το οποίο περιλαμβάνει χρονοσειρές με διαφορετικούς τύπους ανωμαλιών, και τη χρονοσειρά *NYC Taxi* από το *Numenta Anomaly Benchmark (NAB)*, η οποία περιέχει δεδομένα κίνησης ταξί σε αστικό περιβάλλον.

Ανάλογα με τη φύση κάθε αλγορίθμου, εφαρμόζονται είτε χρονικά χαρακτηριστικά (*temporal features*) για να ενσωματωθεί η χρονική πληροφορία στα μοντέλα, είτε στρατηγικές οριοθέτησης όπως

τα στατικά και δυναμικά όρια, με σκοπό τη βελτίωση της ικανότητας εντοπισμού των ανωμαλιών. Η τελική αξιολόγηση των αλγορίθμων βασίζεται τόσο σε κλασικές μετρικές (ακρίβεια, ανάκληση, βαθμολογία F1), όσο και στη μετρική της βαθμολογίας NAB, η οποία λαμβάνει υπόψη τη χρονική ακρίβεια ανίχνευσης, για το NYC Taxi. Η εργασία ολοκληρώνεται με σχολιασμό των αποτελεσμάτων, αναφορά σε πιθανές βελτιώσεις και προτάσεις για μελλοντική έρευνα.

Λέξεις-Κλειδιά: Ανίχνευση Ανωμαλιών, Χρονοσειρές, Στατιστικά Μοντέλα, Μηχανική Μάθηση, Βαθιά Μάθηση, Χρονικά Χαρακτηριστικά, Στατικά και Δυναμικά Όρια, Βελτιστοποίηση Υπερπαραμέτρων, Yahoo Webscope S5, NAB NYC Taxi σύνολο δεδομένων.

Κατάλογος Πινάκων

3.1	Εξισώσεις εποχιακού μοντέλου Holt-Winters.	32
4.1	Υπερπαράμετροι και Λειτουργίες των Αλγορίθμων της Ομάδας I.	64
4.2	Τιμές των υπερπαραμέτρων για τους αλγορίθμους HWEST και SARIMA στα σύνολα δεδομένων.	67
4.3	Λειτουργία και τιμές των υπερπαραμέτρων του XGBoost.	68
4.4	Υπερπαράμετροι και Λειτουργίες των Νευρωνικών Δικτύων της Ομάδας II.	70
5.1	Αποτελέσματα μέσης Ακρίβειας (P), μέσης Ανάκλησης (R) και μέσης Βαθμολογίας F1 για τα σύνολα δεδομένων A1A και A1B.	81
5.2	Στατιστική σημαντικότητα (✓) και μεταβολές μέσου F1 Score για τα δεδομένα A1A και A1B. Οι μεταβολές σημειώνονται από Στατικά σε Δυναμικά όρια και από χρονικά σε μη χρονικά χαρακτηριστικά.	86
5.3	Αποτελέσματα μέσης Ακρίβειας (P), μέσης Ανάκλησης (R) και μέσης Βαθμολογίας F1 για τα σύνολα δεδομένων A1C, A1D.	87
5.4	Στατιστική σημαντικότητα (✓) και μεταβολές μέσου F1 Score για τα A1C και A1D. Οι μεταβολές σημειώνονται από Στατικά σε Δυναμικά όρια και από χρονικά σε μη χρονικά χαρακτηριστικά.	92
5.5	Αποτελέσματα μέσων (P, R, F1) για A1D αποτασιοποιημένο.	94
5.6	Ποσοστιαίες μεταβολές και Wilcoxon για το A1D vs A1DD (αποτασιοποιημένο).	95
5.7	Αποτελέσματα Precision, Recall, F1 και NAB score στη χρονοσειρά NYC TAXI NAB για τους αλγορίθμους χωρίς χρονικά χαρακτηριστικά.	100
5.8	Αποτελέσματα Precision, Recall, F1 και NAB score στη χρονοσειρά NYC TAXI NAB για τους αλγορίθμους με χρονικά χαρακτηριστικά.	101

Κατάλογος Διαγραμμάτων

2.1	Παράδειγμα κάθε είδους μοτίβου χρονοσειράς.	21
2.2	Παράδειγμα των βασικών ειδών ανωμαλιών σε χρονοσειρές, με δεδομένα από το Yahoo! Webscope S5.	25
3.1	Δάσος Απομόνωσης - Προσδιορισμός φυσιολογικών (αριστερά) και μη φυσιολογικών παρατηρήσεων (δεξιά).	34
3.2	Οπτικοποίηση του αλγορίθμου ομαδοποίησης DBSCAN. Πηγή: "DBSCAN Clustering Algorithm in Machine Learning," by Nagesh Singh Chauhan, KDnuggets, April 4, 2022.	40
3.3	Μια αναπαράσταση της σχέσης του προφίλ πίνακα με ολόκληρο τον πίνακα προφίλ απόστασης. Πηγή: [85]	44
3.4	Παρουσίαση δύο χρονοσειρών (με κόκκινο χρώμα) και του αντίστοιχου προφίλ πίνακα τους (με μπλε χρώμα). Πηγή: [42]	45
3.5	Η αρχιτεκτονική ενός Πολυστρωματικού Perceptron με ένα στρώμα εισόδου με τρεις νευρώνες, τρία κρυφά επίπεδα με τέσσερις νευρώνες το κάθε ένα και ένα στρώμα εξόδου με έναν νευρώνα. Πηγή: "A Simple overview of Multilayer Perceptron(MLP)" by franckepeixoto, Analytics Vidhya, 14 Dec, 2023.	46
3.6	Απεικόνιση της αρχιτεκτονικής ενός απλού LSTM. Πηγή: [19]	48
3.7	Απεικόνιση της αρχιτεκτονικής ενός αυτοκωδικοποιητή με 2 στρώματα ενσωμάτωσης και 2 στρώματα αποκωδικοποίησης. Πηγή: "Applied Deep Learning - Part 3: Autoencoders" by Arden Dertat, Medium, October 3, 2017.	50
4.1	Χαρακτηριστικά παραδείγματα χρονοσειρών για κάθε ομάδα.	56
4.2	Κατανομή των ανωμαλιών στις τέσσερις ομάδες δεδομένων Yahoo! A1.	57
4.3	Λειτουργία της Διασταυρούμενης Επικύρωσης σε Χρονοσειρές.	66
4.4	Ενδεικτική λειτουργία της υπολογιστικής σιγμοειδούς συνάρτησης NAB. Πηγή: [44]	75
5.1	Ραβδογράμματα μέσης βαθμολογίας F1 για τα δεδομένα A1A, A1B.	84
5.2	Διαγράμματα Μέσης Ακρίβειας-Ανάκλησης για τα A1A, A1B.	85
5.3	Ραβδογράμματα μέσης βαθμολογίας F1 για τα δεδομένα A1C, A1D.	88
5.4	Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για το A1C.	90
5.5	Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για το A1D.	91
5.6	Ραβδογράμματα μέσων F1 για στατικά και δυναμικά όρια στο αποτασιοποιημένο A1D.	94
5.7	Ραβδόγραμμα μεταβολών απόδοσης για στατικά και δυναμικά όρια, A1D vs A1DD.	95

5.8	Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για τους αλγορίθμους του A1D έναντι των εκδοχών της αποτασιοποιημένης έκδοσής του.	96
5.9	Συγκεντρωτικά αποτελέσματα και διακύμανση ανά μοντέλο.	97
5.10	Σύγκριση απόδοσης αλγορίθμων στο σύνολο δεδομένων NYC Taxi μέσω διαφορετικών μετρικών.	103
5.11	Πίνακας συσχέτισης μετρικών αξιολόγησης αλγορίθμων στο NYC Taxi σύνολο δεδομένων.	104

Περιεχόμενα

1	Εισαγωγή	11
1.1	Ιστορικό	11
1.2	Διατύπωση του Προβλήματος	12
1.3	Ερευνητικά Ερωτήματα	13
1.4	Σχετική Έρευνα	14
1.5	Δομή της Εργασίας	16
2	Θεωρητικό υπόβαθρο	17
2.1	Ανωμαλίες και Ακραίες Τιμές	17
2.1.1	Κατηγορίες Ακραίων Τιμών	18
2.1.2	Προσεγγίσεις Ανίχνευσης Ακραίων Τιμών	18
2.2	Στοχαστικές Διαδικασίες και Χρονοσειρές	19
2.2.1	Βασικά Μοτίβα Χρονοσειρών	20
2.2.2	Επίπεδο	20
2.2.3	Τάση	20
2.2.4	Εποχικότητα	20
2.2.5	Κυκλικότητα	21
2.2.6	Στασιμότητα στις Χρονοσειρές	21
2.2.7	Αυτοσυσχέτιση	22
2.2.8	Λευκός Θόρυβος	23
2.2.9	Στάσιμες Διαδικασίες AR, MA και ARMA	23
2.3	Ανίχνευση Ανωμαλιών σε Χρονοσειρές	24
2.4	Επισκόπηση Αλγορίθμων Ανίχνευσης Ανωμαλιών	26
3	Αναλυτική Περιγραφή των Αλγορίθμων	28
3.1	Στατιστικοί Αλγόριθμοι	29
3.1.1	Γραμμικό Μοντέλο και η Σχέση του με το AR Μοντέλο	29
3.1.2	Μη Στάσιμες Διαδικασίες ARIMA και SARIMA	29
3.1.3	Εκθετική Εξομάλυνση	31
3.2	Αλγόριθμοι Μηχανικής Μάθησης	33
3.2.1	Δάση Απομόνωσης	33
3.2.2	Τοπικός Παράγοντας Αποκλίσεων	34
3.2.3	Μηχανές Διανυσμάτων Υποστήριξης Μίας Κλάσης	36

3.2.4	Αλγόριθμος Χωρικής Ομαδοποίησης Εφαρμογών με Θόρυβο με Βάση την Πυκνότητα	38
3.2.5	Αλγόριθμος Extreme Gradient Boosting (XGBoost)	40
3.2.6	Αλγόριθμος Προφίλ Πίνακα	43
3.3	Αλγόριθμοι Βαθιάς Μάθησης	46
3.3.1	Πολυστρωματικό Perceptron	46
3.3.2	Δίκτυα Μακράς Βραχύχρονης Μνήμης	47
3.3.3	Αυτοκωδικοποιητής	49
4	Μεθοδολογία και Υλοποίηση	52
4.1	Περιγραφή Συνόλων Δεδομένων και Περιορισμοί	52
4.2	Προεπεξεργασία Δεδομένων	55
4.2.1	Ομαδοποίηση των Δεδομένων Yahoo A1	55
4.2.2	Εύρεση Εποχικότητας για τα Δεδομένα	57
4.2.3	Τυποποίηση και Κανονικοποίηση των Δεδομένων	58
4.2.4	Αποτασιοποίηση των Δεδομένων	59
4.2.5	Δημιουργία Χαρακτηριστικών	60
4.3	Υλοποίηση των Αλγορίθμων	62
4.3.1	Πρώτη Κατηγορία Υλοποίησης (Holt Winters - SARIMA)	66
4.3.2	Δεύτερη Κατηγορία Υλοποίησης (XGBoost, LM)	68
4.3.3	Τρίτη Κατηγορία Υλοποίησης (Νευρωνικά Δίκτυα)	69
4.3.4	Στατικό Όριο	70
4.3.5	Δυναμικό Όριο	71
4.4	Μετρικές Αξιολόγησης	71
4.4.1	Ακρίβεια	71
4.4.2	Ανάκληση/Ευαισθησία	72
4.4.3	Βαθμολογία F1	72
4.4.4	Βαθμολογία NAB	73
5	Αποτελέσματα και Συζήτηση	78
5.0.1	Χρήση και Επιλογή του Ελέγχου Προσημασμένης Διάταξης του Wilcoxon	79
5.0.2	Μαθηματική Διατύπωση	79
5.1	Ανάλυση Αποτελεσμάτων	80
5.1.1	Σύνολο Δεδομένων Yahoo A1	81
5.1.2	Σύγκριση A1D με την Αποτασιοποιημένη Μορφή του	94
5.1.3	Συγκεντρωτική Ανάλυση Yahoo A1	96
5.1.4	Προβλήματα στην Υλοποίηση	99
5.1.5	Σύνολο Δεδομένων New York City Taxi	99
5.2	Συνολική Επισκόπηση Αποτελεσμάτων	105
6	Βελτιώσεις και Μελλοντικές Επεκτάσεις	108

6.1	Βελτιώσεις και Επεκτάσεις	108
6.2	Προτάσεις για Μελλοντική Έρευνα	109

Κεφάλαιο 1

Εισαγωγή

1.1 Ιστορικό

Η ανίχνευση ανωμαλιών (*anomaly detection*), γνωστή επίσης ως εντοπισμός αποκλίσεων, εξαιρέσεων ή καινοτομιών (*outlier/novelty detection*), αναφέρεται στη διαδικασία εντοπισμού παρατηρήσεων που αποκλίνουν σημαντικά από το γενικό μοτίβο ή τη δομή των δεδομένων. Αυτές οι αποκλίνουσες παρατηρήσεις, γνωστές και ως ανωμαλίες, συνιστούν συχνά ενδείξεις για κρίσιμα και δυνητικά σημαντικά γεγονότα, όπως απόπειρες απάτης, κυβερνοεπιθέσεις, βλάβες συστημάτων ή σπάνια ιατρικά περιστατικά. Η σημασία της ανίχνευσης ανωμαλιών έγκειται στο γεγονός ότι, σε πληθώρα εφαρμογών, οι ανωμαλίες συνδέονται με αυξημένο επιχειρησιακό ή κοινωνικό ρίσκο και απαιτούν άμεση και αξιόπιστη αναγνώριση.

Στο πέρασμα των δεκαετιών, έχει αναπτυχθεί πληθώρα τεχνικών για την ανίχνευση ανωμαλιών, άλλοτε με στόχο τη γενική χρήση και άλλοτε ειδικά προσαρμοσμένων σε συγκεκριμένα περιβάλλοντα και εφαρμογές. Στον χρηματοοικονομικό τομέα, οι τεχνικές αυτές εφαρμόζονται για τον εντοπισμό ύποπτων συναλλαγών, απάτης σε πιστωτικές κάρτες ή χειραγώγησης της αγοράς. Στον τομέα της υγείας, αξιοποιούνται για την ανίχνευση σπάνιων ή παθολογικών καταστάσεων, όπως όγκοι σε απεικονιστικά δεδομένα ή ανωμαλίες σε ζωτικά σημεία. Στη βιομηχανία και την τεχνολογία, χρησιμοποιούνται για την πρόβλεψη και την έγκαιρη διάγνωση τεχνικών βλαβών, όπως αποτυχίες αισθητήρων ή δυσλειτουργίες σε γραμμές παραγωγής. Στην κυβερνοασφάλεια, συνεισφέρουν στον εντοπισμό εισβολών, κακόβουλων ενεργειών και γενικότερα στην παρακολούθηση ύποπτης δραστηριότητας σε ψηφιακά περιβάλλοντα. Τέλος, σε συστήματα αστικής κινητικότητας, όπως τα μέσα μαζικής μεταφοράς, οι ανωμαλίες μπορούν να υποδηλώνουν απότομες μεταβολές στη ζήτηση, κυκλοφοριακά προβλήματα ή δυσλειτουργίες στη λειτουργία υπηρεσιών.

Η ενασχόληση με την ανίχνευση ανωμαλιών έχει βαθιές ρίζες στη στατιστική, με πρώιμες αναφορές να εντοπίζονται ήδη από τα τέλη του 19ου αιώνα (π.χ. Edgeworth, 1887) [22]. Σημαντική πρόοδος σημειώθηκε τη δεκαετία του 1960, με χαρακτηριστικό παράδειγμα την εργασία του Grubbs, ο

οποίος πρότεινε το γνωστό Grubbs test για τον εντοπισμό ανωμαλιών σε μονοδιάστατα δεδομένα, που προέρχονται από κανονική κατανομή [29]. Οι μέθοδοι ανίχνευσης ανωμαλιών διαφέρουν σημαντικά ανάλογα με το είδος των δεδομένων στα οποία εφαρμόζονται. Για παράδειγμα, οι αλγόριθμοι που χρησιμοποιούνται για την ανίχνευση ανωμαλιών σε εικόνες διαφέρουν από αυτούς που εφαρμόζονται σε ροές δεδομένων (*data streams*). Η παρούσα διπλωματική επικεντρώνεται σε μεθόδους που εφαρμόζονται στην ανίχνευση ανωμαλιών **σε δεδομένα χρονοσειρών μιας μεταβλητής**. Η συγκεκριμένη περιοχή αποτελεί αντικείμενο επιστημονικού ενδιαφέροντος εδώ και αρκετές δεκαετίες. Ήδη από το 1981, ο Tukey [8] είχε προτείνει το "διάγραμμα ελέγχου Tukey", ένα στατικό όριο για την ανίχνευση ανωμαλιών σε χρονοσειρές, ενώ αργότερα οι Chang κ.ά, [16] το 1988 εισήγαγαν τη χρήση του ελέγχου λόγου πιθανοφάνειας (*Likelihood Ratio Test – LRT*) ως μέθοδο ανίχνευσης αποκλίσεων στα εν λόγω δεδομένα. Καθώς αυξανόταν η διαθεσιμότητα δεδομένων και η υπολογιστική ισχύς, το πεδίο άρχισε να αποκτά ξεχωριστή δυναμική, προσελκύοντας το ενδιαφέρον πλήθους επιστημονικών κοινοτήτων, όπως η στατιστική, η εξόρυξη δεδομένων (*data mining*), η μηχανική μάθηση και η υπολογιστική όραση.

Η εμφάνιση των μεθόδων μηχανικής μάθησης και, κυρίως, της βαθιάς μάθησης την τελευταία δεκαετία (*deep learning*), έχει αλλάξει δραστικά τον τρόπο με τον οποίο προσεγγίζεται η ανίχνευση ανωμαλιών. Οι μέθοδοι βαθιάς ανίχνευσης ανωμαλιών (*deep anomaly detection*) εκμεταλλεύονται την ικανότητα των νευρωνικών δικτύων να μαθαίνουν αναπαραστάσεις υψηλού επιπέδου απευθείας από τα δεδομένα, χωρίς την ανάγκη κατασκευής χειροκίνητων χαρακτηριστικών. Αυτό είναι ιδιαίτερα σημαντικό, όταν πρόκειται για δεδομένα υψηλής διάστασης ή πολυπλοκότητας, όπως εικόνες, χρονοσειρές, γράφοι ή συνδυαστικά δεδομένα πολλών τύπων.

Η παρούσα διπλωματική τοποθετείται στο πλαίσιο αυτής της εξελισσόμενης επιστημονικής περιοχής, εστιάζοντας σε τεχνικές που έχουν σχεδιαστεί για την ανίχνευση ανωμαλιών τόσο σε γενικά δεδομένα όσο και σε χρονοσειρές. Πρόκειται για μια ιδιαίτερα απαιτητική περίπτωση, καθώς οι χρονοσειρές ενσωματώνουν τόσο χρονική δυναμική όσο και συχνά μεγάλο όγκο και πολυπλοκότητα πληροφορίας.

1.2 Διατύπωση του Προβλήματος

Η ανίχνευση ανωμαλιών σε χρονοσειρές αποτελεί μια πολυδιάστατη και σύνθετη πρόκληση, ιδίως όταν εξετάζονται δεδομένα από διαφορετικές πηγές και με διαφορετικά χαρακτηριστικά, όπως ακραίες τιμές, εποχικότητα, τάσεις ή αλλαγές μετατόπισης. Παρά το γεγονός ότι έχουν προταθεί πολλές μέθοδοι για την ανίχνευση ανωμαλιών, δεν είναι ξεκάθαρο ποιου είδους αλγόριθμοι (στατιστικές προσεγγίσεις, αλγόριθμοι μηχανικής ή βαθιάς μάθησης) αποδίδουν καλύτερα υπό διαφορετικές συνθήκες και τύπους δεδομένων.

Παρότι τα νευρωνικά δίκτυα έχουν κερδίσει σημαντικό έδαφος στην αντιμετώπιση προβλημάτων πρόβλεψης και ανίχνευσης ανωμαλιών σε χρονοσειρές, πρόσφατες μελέτες αμφισβητούν την

απόλυτη υπεροχή τους έναντι πιο κλασικών μεθόδων. Ενδεικτικά, στη μελέτη των Elsayed κ.ά το 2021 [23], γίνεται σύγκριση μεταξύ ενός βασικού μοντέλου Παλινδρόμησης με Δέντρα Αποφάσεων και Ενίσχυση Κλίσης (GBRT) και διαφόρων μεθόδων βαθιάς μάθησης για πρόβλεψη σε χρονοσειρές, με τα αποτελέσματα να δείχνουν ότι το απλό μοντέλο GBRT με υπερπαραμετροποίηση σε πολλές περιπτώσεις εμφανίζει χαμηλότερο σφάλμα πρόβλεψης. Αντίστοιχα, οι Audibert κ.ά το 2022 [5] συγκρίνουν αλγόριθμους βαθιάς μάθησης με συμβατικές μεθόδους και αλγόριθμους μηχανικής μάθησης σε χρονοσειρές πολλών μεταβλητών με σημειωμένες ανωμαλίες, καταλήγοντας σε ευρήματα που δεν επιβεβαιώνουν την υπεροχή των νευρωνικών δικτύων, αλλά αντίθετα αναδεικνύουν σημαντική εξάρτηση από το είδος και τα χαρακτηριστικά των δεδομένων. Οι παραπάνω παρατηρήσεις τονίζουν την ανάγκη για συστηματική και αντικειμενική αξιολόγηση των αλγορίθμων, χωρίς την υπόθεση ότι οι μέθοδοι βαθιάς μάθησης υπερέχουν σε κάθε περίπτωση.

Επιπλέον, οι αλγόριθμοι μηχανικής μάθησης γενικού σκοπού (π.χ. Δάση Απομόνωσης, Τοπικός Παράγοντας Αποκλίσεων, Μηχανές Διανυσμάτων Υποστήριξης μιας Κλάσης, DBSCAN) δεν έχουν σχεδιαστεί εξ αρχής για χρονοσειρές, γεγονός που απαιτεί προσαρμογές στη δομή των δεδομένων ώστε να ληφθεί υπόψη η χρονική εξάρτηση. Από την άλλη, αλγόριθμοι πρόβλεψης όπως οι Holt-Winters και SARIMA, ή βαθιά νευρωνικά δίκτυα (LSTM, Αυτοκωδικοποιητής), προσφέρουν εναλλακτικές λύσεις που βασίζονται στη δυναμική συμπεριφορά των χρονοσειρών.

Η παρούσα διπλωματική επιχειρεί μια συγκριτική μελέτη διαφορετικών κατηγοριών μεθόδων —στατιστικών, μηχανικής μάθησης και βαθιάς μάθησης— σε δύο ξεχωριστά σύνολα δεδομένων: το *Yahoo! Webscope S5* και το *Numenta Anomaly Benchmark (NAB) – NYC Taxi σύνολο δεδομένων*. Σκοπός είναι να αξιολογηθεί η επίδοση κάθε μεθόδου σε διαφορετικά σενάρια ανωμαλιών, καθώς και να αναδειχθεί η σημασία της κατάλληλης προεπεξεργασίας και επιλογής μετρικών αξιολόγησης.

1.3 Ερευνητικά Ερωτήματα

Με βάση το παραπάνω πλαίσιο, η εργασία εστιάζει στην απάντηση των εξής βασικών ερευνητικών ερωτημάτων:

1. Πώς συγκρίνονται μεταξύ τους στατιστικές, μηχανικής μάθησης και βαθιάς μάθησης μέθοδοι ανίχνευσης ανωμαλιών, όταν εφαρμόζονται σε χρονοσειρές με διαφορετικούς τύπους ανωμαλιών;
2. Ποια είναι η επίδραση της προεπεξεργασίας των δεδομένων (όπως αποτασιοποίηση ή δημιουργία χρονικών χαρακτηριστικών) στην απόδοση των αλγορίθμων, ειδικά όταν αυτοί δεν έχουν σχεδιαστεί για χρονοσειρές;
3. Ποια στρατηγική υπολογισμού ορίου (στατική ή δυναμική) προσφέρει καλύτερη απόδοση στις προβλεπτικές μεθόδους για την ανίχνευση ανωμαλιών;

4. Πώς μεταβάλλεται η ακρίβεια ανίχνευσης ανάλογα με τη φύση των ανωμαλιών (π.χ. αιφνίδιες μετατοπίσεις, εποχικότητα, τάση, ακραίες τιμές υπό όρους);
5. Ποιοι συνδυασμοί μεθόδων και μετρικών αξιολόγησης (Ανάκληση, Ακρίβεια, Βαθμολογία F1, Βαθμολογία NAB) είναι καταλληλότεροι για περιβάλλοντα πραγματικού χρόνου, όπως το NYC Taxi σύνολο δεδομένων;

1.4 Σχετική Έρευνα

Η ανίχνευση ανωμαλιών σε χρονοσειρές αποτελεί ένα αντικείμενο ιδιαίτερα ενεργού ερευνητικού ενδιαφέροντος τα τελευταία χρόνια, με προσεγγίσεις που εκτείνονται από απλές στατιστικές μεθόδους έως πιο σύνθετα μοντέλα μηχανικής μάθησης (*machine learning*) και βαθιάς μάθησης (*deep learning*). Ιδιαίτερο βάρος έχει δοθεί στην περίπτωση των μονομεταβλητών χρονοσειρών (*univariate time series*), καθώς αυτές συνιστούν συχνή μορφή δεδομένων σε πλήθος εφαρμογών. Η σύγκριση μεθόδων σε τέτοιο πλαίσιο έχει στόχο την κατανόηση της απόδοσής τους υπό διαφορετικές συνθήκες. Στην παρούσα ενότητα παρουσιάζονται οι εργασίες που σχετίζονται άμεσα ή έμμεσα με τη μεθοδολογία και τα δεδομένα που χρησιμοποιούνται στη διπλωματική εργασία.

Η εργασία των Braei και Wagner [11] αποτελεί σημείο αναφοράς στον χώρο της ανίχνευσης ανωμαλιών σε μονομεταβλητές χρονοσειρές, καθώς συγκρίνει 20 αλγορίθμους που καλύπτουν μεθόδους στατιστικές, μηχανικής μάθησης και βαθιάς μάθησης. Η αξιολόγηση πραγματοποιείται στα τέσσερα σύνολα δεδομένων του Yahoo! Webscope S5, καθώς και στο σύνολο NYC Taxi, με χρήση της μετρικής ROC-AUC και του χρόνου υπολογισμού. Η παρούσα διπλωματική εργασία είναι βασισμένη στη μεθοδολογία της συγκεκριμένης μελέτης, με δύο βασικές διαφοροποιήσεις: πρώτον, χρησιμοποιούνται διαφορετικές μετρικές αξιολόγησης, καθώς η ROC-AUC, αν και δημοφιλής, δεν θεωρείται κατάλληλη για προβλήματα με μη ισορροπημένα δεδομένα (*imbalanced data*). Δεύτερον, χρησιμοποιείται το δυσκολότερο σύνολο δεδομένων του Yahoo (A1), το οποίο ομαδοποιήθηκε περαιτέρω ανάλογα με τα χαρακτηριστικά των χρονοσειρών, ώστε να αντιμετωπιστούν τα προβλήματα που αναλύονται στο Κεφάλαιο 4.1.

Αντίστοιχα, οι Schmidl και συνεργάτες [59] πραγματοποιούν μία από τις μεγαλύτερες συγκριτικές αξιολογήσεις στον τομέα, εφαρμόζοντας 71 διαφορετικούς αλγορίθμους σε 976 χρονοσειρές (συνθετικές και πραγματικές, στις οποίες ανήκουν το Yahoo! Webscope και το NAB). Η μελέτη εξετάζει σημειακές ανωμαλίες (*point anomalies*), δομικές αλλαγές (*subsequence anomalies*) και ανωμαλίες συσχέτισης (*correlation anomalies*), αξιολογώντας τις μεθόδους ως προς την αποτελεσματικότητα, την αποδοτικότητα και τη σταθερότητά τους. Το εύρος της ανάλυσης ενισχύει τη σημασία της συγκριτικής αξιολόγησης πολλών και διαφορετικών προσεγγίσεων, κάτι που υιοθετείται και στην παρούσα διπλωματική.

Ιδιαίτερο ενδιαφέρον παρουσιάζει η εργασία των Daubener και συνεργατών [21], η οποία εξετάζει αλγορίθμους στατιστικούς και μηχανικής μάθησης (όπως ARIMA, SVM, Random Forests,

τεχνητά νευρωνικά δίκτυα και Γκαουσιανές Διαδικασίες) στα πλήρη σύνολα δεδομένων Yahoo Webscope S5 και NAB, τα οποία χρησιμοποιούνται και στην παρούσα διπλωματική. Οι μέθοδοι βασίζονται στην πρόβλεψη της «φυσιολογικής» συμπεριφοράς της χρονοσειράς και την εφαρμογή στατιστικού ελέγχου (*generalized studentized test*) στα υπολείμματα (*residuals*). Η αξιολόγηση πραγματοποιείται μέσω της μετρικής F1-score, με πολύ καλές επιδόσεις για τις Γκαουσιανές Διαδικασίες και το SVM, επιβεβαιώνοντας τη σημασία της ορθής επιλογής μοντέλου.

Η εργασία των Hagemann και Katsarou [30] εστιάζει σε προσεγγίσεις βασισμένες στην ανακατασκευή (*reconstruction-based*), όπως η Ανάλυση Κύριων Συνιστωσών (PCA), τους Αυτοκωδικοποιητές και τα LSTM Encoder-Decoder (Αυτοκωδικοποιητής που αποτελείται από κελιά LSTM) μοντέλα. Οι μέθοδοι εφαρμόζονται στο Yahoo S5 σύνολο δεδομένων και συγκρίνονται με πυκνοτικές προσεγγίσεις μηχανικής μάθησης (*density-based*), με τα αποτελέσματα να δείχνουν υπεροχή των πρώτων και συγκεκριμένα του Αυτοκωδικοποιητή, που δείχνει ότι κάποιες φορές πράγματι είναι προτιμότερα τα νευρωνικά δίκτυα.

Η εργασία των Skaf και Horvath [68] προτείνει ένα βελτιωμένο μοντέλο Αυτοκωδικοποιητή τύπου LSTM (LSTM-Autoencoder) με χρήση τεχνικών αποθορυβοποίησης (*denoising*) και *dropout*, το οποίο βελτιώνει την ακρίβεια και την ταχύτητα εκπαίδευσης σε περιβάλλον χωρίς εποπτεία (*unsupervised*). Αν και η παρούσα διπλωματική δεν περιλαμβάνει LSTM-Autoencoders, η μελέτη αυτή προσφέρει θεωρητικό υπόβαθρο για μελλοντικές επεκτάσεις σε βαθύτερες αρχιτεκτονικές.

Σε διαφορετικό πλαίσιο, η εργασία των Shipmon και συνεργατών [64] από την Google, παρουσιάζει μια εφαρμοσμένη προσέγγιση πρόβλεψης σε συνεχή, περιοδικά και θορυβώδη δεδομένα ροής (*noisy streaming time series*). Χρησιμοποιούνται μοντέλα βαθιάς μάθησης (DNNs, RNNs, LSTM) για πρόβλεψη και εφαρμόζονται κανόνες οριοθέτησης (*thresholding*) για την ανίχνευση παρατεταμένων αποκλίσεων. Η προσέγγιση αυτή είναι συμβατή με την τεχνική των στατικών και δυναμικών ορίων που εφαρμόζεται στην παρούσα διπλωματική για το Yahoo A1 σύνολο δεδομένων.

Η εργασία των Almaguer-Angeles και συνεργατών [3] αξιολογεί 22 εποπτευόμενους αλγορίθμους μηχανικής μάθησης σε δεδομένα IoT (Δίκτυο των Πραγμάτων - Internet of Things), καταλήγοντας στο συμπέρασμα ότι η απόδοση κάθε μεθόδου εξαρτάται από τα χαρακτηριστικά του προβλήματος. Αν και η μελέτη δεν αφορά χρονοσειρές, ενισχύει το γενικό συμπέρασμα ότι δεν υπάρχει απόλυτα βέλτιστη μέθοδος, επιβεβαιώνοντας έτσι τη σημασία της πειραματικής συγκριτικής αξιολόγησης.

Τέλος, δύο σημαντικές εργασίες προσφέρουν θεωρητικό υπόβαθρο στον χώρο της πρόβλεψης χρονοσειρών. Η κλασική μελέτη των Makridakis και Hibon [48], στο πλαίσιο του διαγωνισμού M3, ανέδειξε την αποτελεσματικότητα απλών στατιστικών μοντέλων όπως το ARIMA και η εκθετική εξομάλυνση (*exponential smoothing*). Η μεταγενέστερη εργασία των Makridakis, Spiliotis και Assimakopoulos [49] συγκρίνει στατιστικά μοντέλα και μεθόδους μηχανικής μάθησης σε προβλέψεις 1045 χρονοσειρών, καταλήγοντας στο συμπέρασμα ότι τα στατιστικά μοντέλα υπερέχουν τόσο σε ακρίβεια όσο και σε υπολογιστική αποδοτικότητα. Τα ευρήματα αυτά είναι χρήσιμα στην αξιολόγηση μοντέλων πρόβλεψης που χρησιμοποιούνται ως βάση για ανίχνευση ανωμαλιών.

1.5 Δομή της Εργασίας

Η παρούσα διπλωματική εργασία είναι οργανωμένη ως εξής:

- **Θεωρητικό Υπόβαθρο:** Παρουσιάζονται βασικές έννοιες που αφορούν τις χρονοσειρές, καθώς και η έννοια της ανωμαλίας τόσο γενικά όσο και στο πλαίσιο των χρονοσειρών. Το θεωρητικό αυτό μέρος είναι απαραίτητο για την κατανόηση της υλοποίησης και αξιολόγησης των αλγορίθμων που ακολουθούν στα επόμενα κεφάλαια.
- **Επιλεγμένοι Αλγόριθμοι για Ανίχνευση Ανωμαλιών σε Χρονοσειρές:** Στο κεφάλαιο αυτό παρουσιάζονται και αναλύονται οι αλγόριθμοι που επιλέχθηκαν για την ανίχνευση ανωμαλιών. Περιγράφονται η θεωρητική τους βάση και η λειτουργικότητά τους.
- **Πειραματική Μελέτη:** Περιγράφεται η διαδικασία των πειραμάτων, τα δεδομένα που χρησιμοποιήθηκαν, οι μετρικές αξιολόγησης, καθώς και οι παράμετροι εκτέλεσης των αλγορίθμων.
- **Αποτελέσματα:** Παρουσιάζονται και σχολιάζονται τα αποτελέσματα της πειραματικής αξιολόγησης. Περιλαμβάνεται σύγκριση μεταξύ των μεθόδων και ανάλυση της αποτελεσματικότητάς τους.
- **Επίλογος:** Γίνεται σύνοψη των συμπερασμάτων της εργασίας και προτείνονται πιθανές κατευθύνσεις για βελτιώσεις και μελλοντική έρευνα.

Κεφάλαιο 2

Θεωρητικό υπόβαθρο

Στο παρόν κεφάλαιο αναλύονται οι βασικές θεωρητικές έννοιες που σχετίζονται με την ανίχνευση ανωμαλιών σε χρονοσειρές. Αρχικά, ορίζονται οι έννοιες των ανωμαλιών, του θορύβου και των νεωτερισμών, ενώ ακολουθεί η κατηγοριοποίηση των ακραίων τιμών σε σημειακές, συλλογικές και υπό όρους. Παρουσιάζονται οι κύριες μεθοδολογικές προσεγγίσεις ανίχνευσης με βάση τη διαθεσιμότητα ετικετών, καθώς και τα θεμελιώδη χαρακτηριστικά των χρονοσειρών, όπως η στασιμότητα, η αυτοσυσχέτιση και τα βασικά δομικά μοτίβα.

Εστιάζοντας στις χρονοσειρές, εξετάζεται η ειδική περίπτωση των ανωμαλιών μετατόπισης, ενώ παρουσιάζονται οι δύο βασικές στρατηγικές ανίχνευσης: προβλεπτικές και δομικές. Παρότι τα δεδομένα είναι επισημασμένα, αξιοποιούνται μέθοδοι όλων των τύπων (εποπτευόμενες, ημι-εποπτευόμενες και μη εποπτευόμενες), λαμβάνοντας υπόψη τη διαφορετική λειτουργία κάθε αλγορίθμου. Το κεφάλαιο ολοκληρώνεται με μια επισκόπηση των βασικών κατηγοριών αλγορίθμων που θα μελετηθούν: στατιστικές μέθοδοι, μέθοδοι μηχανικής μάθησης και βαθιάς μάθησης.

2.1 Ανωμαλίες και Ακραίες Τιμές

Σύμφωνα με τον Hawkins [32], ως ακραίο σημείο ή ανωμαλία ορίζεται μια παρατήρηση που αποκλίνει τόσο έντονα από τη συνήθη συμπεριφορά των δεδομένων, ώστε να προκαλεί την υποψία ότι έχει παραχθεί από διαφορετικό μηχανισμό. Οι μηχανισμοί αυτοί είναι συχνά στενά συνδεδεμένοι με το εκάστοτε πεδίο εφαρμογής, καθιστώντας την κατανόηση του πλαισίου ιδιαίτερα σημαντική για την ανάλυση και την ερμηνεία των ανωμαλιών. Η έννοια της ανωμαλίας διαφοροποιείται από τον θόρυβο, ο οποίος αντιστοιχεί σε τυχαία ή εσφαλμένη πληροφορία στα δεδομένα, που δεν έχει νόημα ή αξία για τον αναλυτή [58]. Τα δύο είδη θορύβου είναι όταν η ετικέτα είναι λάθος (*class noise*), π.χ. μια εικόνα με όγκο που έχει ετικέτα "υγιής", είτε όταν κάποιο χαρακτηριστικό είναι λάθος (*attribute noise*), π.χ. μια θερμοκρασία που έχει καταγραφεί ως 400°C αντί για 40°C. Στο δεύτερο, γίνεται αναφορά σε σφάλμα καταγραφής από αισθητήρα, ενώ αν όντως ανέβηκε στους 400°C, π.χ. γιατί πήρε φωτιά ο εξο-

πλισμός, τότε είναι ανωμαλία. Βέβαια, σε ορισμένα datasets, όπως το SMD (Server Machine Dataset) που προτάθηκε από τους Ren κ.ά. το 2019 [55] και αποτελεί σύνολο δεδομένων πολυμεταβλητών χρονοσειρών, περιπτώσεις σφαλμάτων αισθητήρων, αν και θεωρητικά ταξινομούνται ως λάθος χαρακτηριστικά, επισημαίνονται και αντιμετωπίζονται ως ανωμαλίες, καθώς δύνανται να επηρεάσουν τη συμπεριφορά του συστήματος και να προκαλέσουν μη φυσιολογική λειτουργία, άρα αρκετές φορές η θεωρία διαφέρει με την εφαρμογή.

Επίσης, είναι σημαντικό να γίνεται διάκριση μεταξύ ανωμαλιών και νεωτερισμών (novelties) [15]. Οι νεωτερισμοί αναφέρονται σε σημεία δεδομένων τα οποία δεν έχουν εμφανιστεί προηγουμένως στο σύνολο δεδομένων, ωστόσο, σε αντίθεση με τις ανωμαλίες, θεωρούνται φυσιολογικά μόλις εντοπιστούν για πρώτη φορά. Ένα χαρακτηριστικό παράδειγμα αποτελεί η εμφάνιση ενός νέου μοτίβου επικοινωνίας προς έναν διακομιστή έπειτα από την εισαγωγή ενός νέου πρωτοκόλλου. Παρόλα αυτά, λόγω της μεθοδολογικής επικάλυψης μεταξύ τεχνικών ανίχνευσης ανωμαλιών και νεωτερισμών, στην παρούσα διπλωματική αντιμετωπίζονται εννιαία.

2.1.1 Κατηγορίες Ακραίων Τιμών

Τα ακραία σημεία διακρίνονται σε τρεις βασικές κατηγορίες:

Ακραίο Σημείο Υπό Όρους (Contextual Outlier): Παρατηρήσεις που θεωρούνται ακραίες μόνο εντός συγκεκριμένου πλαισίου ή περιβάλλοντος. Για παράδειγμα, θερμοκρασία 20°C θεωρείται φυσιολογική σε εύκρατο κλίμα, αλλά είναι μη αναμενόμενη στην Ανταρκτική.

Ανωμαλία Σημείου (Global Outlier): Παρατηρήσεις που αποκλίνουν σαφώς από το σύνολο των υπολοίπων δεδομένων. Αυτή η κατηγορία αποτελεί τη συχνότερη μορφή ανωμαλιών, με τους περισσότερους αλγόριθμους να στοχεύουν στην ανίχνευσή τους. Παράδειγμα αποτελεί η ανίχνευση ασυνήθιστης επικοινωνιακής δραστηριότητας σε ένα δίκτυο υπολογιστών.

Συλλογική Ανωμαλία (Collective Outlier): Ομάδα παρατηρήσεων που, μεμονωμένα, δεν θεωρούνται ακραίες, αλλά από κοινού αποκλίνουν από τη γενική συμπεριφορά των δεδομένων. Για παράδειγμα, ένα σύνολο υπολογιστών που στέλνουν μαζικά πακέτα άρνησης υπηρεσίας (DoS) μπορεί να χαρακτηριστεί ως συλλογική ανωμαλία.

2.1.2 Προσεγγίσεις Ανίχνευσης Ακραίων Τιμών

Η ανίχνευση ακραίων τιμών μπορεί να πραγματοποιηθεί μέσω διαφόρων μεθόδων, ανάλογα με τη διαθεσιμότητα επισημασμένων δεδομένων (*labels*).

Εποπτευόμενες Μέθοδοι: Χρησιμοποιούνται όταν υπάρχουν διαθέσιμα επισημασμένα δεδομένα, δηλαδή όταν κάθε παρατήρηση συνοδεύεται από την αντίστοιχη ετικέτα κατηγορίας (κα-

νονική ή ανώμαλη). Σε αυτήν την περίπτωση, μπορούν να εκπαιδευτούν ταξινομητές δυαδικής κλάσης που διαχωρίζουν μεταξύ φυσιολογικών και ακραίων παραδειγμάτων. Ενδεικτικοί αλγόριθμοι που χρησιμοποιούνται σε αυτό το πλαίσιο είναι οι *XGBoost*, *LSTM* και *MLP*.

Ημι-Εποπτευόμενες Μέθοδοι: Εφαρμόζονται σε περιπτώσεις όπου υπάρχει μεγάλος όγκος μη επισημασμένων δεδομένων και περιορισμένος αριθμός επισημασμένων. Συνήθως, η εκπαίδευση βασίζεται αποκλειστικά σε κανονικά παραδείγματα, με στόχο την κατασκευή μοντέλου που μαθαίνει την κανονικότητα και εντοπίζει τις αποκλίσεις ως ανωμαλίες. Σε αυτό το πλαίσιο εντάσσονται και οι μέθοδοι μονής κλάσης, όπως οι Μηχανές Διανυσμάτων Υποστήριξης Μιας Κλάσης (OC-SVM), οι οποίες έχουν αποδειχθεί αποτελεσματικές όταν εκπαιδεύονται αποκλειστικά με φυσιολογικά δεδομένα [60].

Μη Εποπτευόμενες Μέθοδοι: Εφαρμόζονται όταν δεν υπάρχουν διαθέσιμες ετικέτες. Οι μέθοδοι αυτές βασίζονται σε υποθέσεις για την κατανομή των δεδομένων, είτε με στατιστικά είτε με υπολογιστικά μοντέλα, με στόχο τον εντοπισμό ακραίων παρατηρήσεων. Περιλαμβάνουν παραμετρικές και μη παραμετρικές προσεγγίσεις, όπως μίγματα κανονικών κατανομών, μετρικές αποστάσεων (π.χ. Ευκλείδεια, Mahalanobis) και ιστογράμματα. Επιπλέον, αξιοποιούνται μέθοδοι βασισμένες στην εκτίμηση πυκνότητας, όπως ο Τοπικός Παράγοντας Αποκλίσεων (LOF), καθώς και τεχνικές ομαδοποίησης, όπως οι DBSCAN, CBLOF και K-Means. Κοινή παραδοχή αυτών των προσεγγίσεων είναι ότι τα ανώμαλα σημεία εντοπίζονται σε περιοχές χαμηλής πυκνότητας.

2.2 Στοχαστικές Διαδικασίες και Χρονοσειρές

Η θεωρητική βάση που ακολουθεί στηρίζεται στο κλασικό έργο των Brockwell και Davis [13]. Μια χρονοσειρά είναι ένα σύνολο παρατηρήσεων x_t , οι οποίες καταγράφονται διαδοχικά σε χρονικές στιγμές t . Γίνεται διάκριση μεταξύ συνεχών χρονοσειρών, όταν οι παρατηρήσεις συλλέγονται συνεχώς στο χρόνο, και διακριτών χρονοσειρών, όταν οι παρατηρήσεις καταγράφονται σε διακριτά χρονικά διαστήματα. Στο πλαίσιο της παρούσας εργασίας, εξετάζονται μόνο διακριτές χρονοσειρές, δηλαδή σειρές που οι τιμές παρατηρούνται σε σταθερά χρονικά διαστήματα.

Επιπλέον, οι χρονοσειρές διακρίνονται σε ντετερμινιστικές και στοχαστικές. Ντετερμινιστική είναι μια χρονοσειρά της οποίας οι μελλοντικές τιμές μπορούν να προβλεφθούν πλήρως μέσω ενός μαθηματικού τύπου. Αντιθέτως, μια στοχαστική (ή μη ντετερμινιστική) χρονοσειρά περιλαμβάνει έναν τυχαίο παράγοντα, ο οποίος δεν επιτρέπει την πλήρη περιγραφή της μέσω αναλυτικής έκφρασης.

Για να προβλεφθούν οι μελλοντικές τιμές μιας στοχαστικής χρονοσειράς, γίνεται η υπόθεση ότι υπάρχει ένα στοχαστικό μοντέλο το οποίο παράγει τις παρατηρήσεις της. Πιο συγκεκριμένα:

Διακριτή Στοχαστική Διεργασία: Μια διακριτή στοχαστική διεργασία είναι μια ακολουθία τυχαίων μεταβλητών $\{X_t\}$, ορισμένων για χρονικές στιγμές $t \in \mathbb{Z}$.

Αυτό σημαίνει ότι για κάθε χρονική στιγμή t , υπάρχει μια τυχαία μεταβλητή X_t , η οποία λαμβάνει τιμές σύμφωνα με μια κατανομή. Η χρονοσειρά που μελετάται στην πράξη, δηλαδή οι πραγματικές τιμές x_t , αποτελεί μία συγκεκριμένη πραγματοποίηση (*realization*) αυτής της στοχαστικής διεργασίας.

Έτσι, βάσει των Brockwell και Davis [13], ένα μοντέλο χρονοσειράς (*time series model*) για τα παρατηρούμενα δεδομένα $\{x_t\}$, αποτελεί μια μαθηματική προδιαγραφή της κοινής κατανομής (*joint distribution*) – ή ενδεχομένως μόνο των μέσων τιμών και των συνδιακυμάνσεων – μιας ακολουθίας τυχαίων μεταβλητών $\{X_t\}$, των οποίων η $\{x_t\}$ θεωρείται ότι είναι μια συγκεκριμένη πραγματοποίηση.

2.2.1 Βασικά Μοτίβα Χρονοσειρών

Η ανάλυση χρονοσειρών στηρίζεται στην παραδοχή ότι κάθε χρονοσειρά μπορεί να αναλυθεί σε βασικά δομικά μοτίβα ή συνιστώσες. Τα συνηθέστερα μοτίβα που συναντώνται σε χρονοσειρές είναι τα εξής:

2.2.2 Επίπεδο

Το επίπεδο (*level*) αναφέρεται στη μέση τιμή γύρω από την οποία κυμαίνεται η χρονοσειρά. Αντιπροσωπεύει το βασικό ύψος της χρονοσειράς χωρίς την επίδραση άλλων μοτίβων, όπως τάση ή εποχικότητα. Το επίπεδο μπορεί να είναι σταθερό ή να μεταβάλλεται με την πάροδο του χρόνου.

2.2.3 Τάση


Η τάση (*trend*) εκφράζει τη μακροπρόθεσμη κατεύθυνση της χρονοσειράς, είτε ανοδική είτε καθοδική. Μπορεί να είναι γραμμική ή μη γραμμική και προκύπτει συνήθως από συστηματικές επιδράσεις όπως τεχνολογική πρόοδος, πληθωρισμός ή πληθυσμιακή αύξηση. Η τάση δεν είναι απαραίτητα σταθερή στο χρόνο, ενώ η παρουσία της καθιστά τη χρονοσειρά μη στάσιμη.

2.2.4 Εποχικότητα

Η εποχικότητα (*seasonality*) περιγράφει τις περιοδικές διακυμάνσεις που εμφανίζονται σε σταθερά διαστήματα χρόνου, όπως μήνες, τρίμηνα ή έτη. Οφείλεται σε επαναλαμβανόμενα φαινόμενα, π.χ. καιρικές συνθήκες, εορταστικές περιόδους ή προγραμματισμένες ανθρώπινες δραστηριότητες. Η εποχικότητα μπορεί να είναι σταθερού ή μεταβαλλόμενου πλάτους και αποτελεί χαρακτηριστικό γνώρισμα πολλών οικονομικών και φυσικών χρονοσειρών.

2.2.5 Κυκλικότητα

Η κυκλικότητα (*cyclicality*) αφορά διακυμάνσεις μεγαλύτερης διάρκειας από την εποχικότητα, οι οποίες όμως δεν έχουν σταθερή περιοδικότητα. Συχνά σχετίζεται με οικονομικούς ή επιχειρηματικούς κύκλους, π.χ. κύκλους ύφεσης και ανάπτυξης. Σε αντίθεση με την εποχικότητα, η κυκλικότητα είναι πιο ακανόνιστη και δύσκολο να προβλεφθεί επακριβώς. Η διάρκεια αυτών των διακυμάνσεων είναι συνήθως τουλάχιστον 2 χρόνια [38].



Διάγραμμα 2.1: Παράδειγμα κάθε είδους μοτίβου χρονοσειράς.

Στο Διάγραμμα 2.1 παρατηρούνται 4 χρονοσειρές με τα προαναφερθέντα μοτίβα. Η πρώτη χρονοσειρά έχει δύο επίπεδα, που αλλάζουν στο 2024. Η πάνω δεξιά έχει μια συνεχή ανοδική τάση από το 2020 μέχρι το 2028. Η κάτω αριστερά παρουσιάζει μια ετήσια εποχικότητα και η κάτω δεξιά μια τετραετή κυκλικότητα, με μακροχρόνιες διακυμάνσεις.

2.2.6 Στασιμότητα στις Χρονοσειρές

Διαισθητικά, μία στάσιμη χρονοσειρά είναι μία χρονοσειρά η οποία διατηρεί τις ίδιες στατιστικές ιδιότητες σε οποιοδήποτε χρονικό διάστημα. Με άλλα λόγια, τα χαρακτηριστικά της δεν εξαρτώνται από το χρόνο. Τυπικά, μπορεί να οριστεί η στασιμότητα ως εξής [38]:

Ορισμός: Μια χρονοσειρά $\{X_t\}$ είναι στάσιμη αν για κάθε μετατόπιση $s \in \mathbb{Z}$, η κατανομή του $(X_1, X_2, \dots, X_T)$ είναι ίδια με την κατανομή του $(X_{1+s}, X_{2+s}, \dots, X_{T+s})$.

Ο παραπάνω ορισμός συνεπάγεται ότι μια στάσιμη χρονοσειρά $\{X_t\}$ εμφανίζει τις εξής ιδιότητες:

- **Σταθερή μέση τιμή**, δηλαδή δεν υπάρχει μακροχρόνια τάση στη χρονοσειρά.
- **Σταθερή διακύμανση**, δηλαδή η μεταβλητότητα της χρονοσειράς παραμένει ίδια στο χρόνο.
- **Σταθερή αυτοσυσχέτιση**, δηλαδή η συσχέτιση μεταξύ των μεταβλητών εξαρτάται μόνο από την υστέρηση και όχι από τη χρονική στιγμή.
- **Απουσία εποχικότητας**, δηλαδή δεν παρατηρούνται περιοδικές διακυμάνσεις (μια εποχική χρονοσειρά μπορεί να είναι στάσιμη εφόσον η εποχικότητά της είναι αυστηρά περιοδική και προβλέψιμη, χωρίς να αλλάζει η στατιστική της φύση με το χρόνο).

2.2.7 Αυτοσυσχέτιση

Η έννοια της αυτοσυσχέτισης είναι θεμελιώδης στην ανάλυση χρονοσειρών, καθώς μετρά το βαθμό συσχέτισης μιας χρονοσειράς με παλαιότερες τιμές της. Σημειώνεται ότι η έννοια της υστέρησης (*lag*), αναφέρεται στη χρονική μετατόπιση μιας μεταβλητής στο παρελθόν. Όπως αναφέρει και ο Rob Hyndman [38], η συνάρτηση αυτοσυσχέτισης (*Autocorrelation Function - ACF*) για υστέρηση h ορίζεται ως:

$$\rho(h) = \frac{\text{Cov}(X_t, X_{t+h})}{\text{Var}(X_t)}.$$

Η αυτοσυσχέτιση παρέχει πληροφορίες για την εσωτερική εξάρτηση της χρονοσειράς. Για παράδειγμα, υψηλές τιμές αυτοσυσχέτισης για μικρές υστερήσεις υποδηλώνουν ότι το παρελθόν έχει ισχυρή προβλεπτική δύναμη για το παρόν. Η μελέτη της ACF είναι απαραίτητη τόσο για την κατανόηση της δομής της χρονοσειράς όσο και για την επιλογή κατάλληλων μοντέλων (όπως MA, εποχιακό MA, ARIMA, SARIMA).

Η συνάρτηση μερικής αυτοσυσχέτισης (*PACF*) μιας στάσιμης χρονοσειράς X_t , όπως αναφέρεται στο βιβλίο των Shumway και Stoffer [65], συμβολιζόμενη ως ϕ_{hh} , για $h = 1, 2, \dots$, ορίζεται ως:

$$\phi_{11} = \text{corr}(X_{t+1}, X_t) = \rho(1)$$

και

$$\phi_{hh} = \text{corr}(X_{t+h} - \hat{X}_{t+h}, X_t - \hat{X}_t), \quad h \geq 2,$$

με τη συνάρτηση συσχέτισης να είναι $\text{corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var}(X)\text{Var}(Y)}}$ και ο όρος $\hat{X}_{t+h}$ είναι η βέλτιστη γραμμική πρόβλεψη της X_{t+h} με βάση τις ενδιάμεσες τιμές $\{X_{t+1}, X_{t+2}, \dots, X_{t+h-1}\}$. Αυτή η πρόβλεψη υπολογίζεται συνήθως μέσω γραμμικής παλινδρόμησης:

$$\hat{X}_{t+h} = \alpha_1 X_{t+1} + \alpha_2 X_{t+2} + \dots + \alpha_{h-1} X_{t+h-1},$$

με $\alpha_i, i = 1, \dots, h-1$, τα βάρη. Ομοίως, $\hat{X}_t$ είναι η γραμμική πρόβλεψη της X_t από τις ίδιες ενδιάμεσες τιμές.

Οι τυχαίες μεταβλητές $(X_{t+h} - \hat{X}_{t+h})$ και $(X_t - \hat{X}_t)$ είναι μη συσχετισμένες με το σύνολο $\{X_{t+1}, \dots, X_{t+h-1}\}$, με την τιμή ϕ_{hh} να εκφράζει τη συσχέτιση μεταξύ των X_{t+h} και X_t , αφού αφαιρεθεί η γραμμική εξάρτηση των ενδιάμεσων τιμών από το καθένα. Η μελέτη της PACF είναι απαραίτητη για την επιλογή των μοντέλων AR και εποχιακού AR, όπως και για τα ARIMA, SARIMA.

2.2.8 Λευκός Θόρυβος

Ο λευκός θόρυβος (*white noise*) είναι μια στοχαστική διεργασία $\{\epsilon_t\}$, η οποία προέρχεται από σταθερή κατανομή, έχει σταθερή και πεπερασμένη διακύμανση σ^2 , μηδενική μέση τιμή και χαρακτηρίζεται από το γεγονός ότι δεν εμφανίζει καμία χρονική εξάρτηση. Πιο συγκεκριμένα, η αυτοσυσχέτιση (ACF) και η μερική αυτοσυσχέτιση (PACF) του λευκού θορύβου είναι μηδενικές για κάθε υστέρηση $h \neq 0$, γεγονός που υποδηλώνει ότι δεν υπάρχει καμία συσχέτιση μεταξύ διαφορετικών χρονικών στιγμών. Αυτή η πλήρης απουσία δομής καθιστά τον λευκό θόρυβο στάσιμο, αφού οι στατιστικές του ιδιότητες παραμένουν αμετάβλητες στο χρόνο. Σε πολλά θεωρητικά μοντέλα ανάλυσης χρονοσειρών, ο λευκός θόρυβος θεωρείται ως η βασική μορφή σφάλματος, ενώ συχνά γίνεται η επιπλέον παραδοχή ότι οι τιμές του προέρχονται από την κανονική κατανομή $N(0, \sigma^2)$, οπότε γίνεται αναφορά σε κανονικό λευκό θόρυβο (Gaussian white noise).

2.2.9 Στάσιμες Διαδικασίες AR, MA και ARMA

Οι στάσιμες διαδικασίες αποτελούν βασικό θεμέλιο της θεωρίας χρονοσειρών, καθώς επιτρέπουν την ανάλυση και πρόβλεψη με βάση σταθερές στατιστικές ιδιότητες στο χρόνο. Ιδιαίτερο ενδιαφέρον παρουσιάζουν τα μοντέλα αυτοπαλινδρόμησης (*Autoregressive – AR*), κινητού μέσου (*Moving Average – MA*) και ο συνδυασμός τους (*Autoregressive Moving Average – ARMA*), τα οποία έχουν λάβει ευρεία εφαρμογή στις επιστήμες, ιδίως στην οικονομία και τη μηχανική.

Η αρχή της μελέτης των στάσιμων χρονοσειρών μέσω αυτοπαλινδρομικών μοντέλων αποδίδεται στον G. Udny Yule (1927), ο οποίος εισήγαγε τα AR μοντέλα στο πλαίσιο της ανάλυσης περιοδικοτήτων στις ηλιακές κηλίδες [83]. Αργότερα, ο Eugen Slutsky (1937) πρότεινε τα MA μοντέλα για να εξηγήσει οικονομικούς κύκλους ως αποτέλεσμα τυχαίων διαταραχών [69]. Η μαθηματική θεμελίωση

και η εκτεταμένη ανάλυση των ARMA μοντέλων ενισχύθηκε από τον Peter Whittle (1951), ο οποίος ανέπτυξε μεθόδους εκτίμησης παραμέτρων για στοχαστικά μοντέλα με χρήση της μεθόδου μέγιστης πιθανοφάνειας [78]. Η πιο ώριμη και εφαρμοσμένη μορφή αυτών των μοντέλων παρουσιάστηκε από τους Box και Jenkins (1970), οι οποίοι συνδυάζοντάς τα, καθιέρωσαν τη μεθοδολογία ARIMA για τη μοντελοποίηση και πρόβλεψη χρονοσειρών, η οποία θα αναλυθεί στο Κεφάλαιο 3.

Μια στάσιμη αυτοπαλινδρομική διαδικασία τάξης p (AR(p)) ορίζεται ως:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \epsilon_t,$$

όπου ϵ_t είναι λευκός θόρυβος με μέσο μηδέν και σταθερή διακύμανση σ^2 , και οι σταθερές $\phi_1, \dots, \phi_p$ είναι οι αυτοπαλινδρομικοί συντελεστές. Η διαδικασία θεωρείται στάσιμη εάν οι ρίζες του χαρακτηριστικού πολωνύμου $\Phi(z) = 1 - \phi_1 z - \phi_2 z^2 - \dots - \phi_p z^p$ βρίσκονται εκτός του μοναδιαίου κύκλου.

Μια διαδικασία κινητού μέσου τάξης q (MA(q)) ορίζεται ως:

$$X_t = \epsilon_t + \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} + \dots + \theta_q \epsilon_{t-q},$$

όπου $\theta_1, \dots, \theta_q$ είναι οι συντελεστές κινητού μέσου. Η MA διαδικασία είναι πάντοτε στάσιμη ανεξαρτήτως των τιμών των παραμέτρων, εφόσον ο λευκός θόρυβος είναι στάσιμος.

Ο συνδυασμός των δύο προηγούμενων διαδικασιών οδηγεί στη διαδικασία ARMA(p, q), η οποία συνδυάζει p όρους αυτοπαλινδρόμησης και q όρους κινητού μέσου. Ορίζεται ως:

$$X_t = \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \epsilon_t + \theta_1 \epsilon_{t-1} + \dots + \theta_q \epsilon_{t-q}$$

ή πιο συνοπτικά με τελεστές καθυστέρησης (lag operators):

$$\Phi(B)X_t = \Theta(B)\epsilon_t,$$

όπου $\Phi(B) = 1 - \phi_1 B - \dots - \phi_p B^p$, $\Theta(B) = 1 + \theta_1 B + \dots + \theta_q B^q$, και B είναι ο τελεστής καθυστέρησης ($BX_t = X_{t-1}$). Για να είναι η ARMA διαδικασία στάσιμη, απαιτείται και εδώ οι ρίζες του πολωνύμου $\Phi(z)$ να βρίσκονται εκτός του μοναδιαίου κύκλου.


2.3 Ανίχνευση Ανωμαλιών σε Χρονοσειρές

Η ανίχνευση ανωμαλιών σε χρονοσειρές αποτελεί ένα ιδιαίτερο και απαιτητικό υποσύνολο του

γενικότερου προβλήματος εντοπισμού ανωμαλιών, καθώς τα δεδομένα εμφανίζουν χρονική εξάρτηση. Σε αντίθεση με τα στατικά δεδομένα, όπου κάθε παρατήρηση θεωρείται ανεξάρτητη, οι τιμές μιας χρονοσειράς εξαρτώνται από προηγούμενες χρονικές στιγμές, δημιουργώντας δυναμικές σχέσεις και μοτίβα. Μια παρατήρηση μπορεί να χαρακτηριστεί ως ανώμαλη όχι λόγω του απόλυτου μεγέθους της, αλλά επειδή αποκλίνει από την αναμενόμενη χρονική συμπεριφορά.

Όπως παρουσιάστηκε στο προηγούμενο κεφάλαιο, οι ανωμαλίες διακρίνονται σε σημειακές, συλλογικές και υπό όρους. Ωστόσο, στο πλαίσιο των χρονοσειρών, συναντάται συχνά και μια τέταρτη μορφή, η αλλαγή μετατόπισης (*change point anomaly*), που αφορά απότομες ή σταδιακές μεταβολές στη στατιστική δομή της χρονοσειράς.

Αλλαγή Μετατόπισης (Change Point/Shift Anomaly): Αναφέρεται σε ξαφνικές ή σταδιακές αλλαγές στο επίπεδο, τη μέση τιμή, τη διακύμανση ή την αυτοσυσχέτιση της χρονοσειράς. Αν και αυτές οι μεταβολές δεν αποτελούν απαραίτητα ακραίες τιμές, συχνά υποδηλώνουν σημαντικές αλλαγές στη δυναμική του συστήματος. Για παράδειγμα, μια απότομη αύξηση στην κατανάλωση ενέργειας μπορεί να υποδεικνύει μετάβαση σε νέα φάση λειτουργίας σε μια βιομηχανική εγκατάσταση.



Διάγραμμα 2.2: Παράδειγμα των βασικών ειδών ανωμαλιών σε χρονοσειρές, με δεδομένα από το Yahoo! Webscope S5.

Το Διάγραμμα 2.2 απεικονίζει παραδείγματα των τεσσάρων βασικών κατηγοριών ανωμαλιών που απαντώνται σε χρονοσειρές. Οι σημειακές ανωμαλίες (*point anomalies*) εμφανίζονται ως μεμονωμένες αποκλίσεις (π.χ. στο χρόνο 1200), ενώ οι συλλογικές ανωμαλίες (*collective anomalies*) προκύπτουν από ομάδες τιμών που αποκλίνουν συνολικά (χρόνοι 800, 1000 και 1300). Οι υπό όρους ανωμαλίες (*contextual anomalies*) παραβιάζουν το τοπικό μοτίβο (π.χ. εποχικότητα), όπως φαίνεται στους χρόνους 600 και 1000. Τέλος, οι ανωμαλίες μετατόπισης (*change point anomalies*) εκδηλώνο-

νται ως μακροχρόνιες αλλαγές στη δομή της χρονοσειράς (χρόνοι 200, 1350 και 1400).

Οι χρονοσειρές διακρίνονται σε μονομεταβλητές (*univariate*), όταν περιγράφεται μόνο μία μεταβλητή στον χρόνο, και σε πολυμεταβλητές (*multivariate*), όταν καταγράφονται περισσότερες ταυτόχρονα. Στην παρούσα διπλωματική, η ανάλυση επικεντρώνεται αποκλειστικά στις μονομεταβλητές χρονοσειρές, στις οποίες η ανωμαλία εντοπίζεται βάσει της δυναμικής και της δομής της ίδιας της σειράς.

Σύμφωνα με τον Aggarwal [2], οι μέθοδοι ανίχνευσης ανωμαλιών σε χρονοσειρές διακρίνονται σε δύο κύριες κατηγορίες:

- **Προβλεπτικές (prediction-based):** Μοντελοποιούν τη χρονοσειρά και προβλέπουν τη μελλοντική τιμή. Η αξιοσημείωτη απόκλιση της πραγματικής τιμής από την πρόβλεψη χρησιμεύει ως ένδειξη ανωμαλίας.
- **Δομικές (shape-based):** Εστιάζουν στον εντοπισμό ασυνήθιστων μοτίβων ή μεταβολών στο σχήμα της χρονοσειράς, χωρίς απαραίτητα χρήση πρόβλεψης.

Οι περισσότερες στατιστικές προσεγγίσεις εντάσσονται στην πρώτη κατηγορία, βασιζόμενες στο σφάλμα πρόβλεψης. Από την άλλη, αρκετές μέθοδοι μηχανικής μάθησης (ML), όπως clustering-based τεχνικές, επιδιώκουν να εντοπίσουν παρατηρήσεις που αποκλίνουν από τα κύρια μοτίβα συσσωμάτωσης (*clusters*) των δεδομένων.

Στην παρούσα διπλωματική χρησιμοποιούνται **μονομεταβλητές χρονοσειρές με διαθέσιμες ετικέτες**, γεγονός που επιτρέπει την αντικειμενική αξιολόγηση των αποτελεσμάτων μέσω κατάλληλων μετρικών. Παρά τη διαθεσιμότητα αυτών των επισημάνσεων, εφαρμόζονται και οι τρεις κατηγορίες μεθόδων — εποπτευόμενες, ημι-εποπτευόμενες και μη εποπτευόμενες — καθώς κάθε αλγόριθμος λειτουργεί με διαφορετικό τρόπο και αξιοποιεί διαφορετική πληροφορία από τα δεδομένα.

2.4 Επισκόπηση Αλγορίθμων Ανίχνευσης Ανωμαλιών

Η ανίχνευση ανωμαλιών σε χρονοσειρές μπορεί να υλοποιηθεί με διαφορετικές τεχνικές, οι οποίες διαφέρουν τόσο στη φιλοσοφία τους όσο και στις υποθέσεις που κάνουν για τα δεδομένα. Οι μέθοδοι μπορούν να ομαδοποιηθούν στις εξής κατηγορίες:

- **Στατιστικές μέθοδοι:** Βασίζονται σε υποθέσεις για την κατανομή των δεδομένων ή τη χρονική εξάρτηση (π.χ. μέση τιμή, διακύμανση, εποχικότητα).
- **Μέθοδοι μηχανικής μάθησης:** Μοντελοποιούν τη δομή των δεδομένων χωρίς να κάνουν ισχυρές στατιστικές υποθέσεις. Συχνά απαιτούν μετασχηματισμούς των χρονοσειρών για να γίνουν εφαρμόσιμοι.

- **Μέθοδοι βαθιάς μάθησης:** Χρησιμοποιούν νευρωνικά δίκτυα για την εκμάθηση αναπαραστάσεων ή την πρόβλεψη, επιτυγχάνοντας καλύτερη απόδοση σε πολύπλοκα μοτίβα ή μεγάλα δεδομένα.

Αναλυτική παρουσίαση των συγκεκριμένων αλγορίθμων και της πειραματικής διαδικασίας ακολουθεί στα επόμενα κεφάλαια.

Κεφάλαιο 3

Αναλυτική Περιγραφή των Αλγορίθμων

Το παρόν κεφάλαιο παρουσιάζει τη θεωρητική θεμελίωση και βασικές αρχές λειτουργίας των σημαντικότερων κατηγοριών αλγορίθμων ανίχνευσης ανωμαλιών, οι οποίες διακρίνονται σε στατιστικές, μεθόδους μηχανικής μάθησης και προσεγγίσεις βαθιάς μάθησης. Αρχικά, αναλύονται οι στατιστικοί αλγόριθμοι, όπως το γραμμικό μοντέλο (Linear Model), οι μέθοδοι εκθετικής εξομάλυνσης, και τα χρονικά μοντέλα ARIMA, SARIMA, τα οποία βασίζονται σε υποθέσεις στάσιμων ή εποχικών χρονοσειρών και αξιοποιούν ιστορικά μοτίβα για πρόβλεψη και εντοπισμό αποκλίσεων. Στη συνέχεια, εξετάζονται αλγόριθμοι μηχανικής μάθησης για την ανίχνευση ανωμαλιών, οι οποίοι βασίζονται σε διαφορετικές θεωρητικές αρχές. Τα Δάση Απομόνωσης (Isolation Forests) αξιοποιούν την ιδέα της τυχαίας απομόνωσης παρατηρήσεων σε δένδρα, όπου οι ανωμαλίες απαιτούν λιγότερες διαχωριστικές ενέργειες και συνεπώς εντοπίζονται πιο εύκολα. Ο Τοπικός Παράγοντας Αποκλίσεων (Local Outlier Factor – LOF) βασίζεται σε πυκνότητα, συγκρίνοντας την τοπική πυκνότητα μιας παρατήρησης (βλέπε Ενότητα 3.2.2) με εκείνη των γειτόνων της για να εκτιμήσει πόσο απομονωμένη είναι. Οι Μηχανές Διανυσμάτων Υποστήριξης Μιας Κλάσης (One-Class SVM) προσεγγίζουν την κανονικότητα μέσω θεωρίας υποχώρων, εντοπίζοντας το όριο που διαχωρίζει την πλειονότητα των φυσιολογικών παρατηρήσεων από την υπόλοιπη χωρική περιοχή. Τέλος, ο αλγόριθμος DBSCAN (Density-Based Spatial Clustering of Applications with Noise) βασίζεται επίσης σε πυκνότητα, εντοπίζοντας συσσωματώσεις παρατηρήσεων και ταξινομώντας ως ανώμαλες εκείνες που βρίσκονται εκτός πυκνών περιοχών. Επόμενοι είναι οι αλγόριθμοι Προφίλ Πίνακα, που εντοπίζει ανωμαλίες μέσω της σύγκρισης υποσειρών και ο XGBoost, ένας από τους πιο διάσημους και ισχυρούς επαναληπτικούς ταξινομητές. Τέλος, παρουσιάζονται μέθοδοι βαθιάς μάθησης, όπως το Πολυστρωματικό Perceptron (Multi-layered Perceptron), τα επαναληπτικά Δίκτυα Μακράς Βραχύχρονης Μνήμης (LSTM) και οι Αυτοκωδικοποιητές, οι οποίοι αξιοποιούνται για την αναπαράσταση πολύπλοκων και μη γραμμικών μοτίβων σε χρονοσειρές, ακόμα και χωρίς επισημασμένα δεδομένα. Συνολικά, το κεφάλαιο παρέχει το απαραίτητο θεωρητικό υπόβαθρο για την κατανόηση και συγκριτική αξιολόγηση ετερογενών τεχνικών ανίχνευσης ανωμαλιών, ενόψει της πειραματικής εφαρμογής τους σε επόμενα κεφάλαια.

3.1 Στατιστικοί Αλγόριθμοι

3.1.1 Γραμμικό Μοντέλο και η Σχέση του με το AR Μοντέλο

Το γραμμικό μοντέλο αποτελεί τη βασική μορφή παλινδρόμησης στη στατιστική και χρησιμοποιείται ευρέως για την περιγραφή της σχέσης μεταξύ μιας εξαρτημένης και μιας ανεξάρτητης μεταβλητής. Στη βασική του μορφή, εκφράζεται ως:

$$Y_t = \beta_0 + \beta_1 X_t + \epsilon_t,$$

όπου Y_t είναι η εξαρτημένη μεταβλητή, X_t η ανεξάρτητη μεταβλητή, β_0 και β_1 είναι οι συντελεστές παλινδρόμησης, και ϵ_t είναι το σφάλμα παλινδρόμησης, το οποίο θεωρείται λευκός θόρυβος με μηδενική μέση τιμή και σταθερή διακύμανση.

Στην περίπτωση χρονοσειρών, η ανεξάρτητη μεταβλητή X_t μπορεί να είναι προηγούμενες τιμές της ίδιας της εξαρτημένης μεταβλητής Y_t , δηλαδή υστερημένες τιμές της σειράς. Έτσι, το γραμμικό μοντέλο μετατρέπεται σε μοντέλο παλινδρόμησης με καθυστερήσεις, γνωστό ως αυτοπαλινδρομικό (Autoregressive - AR) μοντέλο. Η γενική μορφή του αυτοπαλινδρομικού μοντέλου τάξης p (AR(p)) δίνεται από:

$$X_t = \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \epsilon_t.$$

Στην παραπάνω σχέση, η τιμή της χρονοσειράς X_t εξαρτάται γραμμικά από τις προηγούμενες p τιμές της, καθώς και από έναν όρο λευκού θορύβου ϵ_t . Το μοντέλο αυτό μπορεί να ιδωθεί ως μια ειδική περίπτωση του γραμμικού μοντέλου, όπου οι ανεξάρτητες μεταβλητές είναι οι υστερημένες τιμές της ίδιας της εξαρτημένης μεταβλητής. Η μετάβαση από το γενικό γραμμικό μοντέλο στο AR μοντέλο είναι ιδιαίτερα χρήσιμη όταν πρόκειται για χρονοσειρές που παρουσιάζουν συσχέτιση με το παρελθόν.

3.1.2 Μη Στάσιμες Διαδικασίες ARIMA και SARIMA

Παρότι τα μοντέλα AR, MA και ARMA αποτελούν θεμελιώδεις σταθμούς στη θεωρία χρονοσειρών, προϋποθέτουν ότι η χρονοσειρά υπό μελέτη είναι στάσιμη. Στην πράξη, ωστόσο, πολλές πραγματικές χρονοσειρές εμφανίζουν τάσεις, εποχικότητα ή άλλες μορφές μη στάσιμης συμπεριφοράς. Για την αντιμετώπιση αυτών των περιπτώσεων, εισήχθησαν τα μοντέλα ολοκλήρωσης ARIMA (*Αυτοπαλινδρομικά Ολοκληρωμένα μοντέλα Κινητού Μέσου - Autoregressive Integrated Moving Average*) και οι εποχικές τους επεκτάσεις SARIMA (*Seasonal ARIMA*), τα οποία καθιερώθηκαν από τους Box και Jenkins (1970) στο έργο τους *Time Series Analysis: Forecasting and Control* [10].

Το μοντέλο $ARIMA(p, d, q)$ αποτελεί γενίκευση του $ARMA$, επιτρέποντας στην αρχική χρονοσειρά να γίνει στάσιμη μέσω διαφοροποίησης. Ο όρος Ολοκληρωμένο *Integrated* αναφέρεται ακριβώς σε αυτή τη διαδικασία. Η διαφοροποίηση εφαρμόζεται για την απομάκρυνση μακροπρόθεσμων τάσεων και τη σταθεροποίηση της μέσης τιμής της σειράς.

Υπάρχουν δύο βασικοί τύποι διαφοροποίησης:

- **Απλή (γραμμική) διαφοροποίηση** (*regular differencing*), η οποία απομακρύνει γραμμικές τάσεις. Ορίζεται ως:

$$X'_t = X_t - X_{t-1}.$$

Σε περίπτωση πιο σύνθετης ή μη γραμμικής τάσης, μπορεί να απαιτείται η εφαρμογή της διαδικασίας περισσότερες από μία φορές, δηλαδή $d > 1$, με την παράμετρο d να αποτελεί τον αριθμό των επαναλήψεων που εφαρμόζεται η διαδικασία.

- **Εποχική διαφοροποίηση** (*seasonal differencing*), η οποία αποσκοπεί στην εξάλειψη επαναλαμβανόμενων εποχικών μοτίβων. Ορίζεται ως:

$$X''_t = X_t - X_{t-n},$$

όπου n είναι το μήκος της εποχικής περιόδου (π.χ. $n = 12$ για μηνιαία δεδομένα με ετήσια εποχικότητα).

Η εποχική διαφοροποίηση συχνά εφαρμόζεται σε συνδυασμό με την απλή διαφοροποίηση για τη δημιουργία στάσιμων χρονοσειρών που περιέχουν τόσο τάσεις όσο και εποχικά μοτίβα, όπως συμβαίνει στα μοντέλα $SARIMA$.

Η κατάλληλη επιλογή του πλήθους διαφοροποιήσεων (d και D) είναι κρίσιμη για την επίτευξη στασιμότητας χωρίς να χαθεί η πληροφορία ή να προκληθεί υπερδιαφοροποίηση, η οποία μπορεί να εισάγει περιττό θόρυβο στη χρονοσειρά. Με αυτόν τον τρόπο, η εποχική δομή αφαιρείται από τη χρονοσειρά και διευκολύνεται η μοντελοποίηση της υπολειπόμενης συμπεριφοράς. Εάν μια χρονοσειρά $\{X_t\}$ απαιτεί d διαφορές για να καταστεί στάσιμη, τότε το μετασχηματισμένο σήμα $\{Y_t\} = \nabla^d X_t$ μοντελοποιείται ως $ARMA(p, q)$ διαδικασία. Η γενική μορφή του $ARIMA(p, d, q)$ είναι:

$$\Phi(B)\nabla^d X_t = \Theta(B)\epsilon_t,$$

όπου B είναι ο τελεστής καθυστέρησης, $\nabla^d = (1 - B)^d$ είναι ο τελεστής d -οστής διαφοράς, $\Phi(B)$ και $\Theta(B)$ είναι τα πολώνυμα αυτοπαλινδρόμησης και κινητού μέσου αντίστοιχα, όπως και στο $ARMA$ μοντέλο, και ϵ_t είναι λευκός θόρυβος.

Η ανάγκη για μοντελοποίηση εποχικών χρονοσειρών οδήγησε στη δημιουργία του μοντέλου $SARIMA$, το οποίο επεκτείνει το $ARIMA$ με εποχικούς όρους. Το μοντέλο

$SARIMA(p, d, q) \times (P, D, Q)_s$ συνδυάζει μη εποχικούς και εποχικούς όρους ARIMA, όπου s είναι η περίοδος της εποχικότητας, και οι παράμετροι P, D, Q αντιστοιχούν στους εποχικούς όρους αυτοπαλινδρόμησης, ολοκλήρωσης και κινητού μέσου αντίστοιχα.

Η γενική μορφή του SARIMA μοντέλου δίνεται από:

$$\Phi(B)\Phi_s(B^s)\nabla^d\nabla_s^D X_t = \Theta(B)\Theta_s(B^s)\epsilon_t,$$

όπου $\Phi(B)$ είναι το μη εποχικό πολυώνυμο αυτοπαλινδρόμησης (AR) τάξης p , $\Phi_s(B^s)$ είναι το εποχικό πολυώνυμο AR τάξης P , $\Theta(B)$ είναι το μη εποχικό πολυώνυμο κινητού μέσου (MA) τάξης q , και $\Theta_s(B^s)$ είναι το εποχικό πολυώνυμο MA τάξης Q . Ο τελεστής $\nabla^d = (1 - B)^d$ εκφράζει τη μη εποχική διαφοροποίηση, ενώ ο $\nabla_s^D = (1 - B^s)^D$ είναι ο τελεστής εποχικής διαφοροποίησης με περίοδο s .

Η επιλογή κατάλληλων τιμών για τις παραμέτρους p, d, q, P, D, Q, s πραγματοποιείται συνήθως με τη βοήθεια διαγνωστικών εργαλείων, όπως τα διαγράμματα αυτοσυσχέτισης (ACF) και μερικής αυτοσυσχέτισης (PACF), καθώς και με τη χρήση στατιστικών κριτηρίων προσαρμογής, όπως το AIC (*Akaike Information Criterion*) ή το BIC (*Bayesian Information Criterion*). Εναλλακτικά, είναι δυνατή η αξιολόγηση διαφορετικών συνδυασμών των υπερπαραμέτρων μέσω πειραματισμού, με στόχο την επιλογή εκείνου που ελαχιστοποιεί το σφάλμα πρόβλεψης. Μία από τις πιο ευρέως χρησιμοποιούμενες προσεγγίσεις είναι η μέθοδος *Box-Jenkins*, η οποία παρουσιάστηκε από τους Box και Jenkins στο ομώνυμο έργο τους [10]. Η διαδικασία ξεκινά με την εξέταση της στάσιμης συμπεριφοράς της χρονοσειράς και την αναγνώριση πιθανής εποχικότητας, ώστε να εφαρμοστούν οι απαραίτητοι μετασχηματισμοί (διαφορές ή εποχικές διαφορές). Στη συνέχεια, με βάση τα διαγνωστικά διαγράμματα ACF και PACF της μετασχηματισμένης σειράς, προσδιορίζονται οι τιμές των υπερπαραμέτρων. Οι παράμετροι του μοντέλου εκτιμώνται συνήθως μέσω της μεθόδου μέγιστης πιθανοφάνειας, ενώ το προσαρμοσμένο μοντέλο αξιολογείται ως προς την ικανότητά του να αναπαράγει τη χρονοσειρά και να παρέχει αξιόπιστες προβλέψεις. Αν η απόδοσή του κριθεί μη ικανοποιητική, η διαδικασία επαναλαμβάνεται με νέα παραμετροποίηση.

Στο πλαίσιο της παρούσας διπλωματικής εργασίας, εξετάζεται αποκλειστικά το μοντέλο SARIMA, καθώς τα δεδομένα παρουσιάζουν είτε έντονη είτε ασθενή εποχικότητα, την οποία το κλασικό μοντέλο ARIMA δεν είναι σε θέση να αποτυπώσει επαρκώς.

3.1.3 Εκθετική Εξομάλυνση

Η εκθετική εξομάλυνση (*Exponential Smoothing*) αποτελεί μία από τις πιο σημαντικές και ευρέως χρησιμοποιούμενες μεθόδους πρόβλεψης χρονοσειρών. Βασίζεται στην αρχή της στάθμισης των παλαιότερων τιμών της σειράς με φθίνουσα βαρύτητα, δίνοντας μεγαλύτερη έμφαση στις πιο πρόσφατες παρατηρήσεις.

Η απλή εκθετική εξομάλυνση (*Simple Exponential Smoothing – SES*), γνωστή και ως πρώτης τάξης (*1st-order*), προτάθηκε από τον Robert G. Brown το 1956 [14] και χρησιμοποιείται όταν η χρονοσειρά δεν εμφανίζει σαφή τάση ή εποχικότητα. Η εξίσωση της πρόβλεψης είναι:

$$\hat{y}_{t+1} = \alpha y_t + (1 - \alpha)\hat{y}_t,$$

όπου $\alpha \in [0, 1]$ είναι ο συντελεστής εξομάλυνσης.

Στην περίπτωση που η χρονοσειρά παρουσιάζει γραμμική τάση, η απλή εξομάλυνση δεν είναι επαρκής. Γι' αυτόν τον λόγο, ο Charles C. Holt (1957) [36] πρότεινε τη διπλή εκθετική εξομάλυνση (*Holt's Linear Trend Method*), ή δεύτερης τάξης (*2nd-order*) εξομάλυνση, η οποία ενσωματώνει την πρόβλεψη του επιπέδου και της τάσης. Το μοντέλο αποτελείται από τις εξής εξισώσεις:

$$\begin{aligned} l_t &= \alpha y_t + (1 - \alpha)(l_{t-1} + b_{t-1}), \\ b_t &= \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}, \\ \hat{y}_{t+h} &= l_t + h \cdot b_t, \end{aligned}$$

όπου l_t είναι το επίπεδο, b_t η τάση, και α, β οι συντελεστές εξομάλυνσης.

Για χρονοσειρές που εμφανίζουν και εποχικότητα, ο μαθητής του Holt, Peter Winters (1960), επέκτεινε το μοντέλο Holt με την προσθήκη εποχιακής συνιστώσας, δημιουργώντας έτσι τη μέθοδο Holt-Winters [80]. Το πλήρες εποχιακό μοντέλο διατίθεται σε δύο μορφές: προσθετική και πολλαπλασιαστική, ανάλογα με τη φύση της εποχικότητας.

Η προσθετική εκδοχή χρησιμοποιείται όταν το εποχιακό μοτίβο παραμένει σταθερό σε ένταση καθ' όλη τη διάρκεια της σειράς, ενώ η πολλαπλασιαστική εφαρμόζεται όταν το εύρος της εποχικότητας μεταβάλλεται αναλογικά με το επίπεδο της σειράς. Οι εξισώσεις των δύο μοντέλων παρουσιάζονται συνοπτικά στον Πίνακα 3.1,

Συνιστώσα	Προσθετικό Μοντέλο	Πολλαπλασιαστικό Μοντέλο
Πρόβλεψη	$\hat{y}_{t+h} = l_t + h \cdot b_t + s_{t+h-m(k)}$	$\hat{y}_{t+h} = (l_t + h \cdot b_t) \cdot s_{t+h-m(k)}$
Επίπεδο	$l_t = \alpha(y_t - s_{t-m}) + (1 - \alpha)(l_{t-1} + b_{t-1})$	$l_t = \alpha \left(\frac{y_t}{s_{t-m}} \right) + (1 - \alpha)(l_{t-1} + b_{t-1})$
Τάση	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$	$b_t = \beta(l_t - l_{t-1}) + (1 - \beta)b_{t-1}$
Εποχικότητα	$s_t = \gamma(y_t - l_{t-1} - b_{t-1}) + (1 - \gamma)s_{t-m}$	$s_t = \gamma \left(\frac{y_t}{l_{t-1} + b_{t-1}} \right) + (1 - \gamma)s_{t-m}$

Πίνακας 3.1: Εξισώσεις εποχιακού μοντέλου Holt-Winters.

όπου l_t είναι το εκτιμώμενο επίπεδο της χρονοσειράς στο χρόνο t , b_t είναι η εκτιμώμενη τάση, και s_t η εποχική συνιστώσα. Το m δηλώνει την περίοδο εποχικότητας, ενώ h είναι ο χρονικός ορίζοντας

πρόβλεψης. Ο αριθμός πλήρων εποχιακών κύκλων δίνεται από $k = \lfloor (h - 1)/m \rfloor$. Οι παράμετροι α , β και γ είναι οι συντελεστές εξομάλυνσης για το επίπεδο, την τάση και την εποχικότητα αντίστοιχα.

Στην παρούσα διπλωματική, εξετάζεται το μοντέλο Εκθετικής Εξομάλυνσης Holt-Winters, καθώς είναι κατάλληλο για τη μοντελοποίηση δεδομένων με εποχικά χαρακτηριστικά — είτε έντονα είτε ηπιότερα — όπως έχει ήδη αναφερθεί.

3.2 Αλγόριθμοι Μηχανικής Μάθησης

3.2.1 Δάση Απομόνωσης


Τα Δάση Απομόνωσης (*Isolation Forests - IF*), επίσης γνωστά ως iForests, προτάθηκαν από τους Fei Tony Liu κ.ά. το 2008 [46], ενώ το 2012 αποδείχθηκε από την ίδια ομάδα ότι έχουν γραμμική πολυπλοκότητα και χαμηλή χρήση μνήμης, το οποίο τα καθιστά αποτελεσματικά σε μεγάλου όγκου δεδομένα [47]. Αποτελούν έναν αλγόριθμο ανίχνευσης ανωμαλιών που βασίζεται στην αρχή της απομόνωσης για τον εντοπισμό των ανωμαλιών. Τα Δάση Απομόνωσης επιλέγουν τυχαία ένα χαρακτηριστικό και στη συνέχεια επιλέγουν τυχαία μια τιμή διαχωρισμού εντός του εύρους των παρατηρούμενων τιμών για εκείνο. Με την επαναλαμβανόμενη εφαρμογή αυτού του τυχαίου διαχωρισμού, αναμένεται ότι οι μη φυσιολογικές τιμές (*anomalies*) θα βρίσκονται πιο κοντά στη ρίζα του δέντρου (με μικρότερα μέσα μήκη μονοπατιών) και θα απαιτούν λιγότερους διαχωρισμούς σε σύγκριση με τις φυσιολογικές τιμές (λιγότερους απαραίτητους διαχωρισμούς μέχρι την απομόνωση του σημείου). Αυτό συμβαίνει επειδή οι μη φυσιολογικές τιμές εμφανίζουν χαμηλότερη συχνότητα και προορίζεται να βρίσκονται σε διαχωρίσιμες περιοχές του χώρου σε σχέση με τις φυσιολογικές.

Έτσι, αυτή η μέθοδος θεωρεί τα σημεία με μικρότερα μήκη μονοπατιών (*shorter path lengths*) ως υποψήφιες τιμές που είναι πολύ πιθανό να είναι ανωμαλίες. Η διαδικασία ανίχνευσης ανωμαλιών με τη χρήση Δασών Απομόνωσης πραγματοποιείται γενικά σε δύο βήματα:

1. **Εκπαίδευση (Training):** Δημιουργούνται n Δέντρα Απομόνωσης (iTrees) για το δεδομένο σύνολο εκπαίδευσης.
2. **Αξιολόγηση (Evaluation):** Το σημείο ελέγχου (test instance) περνάει μέσα από τα δέντρα απομόνωσης για τον υπολογισμό του βαθμού ανωμαλίας (anomaly score).

Στο Διάγραμμα 3.1 παρουσιάζεται η παραπάνω διαδικασία. Παρατηρείται ότι για την απομόνωση μιας μη φυσιολογικής παρατήρησης (δεξιά) απαιτούνται σημαντικά λιγότεροι διαχωρισμοί σε σύγκριση με μια φυσιολογική παρατήρηση (αριστερά).

Όπως και σε άλλες μεθόδους ανίχνευσης ακραίων τιμών, τα Δάση Απομόνωσης υπολογίζουν μια βαθμολογία (*anomaly score*) για κάθε παρατήρηση, η οποία καθορίζει αν η παρατήρηση είναι



Διάγραμμα 3.1: Δάσος Απομόνωσης - Προσδιορισμός φυσιολογικών (αριστερά) και μη φυσιολογικών παρατηρήσεων (δεξιά).

φυσιολογική ή όχι. Για τα Δάση Απομόνωσης, αυτή ορίζεται ως εξής:

$$s(x, n) = 2^{-\frac{E(h(x))}{c(x)}},$$

όπου $h(x)$ είναι το μήκος του μονοπατιού για την παρατήρηση x από τον αρχικό κόμβο μέχρι την απομόνωσή της σε έναν τερματικό κόμβο, και $E(h(x))$ είναι το μέσο μήκος μονοπατιού σε όλα τα δέντρα απομόνωσης (iTrees). Ο όρος $c(n)$ χρησιμοποιείται για την κανονικοποίηση του κλάσματος και ορίζεται ως το μέσο μήκος μονοπατιού για ανεπιτυχείς αναζητήσεις σε ένα Δέντρο Δυαδικής Αναζήτησης (καθώς τα Δέντρα Απομόνωσης έχουν παρόμοια δομή με αυτά):

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n},$$

όπου H είναι ο αρμονικός αριθμός και μπορεί να εκτιμηθεί ως $H(i) = \ln(i) + \gamma$, με $\gamma = 0.577215664$ είναι η σταθερά του Euler.

Τέλος, αφού καθοριστεί ο παραπάνω δείκτης για κάθε παρατήρηση, μπορούν να ταξινομηθούν οι παρατηρήσεις ως φυσιολογικές ή μη φυσιολογικές με βάση τους ακόλουθους κανόνες:

- Αν η τιμή s είναι κοντά στο 1, τότε το σημείο x είναι πολύ πιθανόν να είναι ανώμαλο.
- Αν η τιμή s είναι μικρότερη από 0.5, τότε το σημείο x είναι πιθανόν κανονικό.
- Αν όλα τα σημεία στο δείγμα έχουν τιμή γύρω στο 0.5, τότε είναι πιθανόν όλα να είναι κανονικά.

3.2.2 Τοπικός Παράγοντας Αποκλίσεων

Στην ανίχνευση ανωμαλιών, ο Τοπικός Παράγοντας Αποκλίσεων (*Local Outlier Factor - LOF*) είναι ένας αλγόριθμος που προτάθηκε από τους Markus M. Breunig κ.ά. το 2000 [12]. Ο αλγόριθ-

μος αυτός χρησιμοποιείται για την εύρεση ανώμαλων σημείων δεδομένων, μετρώντας την τοπική απόκλιση ενός δεδομένου σημείου σε σχέση με τους γείτονές του. Ο συγκεκριμένος αλγόριθμος βασίζεται στην έννοια της τοπικής πυκνότητας, όπου η "τοπικότητα" ορίζεται από τους k πλησιέστερους γείτονες. Η απόσταση από αυτούς τους γείτονες χρησιμοποιείται για την εκτίμηση της πυκνότητας. Συγκρίνοντας την τοπική πυκνότητα ενός σημείου με αυτές των γειτόνων του, μπορούν να εντοπισθούν περιοχές με παρόμοια πυκνότητα και σημεία που έχουν σημαντικά χαμηλότερη πυκνότητα από τους γείτονές τους. Τέτοια σημεία θεωρούνται ασυνήθιστα (*outliers*).

Η τοπική πυκνότητα εκτιμάται από την τυπική απόσταση με την οποία ένα σημείο μπορεί να "προσεγγιστεί" από τους γείτονές του. Έστω $k\text{-distance}(A)$ η απόσταση του αντικειμένου A από τον k -οστό πλησιέστερο γείτονα. Το σύνολο των k πλησιέστερων γειτόνων συμβολίζεται ως $N_k(A)$. Η απόσταση προσβασιμότητας ορίζεται ως:

$$\text{reachability-distance}_k(A, B) = \max\{k\text{-distance}(B), d(A, B)\}.$$

Δηλαδή, η απόσταση προσβασιμότητας του A από το B είναι η πραγματική απόσταση $d(A, B)$ μεταξύ τους, αλλά τουλάχιστον ίση με την $k\text{-distance}(B)$. Αυτό γίνεται για να μειωθούν οι στατιστικές διακυμάνσεις μεταξύ των σημείων που βρίσκονται κοντά στο B . Όσο αυξάνεται το k , τόσο μεγαλύτερο είναι το μέγεθος εξομάλυνσης. Σημειώνεται ότι αυτή η απόσταση δεν είναι συμμετρική, δηλαδή δεν ισχύει η ιδιότητα της συμμετρίας που χαρακτηρίζει τις μαθηματικές αποστάσεις.

Η τοπική πυκνότητα προσβασιμότητας (*local reachability density*) του αντικειμένου A ορίζεται ως:

$$\text{lrd}_k(A) := \frac{1}{\frac{\sum_{B \in N_k(A)} \text{reachability-distance}_k(A, B)}{|N_k(A)|}}.$$

Δηλαδή, είναι το αντίστροφο της μέσης απόστασης προσβασιμότητας του A από τους γείτονές του. Σημειώνεται ότι δεν είναι η μέση απόσταση προσβασιμότητας των γειτόνων από το A , αλλά η απόσταση με την οποία το A μπορεί να "προσεγγιστεί" από τους γείτονές του. Σε περίπτωση διπλότυπων σημείων, αυτή η τιμή μπορεί να γίνει άπειρη.

Τέλος, ο οπικός παράγοντας αποκλίσεων - (LOF) του A υπολογίζεται ως:

$$\text{LOF}_k(A) := \frac{\sum_{B \in N_k(A)} \text{lrd}_k(B)}{|N_k(A)| \cdot \text{lrd}_k(A)}.$$

Δηλαδή, είναι ο μέσος όρος των τοπικών πυκνοτήτων προσβασιμότητας των γειτόνων του A , διαιρεμένος με την τοπική πυκνότητα προσβασιμότητας του ίδιου του A .

Οι τιμές του LOF ερμηνεύονται ως εξής:

- **LOF(k) $\approx$ 1:** Το σημείο έχει παρόμοια πυκνότητα με τους γείτονές του (δεν είναι ακραίο - outlier).
- **LOF(k) < 1:** Το σημείο βρίσκεται σε πυκνότερη περιοχή από τους γείτονές του (είναι εσωτερικό - inlier).
- **LOF(k) > 1:** Το σημείο βρίσκεται σε λιγότερο πυκνή περιοχή από τους γείτονές του (είναι ακραίο - outlier).

3.2.3 Μηχανές Διανυσμάτων Υποστήριξης Μίας Κλάσης

Ο αρχικός αλγόριθμος των Μηχανών Διανυσμάτων Υποστήριξης (*Support Vector Machines - SVM*) αναπτύχθηκε ως μια γραμμική, εποπτευόμενη μέθοδος από τους Vapnik και Chervonenkis το 1963 [73]. Αργότερα, οι Boser κ.ά. [9] επέκτειναν τον αλγόριθμο εισάγοντας την τεχνική του πυρήνα (kernel trick), η οποία επέτρεψε στα SVM να πραγματοποιούν μη γραμμική ταξινόμηση. Στη συνέχεια, για το πρόβλημα της ανίχνευσης ανωμαλιών, εισήχθη μια νέα προσέγγιση από τους Schölkopf κ.ά. [60] με χρήση SVM, γνωστή ως Μηχανή Διανυσμάτων Υποστήριξης Μίας Κλάσης *One-Class SVM (OC-SVM)*.

Αρχικά, γίνεται εισαγωγή της απαραίτητης ορολογίας και συμβολισμών. Έστω τα δεδομένα εκπαίδευσης

$$\mathbf{x}_1, \dots, \mathbf{x}_\ell \in \mathcal{X},$$

όπου $\ell \in \mathbb{N}$ είναι ο αριθμός των παρατηρήσεων και $\mathcal{X}$ είναι ένα σύνολο. Για απλότητα, θεωρείται ότι $\mathcal{X}$ είναι ένα συμπαγές υποσύνολο του $\mathbb{R}^N$. Έστω Φ ένας μετασχηματισμός χαρακτηριστικών $\Phi : \mathcal{X} \rightarrow F$, δηλαδή ένας μετασχηματισμός που χαρτογραφεί τα δεδομένα σε έναν χώρο εσωτερικών γινομένων F . Σε αυτόν τον χώρο, το εσωτερικό γινόμενο μεταξύ δύο σημείων μπορεί να υπολογιστεί μέσω μιας συνάρτησης πυρήνα (kernel)

$$K(\mathbf{x}, \mathbf{y}) = (\Phi(\mathbf{x}) \cdot \Phi(\mathbf{y})),$$

με την πιο διαδεδομένη επιλογή να είναι ο Γκαουσιανός πυρήνας (*Gaussian Kernel*):

$$K(\mathbf{x}, \mathbf{y}) = e^{-\|\mathbf{x}-\mathbf{y}\|^2/c},$$

επίσης γνωστού ως πυρήνα της Συνάρτησης Ακτινικής Βάσης (*Radial Basis Function kernel - (RBF)*), που γράφεται ως:

$$K(\mathbf{x}, \mathbf{y}) = e^{-\gamma\|\mathbf{x}-\mathbf{y}\|^2},$$

με το γ να ελέγχει το "πλάτος" του πυρήνα και να καθορίζει πόση επιρροή έχει ένα συγκεκριμένο σημείο εκπαίδευσης. Μια μικρή τιμή του γ οδηγεί σε πιο ομαλό όριο απόφασης (μεγαλύτερη επιρροή

σημείων που βρίσκονται μακριά), ενώ μια μεγάλη τιμή του κάνει τον πυρήνα να εστιάζει περισσότερο σε σημεία κοντά στο σημείο εκπαίδευσης, με αποτέλεσμα ένα πιο πολύπλοκο και τοπικά προσαρμοσμένο όριο απόφασης.

Η χρήση του πυρήνα επιτρέπει τον υπολογισμό εσωτερικών γινομένων στον χώρο χαρακτηριστικών F χωρίς να χρειάζεται να υπολογιστούν ρητά οι συντεταγμένες του μετασχηματισμού Φ . Αυτή η ιδιότητα καθιστά δυνατή την εφαρμογή του μοντέλου SVM σε υψηλοδιάστατους ή ακόμη και απειροδιάστατους χώρους.

Το μοντέλο αυτό προσπαθεί να περικλείσει τις φυσιολογικές παρατηρήσεις, θεωρώντας τις υπόλοιπες ως μη φυσιολογικές. Συγκεκριμένα, μετασχηματίζοντας τα δεδομένα στο χώρο χαρακτηριστικών F , όπου μπορεί να υπάρχει ένα υπερεπίπεδο που διαχωρίζει τις παρατηρήσεις ανάλογα με την κλάση τους, διαχωρίζονται όλα τα σημεία στον αρχικό χώρο μεγιστοποιώντας την απόσταση του υπερεπιπέδου από την αρχή. Αυτό οδηγεί σε μια δυαδική συνάρτηση που καταγράφει περιοχές στο χώρο εισόδου, αντιπροσωπεύοντας την πυκνότητα πιθανότητας των δεδομένων. Η συνάρτηση αυτή επιστρέφει $+1$ σε μια "μικρή" περιοχή που θεωρείται περιοχή μη ακραίων τιμών και -1 στον υπόλοιπο χώρο.

Η εκπαίδευση του One-Class SVM διατυπώνεται ως πρόβλημα ελαχιστοποίησης, με στόχο την εύρεση του υπερεπιπέδου που διαχωρίζει το σύνολο των κανονικών παρατηρήσεων από την υπόλοιπη περιοχή του χώρου χαρακτηριστικών. Συγκεκριμένα, η μαθηματική διατύπωση του προβλήματος είναι η εξής:

$$\min_{\mathbf{w}, \xi_i, \rho} \frac{1}{2} \|\mathbf{w}\|^2 + \frac{1}{\nu n} \sum_{i=1}^n \xi_i - \rho,$$

υπό τους περιορισμούς:

$$(\mathbf{w} \cdot \Phi(\mathbf{x}_i)) \geq \rho - \xi_i, \quad \forall i = 1, \dots, n,$$

$$\xi_i \geq 0, \quad \forall i = 1, \dots, n.$$

Σε αυτό το πλαίσιο, το $\mathbf{w}$ είναι το διάνυσμα βαρών που ορίζει τον προσανατολισμό του υπερεπιπέδου, το ρ αποτελεί την τιμή μετατόπισης (offset), ενώ τα ξ_i είναι μεταβλητές χαλάρωσης που επιτρέπουν την παρουσία αποκλίσεων από το υπερεπίπεδο. Η απεικόνιση $\Phi(\mathbf{x}_i)$ μεταφέρει τα δεδομένα σε έναν χώρο υψηλότερης διάστασης, στον οποίο καθίσταται εφικτός ο διαχωρισμός.

Η παράμετρος $\nu \in (0, 1]$ ρυθμίζει την ευαισθησία του μοντέλου, καθώς θέτει άνω φράγμα στο ποσοστό των δειγμάτων που μπορούν να θεωρηθούν ως ανωμαλίες και ταυτόχρονα κάτω φράγμα στον αριθμό των support vectors. Με αυτόν τον τρόπο, το μοντέλο ελέγχει την αυστηρότητα του διαχωρισμού και τη γενίκευση στα νέα δεδομένα.

Η επίλυση του παραπάνω προβλήματος γίνεται μέσω της τεχνικής των πολλαπλασιαστών Lagrange, που οδηγεί στη συνάρτηση απόφασης:

$$f(x) = \text{sgn}((w \cdot \Phi(\mathbf{x})) - \rho) = \text{sgn}\left(\sum_{i=1}^n \alpha_i K(\mathbf{x}, \mathbf{x}_i) - \rho\right),$$

όπου $\text{sgn}(\cdot)$ είναι η συνάρτηση προσήμου και $K(x, x_i)$ είναι η συνάρτηση πυρήνα που υπολογίζει την ομοιότητα μεταξύ των x και x_i . Οι συντελεστές α_i είναι οι παράμετροι που υπολογίζονται κατά την επίλυση του προβλήματος βελτιστοποίησης.

Η μέθοδος των Μηχανών Διανυσμάτων Υποστήριξης Μιας Κλάσης (One-Class SVM) είναι ένα ευέλικτο εργαλείο που μπορεί να χρησιμοποιηθεί για ανίχνευση ανωμαλιών σε δεδομένα. Η δυνατότητα χρήσης διαφορετικών συναρτήσεων πυρήνα καθιστά το μοντέλο ισχυρό και προσαρμοστικό σε διάφορα είδη δεδομένων.

3.2.4 Αλγόριθμος Χωρικής Ομαδοποίησης Εφαρμογών με Θόρυβο με Βάση την Πυκνότητα

Ο Αλγόριθμος Χωρικής Ομαδοποίησης Εφαρμογών με Θόρυβο με Βάση την Πυκνότητα (*Density-Based Spatial Clustering of Applications with Noise - DBSCAN*) αποτελεί μια ισχυρή μέθοδο εύρεσης ανωμαλιών η οποία βασίζεται στην ομαδοποίηση των δεδομένων βάσει της πυκνότητας. Προτάθηκε από τους Ester κ.ά. [24] το 1996.

- Στον αλγόριθμο DBSCAN η πυκνότητα γύρω από ένα σημείο $\mathbf{p}$, εκτιμάται ως ο αριθμός των σημείων του D , όπου D αποτελεί το σύνολο δεδομένων εισόδου, που βρίσκονται μέσα σε μία ορισμένη περιοχή του N -διάστατου χώρου που περικλείει το $\mathbf{p}$.
- Γίνεται η θεώρηση ότι η περιοχή αυτή είναι υπερσφαίρα $V_\epsilon(\mathbf{p})$ με κέντρο το $\mathbf{p}$ και ακτίνα ϵ , η οποία είναι παράμετρος οριζόμενη από το χρήστη. Έστω $N_\epsilon(\mathbf{p})$ ο αριθμός των σημείων του D που βρίσκονται μέσα στην $V_\epsilon(\mathbf{p})$.
- Μια δεύτερη παράμετρος που ορίζεται από το χρήστη είναι ο ελάχιστος αριθμός σημείων, k , που πρέπει να περιέχονται στην $V_\epsilon(\mathbf{p})$ προκειμένου το $\mathbf{p}$ να θεωρηθεί «εσωτερικό» σημείο μιας ομάδας.

Για την αναλυτική περιγραφή του αλγορίθμου, χρειάζεται να δοθούν οι παρακάτω ορισμοί:

1. **Άμεσα Προσβάσιμο Σημείο (Directly Density Reachable):** Ένα σημείο $\mathbf{y}$ είναι άμεσα προσβάσιμο από το $\mathbf{x}$ αν:

- $\mathbf{y} \in V_\epsilon(\mathbf{x})$, και

- $N_\varepsilon(\mathbf{x}) \geq q$.

2. **Προσβάσιμο Σημείο (Density Reachable):** Ένα σημείο y είναι προσβάσιμο από το x αν υπάρχει μια ακολουθία σημείων $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_p \in X$ με $\mathbf{x}_1 = \mathbf{x}$ και $\mathbf{x}_p = y$, έτσι ώστε κάθε $\mathbf{x}_{i+1}$ να είναι άμεσα προσβάσιμο από το $\mathbf{x}_i$.
3. **Συνδεδεμένο Σημείο (Density-Connected):** Ένα σημείο x είναι συνδεδεμένο με το y αν υπάρχει ένα σημείο $z \in X$ έτσι ώστε και τα δύο x και y να είναι προσβάσιμα από το z .

Μια ομάδα (*cluster*) C στο DBSCAN ορίζεται ως ένα μη κενό υποσύνολο του X που ικανοποιεί τις ακόλουθες συνθήκες:

- Αν $\mathbf{x} \in C$ και $\mathbf{y} \in X$ είναι προσβάσιμο από το $\mathbf{x}$, τότε $\mathbf{y} \in C$.
- Για κάθε ζεύγος $(\mathbf{x}, \mathbf{y}) \in C$, τα $\mathbf{x}$ και $\mathbf{y}$ είναι συνδεδεμένα.

Το σύνολο των σημείων που δεν ανήκουν σε καμία ομάδα ονομάζεται θόρυβος (*noise*).

Ένα σημείο $\mathbf{x}$ ονομάζεται σημείο πυρήνας (*core point*) αν έχει τουλάχιστον q σημεία στην ε -γειτονιά του, η οποία ορίζεται ως:

$$\varepsilon - \text{γειτονιά} = \{x_j | x_j \in D : \|x_i - x_j\| \leq \varepsilon, x_i \neq x_j\},$$


διαφορετικά, ονομάζεται μη βασικό σημείο (*noncore point*). Τα μη βασικά σημεία μπορεί να είναι είτε συνοριακά σημεία (*border points*) είτε ενθόρυβα σημεία (*noise points*).

Για την περαιτέρω κατανόηση ακολουθούν δύο σημαντικές προτάσεις:

- **Πρόταση 1:** Αν $\mathbf{x}$ είναι σημείο πυρήνας και D είναι το σύνολο των σημείων του X που είναι προσβάσιμα από το $\mathbf{x}$, τότε το D είναι μια ομάδα.
- **Πρόταση 2:** Αν C είναι μια ομάδα και $\mathbf{x}$ είναι ένα σημείο πυρήνας του C , τότε C ισούται με το σύνολο των σημείων που είναι προσβάσιμα από το $\mathbf{x}$.

Στο Διάγραμμα 3.2 παρατηρείται ότι το q (αναγράφεται ως "MinPts"), το οποίο αποτελεί τον ελάχιστο αριθμό σημείων ώστε το $\mathbf{x}$ να θεωρηθεί σημείο πυρήνας και η γειτονιά να θεωρηθεί πυκνή, είναι 3. Επίσης, τα σημεία εντός της ε -γειτονιάς, εκτός του πυρήνα, είναι τα συνοριακά σημεία, ενώ αυτά που δεν ανήκουν σε κάποια ομάδα είναι τα ενθόρυβα.

Συγκεκριμένα, όπως φαίνεται και στον ψευδοκώδικα του Αλγορίθμου 1 του DBSCAN, στη γραμμή 1 ο αλγόριθμος αρχικοποιεί τις μεταβλητές. Στη γραμμή 2 ξεκινάει μια επαναληπτική διαδικασία μέχρι να επεξεργαστούν όλα τα σημεία. Στην γραμμή 3 γίνεται επιλογή ενός τυχαίου σημείου



Διάγραμμα 3.2: Οπτικοποίηση του αλγορίθμου ομαδοποίησης DBSCAN. Πηγή: "DBSCAN Clustering Algorithm in Machine Learning," by Nagesh Singh Chauhan, KDnuggets, April 4, 2022.

Algorithm 1 Αλγόριθμος DBSCAN

```

1: Θέσε όλα τα σημεία ως μη επεξεργασμένα (unprocessed)  $X_{un} = X$  και μετρητή  $m = 0$ .
2: while  $X_{un} \neq \emptyset$  do
3:   Επέλεξε αυθαίρετα ένα  $x \in X_{un}$ .
4:   if  $x$  είναι μη βασικό σημείο then
5:     Σημείωσε το  $x$  ως ενθόρυβο σημείο.
6:      $X_{un} = X_{un} \setminus \{x\}$ .
7:   else
8:      $m = m + 1$ .
9:     Προσδιόρισε όλα τα σημεία του  $X$  που είναι προσβάσιμα από το  $x$ .
10:    Καταχώρησε το  $x$  και τα προσβάσιμα σημεία στην ομάδα  $C_m$ .
11:     $X_{un} = X_{un} \setminus C_m$ .
12:   end if
13: end while

```

το οποίο ελέγχεται αν είναι βασικό ή όχι. Στην περίπτωση που είναι μη βασικό, σημειώνεται ως θορυβώδης, ενώ αν είναι βασικό, τότε δημιουργείται μια νέα ομάδα όπου προσδιορίζονται τα προσβάσιμα σημεία από αυτό και καταχωρούνται στη νέα ομάδα, ενώ, παράλληλα, αφαιρούνται από τα μη επεξεργασμένα σημεία.

3.2.5 Αλγόριθμος Extreme Gradient Boosting (XGBoost)

Τα μοντέλα βαθιάς μάθησης έχουν επιδείξει εντυπωσιακές επιδόσεις σε τομείς όπως η υπολογιστική όραση και η επεξεργασία φυσικής γλώσσας. Ωστόσο, σε προβλήματα που αφορούν δομημένα δεδομένα σε μορφή πίνακα, αρκετά τέτοιου είδους μοντέλα δεν φτάνουν τις επιδόσεις απλούστερων και λιγότερο υπολογιστικά απαιτητικών μοντέλων, ιδίως όταν λαμβάνεται υπόψη το κόστος και ο όγκος των δεδομένων [66]. Αντίθετα, η τεχνική της Ενισχυτικής Κλίσης (*Gradient Boosting*) επιτυγχάνει ανώτερες επιδόσεις, ιδιαίτερα σε προβλήματα ταξινόμησης με μη ισορροπημένα δεδομένα, με χαμηλό κόστος εκπαίδευσης και καλή ερμηνευσιμότητα.

Η Ενισχυτική Κλίση [50] συνδυάζει απλά μοντέλα βάσης (*Weak Learners*) σε έναν ταξινομητή συνόλου (*Ensemble Classifier*), όπου κάθε μοντέλο επηρεάζεται από τα σφάλματα των προηγούμενων. Αυτή η διαδικασία διαφέρει από τον αλγόριθμο Bootstrap Aggregating (Bagging), όπου τα μοντέλα

εκπαιδεύονται παράλληλα. Η εκπαίδευση ενός μοντέλου Boosting περιλαμβάνει τα εξής βήματα:

1. Τα δεδομένα εκπαίδευσης χρησιμοποιούνται για την εκπαίδευση ενός μοντέλου βάσης, με ίσα βάρη για όλες τις παρατηρήσεις.
2. Το βάρος κάθε παρατήρησης προσαρμόζεται ανάλογα με το σφάλμα πρόβλεψης. Παρατηρήσεις με μεγάλο σφάλμα λαμβάνουν μεγαλύτερα βάρη για να βελτιωθούν στην επόμενη φάση.
3. Ένα βάρος ανατίθεται στο μοντέλο βάσης ανάλογα με την απόδοσή του.
4. Η διαδικασία επαναλαμβάνεται για έναν προκαθορισμένο αριθμό επαναλήψεων ή μέχρι να επιτευχθεί ένα κατώφλι σφάλματος.

Ο αλγόριθμος Gradient Boosting διαφέρει από τον κλασσικό αλγόριθμο Boosting, καθώς δεν χρησιμοποιεί βάρη στα δεδομένα, αλλά τα σφάλματα (*residuals*) από τις προβλέψεις των προηγούμενων μοντέλων. Επιπλέον, βελτιστοποιεί μια συνάρτηση απώλειας L με σταθερό ρυθμό μάθησης (*constant learning rate*). Ο στόχος είναι η εύρεση μιας συνάρτησης $\hat{F}(\mathbf{X})$ που εκτιμά την τιμή της εξόδου Y από τις μεταβλητές εισόδου $\mathbf{X}$, μέσω της ελαχιστοποίησης της αναμενόμενης απώλειας:

$$\hat{F} = \arg \min_F \mathbb{E}_{\mathbf{X}, Y} [L(Y, F(\mathbf{X}))].$$

Η συνάρτηση $\hat{F}(\mathbf{X})$ προσεγγίζεται ως ένα σταθμισμένο άθροισμα από K συναρτήσεις $h_k(\mathbf{X}) \in \mathcal{H}$, όπου $\mathcal{H}$ είναι μια κλάση συναρτήσεων που αντιστοιχούν στα μοντέλα βάσης:

$$\hat{F}(\mathbf{X}) = \sum_{k=1}^K \gamma_k h_k(\mathbf{X}) + \text{const.}$$

Η εκτίμηση της $\hat{F}(\mathbf{X})$ γίνεται με μια ακολουθιακή διαδικασία, ξεκινώντας από ένα σταθερό μοντέλο $F_0(\mathbf{X})$ και προσθέτοντας σταδιακά πιο σύνθετα μοντέλα:

$$F_0(\mathbf{X}) = \arg \min_{\gamma} \sum_{i=1}^n L(Y_i, \gamma),$$

$$F_k(\mathbf{X}) = F_{k-1}(\mathbf{X}) + \arg \min_{h_k \in \mathcal{H}} \left[\sum_{i=1}^n L(Y_i, F_{k-1}(\mathbf{X}_i) + h_k(\mathbf{X}_i)) \right].$$

Για την εύρεση της βέλτιστης συνάρτησης h_k , χρησιμοποιείται η μέθοδος της καθόδου κλίσης (gradient descent), όπου:

$$F_k(\mathbf{X}) = F_{k-1}(\mathbf{X}) - \gamma_k \sum_{i=1}^n \nabla_{F_{k-1}} L(Y_i, F_{k-1}(\mathbf{X}_i)),$$

με $\gamma > 0$ να είναι ο ρυθμός μάθησης και βελτιστοποιείται σε κάθε βήμα:

$$\gamma_k = \arg \min_{\gamma} \sum_{i=1}^n L(Y_i, F_{k-1}(\mathbf{X}_i) - \gamma \nabla_{F_{k-1}} L(Y_i, F_{k-1}(\mathbf{X}_i))).$$

Ο γενικός αλγόριθμος Gradient Boosting, ο οποίος εφαρμόζεται σε ένα σύνολο δεδομένων εκπαίδευσης $\{(\mathbf{X}_i, Y_i)\}_{i=1}^n$ με βάση μια διαφορίσιμη συνάρτηση απώλειας $L(Y, F(\mathbf{X}))$, περιγράφεται συνοπτικά στον Αλγόριθμο 2 μέσω ψευδοκώδικα.

Συνήθως, ως μοντέλα βάσης χρησιμοποιούνται απλά δέντρα απόφασης (CART) με λίγα φύλλα και μικρό βάθος. Δημοφιλή μοντέλα Gradient Boosting περιλαμβάνουν τις Μηχανές Ενισχυτικής Κλίσης (GBM) [28], τα XGBoost [17], LightGBM [41] και CatBoost [54], τα οποία προσφέρουν παράλληλη επεξεργασία δεδομένων, κανονικοποίηση και κλάδεμα (*pruning*) για την αποφυγή υπερπροσαρμογής.

Algorithm 2 Γενικός Αλγόριθμος Gradient Boosting

- 1: Αρχικοποίηση: $F_0(\mathbf{X}) = \arg \min_{\gamma} \sum_{i=1}^n L(Y_i, \gamma)$
 - 2: **for** $k = 1$ έως K **do**
 - 3: Υπολόγισε τα ψευδο-κατάλοιπα: $r_{ik} = -\frac{\partial L(Y_i, F(\mathbf{X}_i))}{\partial F(\mathbf{X}_i)} \Big|_{F(\mathbf{X})=F_{k-1}(\mathbf{X})}$ για $i = 1, \dots, n$
 - 4: Εκπαίδευσε ένα μοντέλο βάσης χρησιμοποιώντας τα $\{(\mathbf{X}_i, r_{ik})\}_{i=1}^n$
 - 5: Υπολόγισε το γ_k : $\gamma_k = \arg \min_{\gamma} \sum_{i=1}^n L(Y_i, F_{k-1}(\mathbf{X}_i) + \gamma h_k(\mathbf{X}_i))$
 - 6: Ανανέωσε το μοντέλο: $F_k(\mathbf{X}) = F_{k-1}(\mathbf{X}) + \gamma_k h_k(\mathbf{X})$
 - 7: **end for**
 - 8: Επέστρεψε την $F_K(\mathbf{X})$
-

Για λόγους απλότητας και συντομίας θα γίνει αναφορά μόνο στον αλγόριθμο Extreme Gradient Boosting (XGBoost) που αποτελεί μία τεχνική μηχανικής μάθησης που έχει αποδώσει εξαιρετικά στους διαγωνισμούς Kaggle και KDDCup. Ένα από τα βασικά πλεονεκτήματα του XGBoost είναι η επεκτασιμότητά του [17] συγκριτικά με τους απλούς αλγόριθμους ενισχυτικής κλίσης. Το XGBoost βασίζεται στον αλγόριθμο Tree Boosting, ο οποίος χρησιμοποιεί τη μέθοδο δεύτερης τάξης Πολυωνύμου Taylor (κοινώς εισάγει και τη δεύτερη παράγωγο), όπως αναφέρθηκε από τους Friedman κ.ά. [27].

Ας θεωρήσουμε ότι το D είναι ένα σύνολο n δεδομένων διάστασης $m + 1$:

$$D = \{(\mathbf{X}_i, Y_i) \mid \mathbf{X}_i \in \mathbb{R}^m, Y_i \in \mathbb{R}\}_{i=1}^n.$$

Ο αλγόριθμος Tree Boosting χρησιμοποιεί μία διαδοχική ακολουθία μοντέλων δέντρου για να προβλέψει τα Y_i για κάθε $\mathbf{X}_i$:

$$\hat{Y}_i = \phi(\mathbf{X}_i) = \sum_{k=1}^K f_k(\mathbf{X}_i), \text{ όπου } f_k \in F,$$

όπου F είναι ο χώρος των δέντρων παλινδρόμησης. Η αντίστοιχη συνάρτηση απώλειας είναι:

$$L(\phi) = \sum_i l(Y_i, \hat{Y}_i) + \sum_k \Omega(f_k),$$

όπου

$$\Omega(f) = T + \frac{1}{2} \lambda \|\mathbf{w}\|^2,$$

με T να είναι ο αριθμός των φύλλων σε κάθε δέντρο και $\mathbf{w}$ τα βάρη των φύλλων.

Η συνάρτηση απώλειας περιέχει συναρτήσεις που δεν μπορούν να βελτιστοποιηθούν με παραδοσιακές μεθόδους βελτιστοποίησης στον Ευκλείδειο χώρο. Για να ξεπεραστεί αυτό το εμπόδιο, το μοντέλο εκπαιδεύεται προσθετικά και χρησιμοποιείται η προσεγγιστική μέθοδος Taylor της συνάρτησης απώλειας, ώστε να γίνει βελτιστοποιήσιμη στον Ευκλείδειο χώρο:

$$L^{(t)} \approx \sum_i \left[l(Y_i, \hat{Y}_i^{(t-1)}) + g_i f_t(\mathbf{X}_i) + \frac{1}{2} h_i f_t^2(\mathbf{X}_i) \right] + \Omega(f_t),$$

όπου

$$g_i = \frac{\partial l(Y_i, \hat{Y}_i^{(t-1)})}{\partial \hat{Y}_i^{(t-1)}}, \quad h_i = \frac{\partial^2 l(Y_i, \hat{Y}_i^{(t-1)})}{\partial \hat{Y}_i^{(t-1)^2}}.$$

Περισσότερες λεπτομέρειες για το XGBoost παρέχονται από τους Tianqi Chen κ.ά. στο κύριο άρθρο τους [17].

3.2.6 Αλγόριθμος Προφίλ Πίνακα

Ο αλγόριθμος Προφίλ Πίνακα (*Matrix Profile - MP*) είναι μια δομή δεδομένων που αναπτύχθηκε το 2016 από τους Eaemon Keogh και Abdullah Mueen [82]. Ο MP είναι ένας καινοτόμος, γρήγορος και ακριβής αλγόριθμος για την εύρεση ομοιοτήτων σε χρονοσειρές, παρέχοντας ταυτόχρονα λύσεις σε βασικά προβλήματα όπως ο εντοπισμός μοτίβων (*motif discovery*), η ανίχνευση ανωμαλιών (*anomaly detection*), η ανίχνευση αλλαγών (*change point detection*) και η σύγκριση χρονοσειρών (*time series comparison*). Το κύριο χαρακτηριστικό του είναι ότι απαιτεί ελάχιστη παραμετροποίηση και πολύ μικρό πλήθος ιστορικών δεδομένων, με ελάχιστη παρέμβαση από τον χρήστη.

Για την ορθή κατανόηση του αλγορίθμου δίνονται οι παρακάτω ορισμοί:

Ορισμός 1: Μια χρονοσειρά T είναι μια ακολουθία πραγματικών αριθμών t_i :

$$T = t_1, t_2, \dots, t_n,$$

όπου n είναι το μήκος της T . Σημασία έχουν όχι οι καθολικές, αλλά οι τοπικές ιδιότητες της χρονοσειράς. Μια τοπική περιοχή της χρονοσειράς ονομάζεται υποακολουθία.

Ορισμός 2: Μια υποακολουθία $T_{i,m}$ μιας χρονοσειράς T είναι ένα συνεχές υποσύνολο τιμών

από την T με μήκος m που ξεκινά από τη θέση i . Τυπικά:

$$T_{i,m} = t_i, t_{i+1}, \dots, t_{i+m-1},$$

όπου $1 \leq i \leq n - m + 1$.

Μια υποακολουθία μπορεί να συγκριθεί ως προς την απόστασή της με όλες τις υπόλοιπες υποακολουθίες της ίδιας χρονοσειράς, υπολογίζοντας το βαθμό ομοιότητας ή απόκλισης μεταξύ τους. Αυτό ονομάζεται προφίλ απόστασης:

Ορισμός 3: Το Προφίλ Απόστασης (*distance profile*) D_i μιας χρονοσειράς T είναι ένα διάνυσμα των Ευκλείδειων αποστάσεων μεταξύ μιας δεδομένης υποακολουθίας ερωτήματος $T_{i,m}$ και κάθε υποακολουθίας της χρονοσειράς T . Τυπικά:

$$D_i = [d_{i,1}, d_{i,2}, \dots, d_{i,n-m+1}],$$

όπου $d_{i,j}$ (με $1 \leq i, j \leq n - m + 1$) είναι η απόσταση μεταξύ των $T_{i,m}$ και $T_{j,m}$. Γίνεται η υπόθεση ότι η απόσταση μετράται ως η Ευκλείδεια απόσταση μεταξύ κανονικοποιημένων υποακολουθιών (z-normalized subsequences) [75].

Ορισμός 4: Το Προφίλ Πίνακα (*Matrix Profile*) P μιας χρονοσειράς T είναι ένα διάνυσμα των Ευκλείδειων αποστάσεων μεταξύ κάθε υποακολουθίας $T_{i,m}$ και του πλησιέστερου γείτονά της (closest match) στην χρονοσειρά T . Τυπικά:

$$P = [\min(D_1), \min(D_2), \dots, \min(D_{n-m+1})],$$

όπου D_i (με $1 \leq i \leq n - m + 1$) είναι το προφίλ απόστασης D_i της χρονοσειράς T .

Στο Διάγραμμα 3.3 παρατηρείται η σχέση του προφίλ πίνακα με το προφίλ απόστασης:

	D_1	D_2	...	D_{n-m+1}
D_1	$d_{1,1}$	$d_{1,2}$	...	$d_{1,n-m+1}$
D_2	$d_{2,1}$	$d_{2,2}$	...	$d_{2,n-m+1}$
...	...	...	...	...
D_{n-m+1}	$d_{n-m+1,1}$	$d_{n-m+1,2}$	...	$d_{n-m+1,n-m+1}$
	↓	↓	↓	↓
P	$\min(D_1)$	$\min(D_2)$	...	$\min(D_{n-m+1})$

Διάγραμμα 3.3: Μια αναπαράσταση της σχέσης του προφίλ πίνακα με ολόκληρο τον πίνακα προφίλ απόστασης. Πηγή: [85]

Ορισμός 5: Ο Δείκτης Προφίλ Πίνακα (*Matrix Profile Index*) I μιας χρονοσειράς T είναι ένα διάνυσμα ακεραίων:

$$I = [I_1, I_2, \dots, I_{n-m+1}],$$


όπου $I_i = j$ αν $d_{i,j} = \min(D_i)$.

Ο πίνακας απόστασης γίνεται να υπολογιστεί με διαφορετικούς τρόπους.

Πρώτος τρόπος είναι ο Αλγόριθμος Ωμής Βίας (*Brute force Algorithm*), ο οποίος, για κάθε υποακολουθία $T_{i,m}$ (όπου i είναι η θέση της αρχής της υποακολουθίας), την συγκρίνει με όλες τις άλλες υποακολουθίες $T_{j,m}$ (όπου $j \neq i$). Για μια χρονοσειρά μήκους n και υποακολουθίες μήκους m , υπάρχουν $n - m + 1$ υποακολουθίες. Αυτό σημαίνει ότι για κάθε μια από αυτές, γίνονται $n - m + 1$ συγκρίσεις. Έτσι, για κάθε σύγκριση, υπολογίζεται η Ευκλείδεια απόσταση μεταξύ των δύο υποακολουθιών. Ο υπολογισμός αυτός απαιτεί m πράξεις (ένα για κάθε σημείο της υποακολουθίας), οπότε, η χρονική πολυπλοκότητα του αλγορίθμου για τις μέσες και χειρότερες περιπτώσεις είναι $O(n^2m)$, με $n - m + 1$, για μεγάλα n .

Ο παραπάνω αλγόριθμος βελτιώνεται μέσω του αλγορίθμου STAMP (*Scalable Time-series Anytime Matrix Profile*) ο οποίος χρησιμοποιεί τον Γρήγορο Μετασχηματισμό Φουριέ (FFT) για να επιταχύνει τους υπολογισμούς. Αντί να υπολογίζει τις αποστάσεις μία-μία, ο STAMP εκμεταλλεύεται τον FFT για να κάνει τους υπολογισμούς πιο γρήγορους. Ο FFT έχει χρονική πολυπλοκότητα $O(n \log n)$, οπότε η συνολική χρονική πολυπλοκότητα του STAMP είναι $O(n^2 \log n)$.

Ο STAMP μπορεί να βελτιωθεί ακόμα περαιτέρω. Ο STAMP υπολογίζει τα προφίλ απόστασης για τις γραμμές σε τυχαία σειρά. Κάθε προφίλ απόστασης υπολογίζεται ανεξάρτητα. Ωστόσο, οι διαδοχικές γραμμές αντιστοιχούν σε προφίλ δύο υποακολουθιών που επικαλύπτονται σε $m - 1$ παρατηρήσεις. Έτσι, προκύπτει ο ακόμα πιο βελτιωμένος αλγόριθμος, STOMP (*Scalable Time-series Ordered Matrix Profile*) [85], που προτείνεται από τους ίδιους συγγραφείς. Συγκεκριμένα, για κάθε επόμενη υποακολουθία $T_{i,m}$ εκμεταλλεύεται τα αποτελέσματα από την προηγούμενη υποακολουθία $T_{i-1,m}$ για να υπολογίσει γρήγορα τις αποστάσεις. Έτσι, η χρονική πολυπλοκότητα, βελτιώνεται από $O(n^2 \log n)$ σε $O(n^2)$.



Διάγραμμα 3.4: Παρουσίαση δύο χρονοσειρών (με κόκκινο χρώμα) και του αντίστοιχου προφίλ πίνακα τους (με μπλε χρώμα). Πηγή: [42]


Παρατηρείται στο Διάγραμμα 3.4 ότι για το προφίλ πίνακα υπάρχουν σχετικά χαμηλές τιμές. Τότε, η υποακολουθία στην αρχική χρονοσειρά πρέπει να έχει (τουλάχιστον μία) σχετικά παρόμοια υποακολουθία κάπου αλλού στα δεδομένα (τέτοιες περιοχές ονομάζονται μοτίβα (*motifs*)). Στο ίδιο διάγραμμα, όταν το προφίλ πίνακα της χρονοσειράς έχει υψηλή τιμή, η υποακολουθία στην αρχική

χρονοσειρά πρέπει να είναι μοναδική στο σχήμα της (τέτοιες περιοχές χαρακτηρίζονται ως ανωμαλίες (*discords*)).

3.3 Αλγόριθμοι Βαθιάς Μάθησης

3.3.1 Πολυστρωματικό Perceptron

Στη βαθιά μάθηση, ο όρος Πολυστρωματικό Perceptron (*Multi-layer Perceptron - MLP*) αναφέρεται σε ένα σύγχρονο νευρωνικό δίκτυο εμπρόσθιας τροφοδοσίας (*feedforward*), το οποίο περιλαμβάνει νευρώνες πλήρως διασυνδεδεμένους μεταξύ τους και χρησιμοποιεί μη γραμμικές συναρτήσεις ενεργοποίησης. Η δομή του δικτύου βασίζεται σε πολλαπλά επίπεδα και η ιδιαιτερότητά του έγκειται στην ικανότητά του να διαχωρίζει δεδομένα που δεν μπορούν να διαχωριστούν γραμμικά, κάτι που το καθιστά ιδανικό για την αντιμετώπιση πολύπλοκων και μη γραμμικών προβλημάτων.



Διάγραμμα 3.5: Η αρχιτεκτονική ενός Πολυστρωματικού Perceptron με ένα στρώμα εισόδου με τρεις νευρώνες, τρία κρυφά επίπεδα με τέσσερις νευρώνες το κάθε ένα και ένα στρώμα εξόδου με έναν νευρώνα. Πηγή: "A Simple overview of Multilayer Perceptron(MLP)" by franckepeixoto, Analytics Vidhya, 14 Dec, 2023.

Ένα MLP αποτελείται από τρία βασικά επίπεδα, όπως φαίνεται και στο Διάγραμμα 3.5. Το πρώτο είναι το στρώμα εισόδου (*Input Layer*), το οποίο δέχεται τα δεδομένα εισόδου και κάθε νευρώνας αντιστοιχεί σε μια χαρακτηριστική τιμή των δεδομένων. Το δεύτερο είναι τα κρυφά στρώματα (*Hidden Layers*), που είναι τα ενδιάμεσα επίπεδα μεταξύ της εισόδου και της εξόδου. Κάθε κρυφό επίπεδο αποτελείται από νευρώνες που εφαρμόζουν γραμμικούς και μη γραμμικούς μετασχηματισμούς στα δεδομένα. Τέλος, το στρώμα εξόδου (*Output Layer*), παράγει τα τελικά αποτελέσματα του δικτύου, όπως προβλέψεις ή ταξινομήσεις.

Κάθε νευρώνας σε ένα MLP εκτελεί δύο βασικές λειτουργίες:

- **Γραμμικός Μετασχηματισμός:** Υπολογίζει ένα σταθμισμένο άθροισμα των εισόδων του:

$$z = \sum_{i=1}^n w_i x_i + b,$$

όπου w_i είναι τα βάρη, x_i οι εισοδοί και b η πόλωση (bias). Η παράμετρος b δεν σχετίζεται με

στατιστική προκατάληψη, αλλά με τη μετατόπιση του υπολογισμού του νευρώνα, επιτρέποντας στο δίκτυο να προσαρμόζει καλύτερα τα δεδομένα.

- **Συνάρτηση Ενεργοποίησης:** Εφαρμόζει μια μη γραμμική συνάρτηση στο αποτέλεσμα του γραμμικού μετασχηματισμού:

$$a = f(z),$$

με τις πιο συνηθισμένες συναρτήσεις ενεργοποίησης να είναι:

- **ReLU (Rectified Linear Unit):** $f(z) = \max(0, z)$
- **Sigmoid:** $f(z) = \frac{1}{1+e^{-z}}$
- **Tanh:** $f(z) = \tanh(z)$

Η εκπαίδευση ενός MLP γίνεται με τον αλγόριθμο της Οπισθοδιάδοσης (*Backpropagation*), ο οποίος ακολουθεί έναν αλγόριθμο βελτιστοποίησης βασισμένο στην κλίση (*gradient descent*) που εκμεταλλεύεται τον κανόνα της αλυσίδας. Ο αλγόριθμος αυτός καθιερώθηκε για την εκπαίδευση πολυστρωματικών νευρωνικών δικτύων με την εφαρμογή και τη δημοφιλία του να οφείλονται στην εργασία των Rumelhart, Hinton και Williams το 1986 [57], οι οποίοι ανέδειξαν τη σημασία του στην επίλυση πολύπλοκων προβλημάτων. Η διαδικασία περιλαμβάνει τα εξής βήματα:

1. **Προώθηση (Forward Pass):** Τα δεδομένα εισόδου περνούν από το δίκτυο και υπολογίζονται οι έξοδοι.
2. **Υπολογισμός Σφάλματος:** Το σφάλμα μεταξύ των προβλεπόμενων και των πραγματικών τιμών υπολογίζεται χρησιμοποιώντας μια συνάρτηση κόστους.
3. **Αντίστροφη Διάδοση (Backward Pass):** Το σφάλμα διαδίδεται προς τα πίσω στο δίκτυο, και υπολογίζονται οι κλίσεις (gradients) των βαρών ως προς τη συνάρτηση κόστους.
4. **Ενημέρωση Βαρών:** Τα βάρη ενημερώνονται χρησιμοποιώντας τον κανόνα:

$$w_i = w_i - \eta \frac{\partial L}{\partial w_i},$$


όπου η είναι ο ρυθμός μάθησης (learning rate) και L η συνάρτηση κόστους.

3.3.2 Δίκτυα Μακράς Βραχύχρονης Μνήμης

Τα Δίκτυα Μακράς Βραχύχρονης Μνήμης (*Long Short-Term Memory Networks - (LSTMs)*), τα οποία προτάθηκαν από τους Hochreiter και Schmidhuber το 1997 [35], είναι ένα ακόμα είδος τεχνητού νευρωνικού δικτύου, τα οποία είναι σχεδιασμένα για σειριακά δεδομένα και αποτελούν μια βελτίωση των παραδοσιακών αναδρομικών νευρωνικών δικτύων (*Recurrent Neural Networks - (RNNs)*), ώστε να μπορούν να αντιμετωπίσουν τα κύρια μειονεκτήματά τους, όπως το πρόβλημα της εξαφάνισης

ή της εκρήξεως της κλίσης (*vanishing/exploding gradient*). Αυτό το πρόβλημα εμφανίζεται όταν τα RNN εκπαιδεύονται σε μεγάλες ακολουθίες δεδομένων, καθώς η κλίση κατά την αντίστροφη διάδοση του σφάλματος (backpropagation) γίνεται εξαιρετικά μικρή ή μεγάλη, καθιστώντας δύσκολη την ενημέρωση των βαρών στα πρώτα επίπεδα του δικτύου, λόγω της απλής δομής τους. Το συγκεκριμένο πρόβλημα αναλύεται περαιτέρω στην διπλωματική εργασία του Hochreiter [34] το 1991 και από τους Bengio κ.ά. το 1994 [7].

Η κύρια διαφορά των LSTM, από τα παραδοσιακά RNNs, έγκειται στη δομή τους, η οποία περιλαμβάνει κύτταρα μνήμης (*memory cells*) και πύλες (*gates*) που ρυθμίζουν τη ροή της πληροφορίας. Αυτές οι πύλες (forget gate, input gate, output gate) επιτρέπουν στα LSTM να διατηρούν πληροφορίες για μεγάλα χρονικά διαστήματα και να επιλέγουν ποια πληροφορία θα διατηρήσουν ή θα απορρίψουν. Αυτή η ικανότητα κάνει τα LSTM ιδανικά για εφαρμογές που απαιτούν μακροπρόθεσμη εξάρτηση, όπως η επεξεργασία φυσικής γλώσσας (NLP), η πρόβλεψη χρονοσειρών και η αναγνώριση ομιλίας.



Διάγραμμα 3.6: Απεικόνιση της αρχιτεκτονικής ενός απλού LSTM. Πηγή: [19]

Το κλειδί για τη λειτουργία του LSTM, όπως φαίνεται και από το Διάγραμμα 3.6 είναι η κατάσταση του κελιού μνήμης, C_t . Η κατάσταση αυτού το κελιού είναι σαν μια ζώνη που διατρέχει την αλυσίδα. Η γραμμή αυτή επεκτείνεται στην αλυσίδα με μικρές γραμμικές αλλαγές στο περιεχόμενο της. Το LSTM έχει την δυνατότητα να αφαιρεί ή να προσθέτει πληροφορία στο κύτταρο κατάστασης, με την χρήση δομών που λέγονται πύλες (*gates*) που χρησιμοποιούν σιγμοειδείς συναρτήσεις ενεργοποίησης με τιμές στο εύρος $[0,1]$. Όσο προσεγγίζεται το 1, τόσο πιο πολύ σημασία δίνεται στην προηγούμενη πληροφορία, ενώ όσο προσεγγίζεται το 0, τόσο πιο πολύ αγνοείται.

Η πρώτη πύλη είναι η πύλη επιλεκτικής συγκράτησης (*forget gate*), f_t . Πρόκειται για σιγμοειδές επίπεδο όπως φαίνεται στο Διάγραμμα 3.6, που αποφασίζει εάν η τιμή εξόδου h_{t-1} της προηγούμενης κατάστασης θα κρατηθεί ή όχι. Εκφράζεται από την εξίσωση:

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f),$$

στην οποία οι αγκύλες "[,]" εκφράζουν την συνένωση διανυσμάτων, το W αποτελεί τον πίνακα βαρών και το b αποτελεί το διάνυσμα της μεροληψίας.

Στο επόμενο βήμα παίρνεται η απόφαση σχετικά με το ποια νέα πληροφορία πρόκειται να καταγραφεί στο κελί μνήμης. Αυτό υλοποιείται μέσω της πύλης εισόδου (*Input Gate*), i_t , μέσω ενός σιγμοειδούς επιπέδου, που αποφασίζει ποιες τιμές θα ενημερωθούν και ενός επιπέδου με τη συνάρτηση ενεργοποίησης $\tanh$ που παράγει υποψήφιες τιμές, $\tilde{C}_t$, που θα μπορούσαν να εισαχθούν στην κατάσταση. Ο συνδυασμός τους πρόκειται να ενημερώσει την κατάσταση του κελιού μνήμης.

$$i_t = \sigma(W_i[h_{t-1}, x_t] + b_i),$$

$$\tilde{C}_t = \tanh(W_C[h_{t-1}, x_t] + b_C).$$

Στο σημείο αυτό γίνεται ενημέρωση της προηγούμενης κατάστασης κελιού μνήμης, C_{t-1} , στην νέα κατάσταση C_t . Πολλαπλασιάζεται η προηγούμενη κατάσταση με την τιμή που προέκυψε από την πύλη επιλεκτικής συγκράτησης και μετά προστίθεται το $i_t \circ \tilde{C}_t$, με το σύμβολο $\circ$ να εκφράζει τον στοιχειώδη πολλαπλασιασμό (Hadamard Product) μεταξύ των πινάκων. Έτσι, προκύπτει η καινούρια κατάσταση κελιού μνήμης C_t :

$$C_t = f_t \circ C_{t-1} + i_t \circ \tilde{C}_t.$$

Τελικά το αποτέλεσμα της πύλης εξόδου (*Output Gate*), h_t , όπως φαίνεται στο σχήμα, βασίζεται στην κατάσταση του κελιού όπως προκύπτει από ένα σιγμοειδές επίπεδο, o_t και από την εφαρμογή εφαπτομενικής εξίσωσης ($\tanh$) στην τιμή της προηγούμενης κατάστασης του κελιού μνήμης, ώστε να είναι οι τιμές στο εύρος $[-1, 1]$. Έτσι, προκύπτει η τιμή εξόδου:

$$h_t = o_t \circ \tanh(C_t),$$

με $o_t = \sigma(W_o[h_{t-1}, x_t] + b_o)$.


3.3.3 Αυτοκωδικοποιητής

Ένας Αυτοκωδικοποιητής (*Autoencoder - AE*) είναι ένας τύπος νευρωνικού δικτύου που συμπιέζει τα δεδομένα εισόδου στα βασικά τους χαρακτηριστικά και τα ανακατασκευάζει από τη συμπιεσμένη αναπαράσταση. Χρησιμοποιείται κυρίως ως εργαλείο μη εποπτευόμενης μάθησης για προβλήματα αποθορυβοποίησης εικόνων, μείωσης διαστατικότητας και εύρεσης ανωμαλιών.

Οι πρώιμες εκδοχές των αυτοκωδικοποιητών αναπτύχθηκαν ως εργαλείο για προ-εκπαίδευση σε πλαίσια μη εποπτευόμενης μάθησης, με σκοπό την εξαγωγή χρήσιμων χαρακτηριστικών από τα

δεδομένα πριν από την εφαρμογή τεχνικών επιβλεπόμενης μάθησης από τον Ballard το 1986 [6] και για την αντιμετώπιση της οπισθοδιάδοσης χωρίς επίβλεψη [57]. Η πρώτη επίσημη ιδέα αυτοκωδικοποιητή δόθηκε από τον Kramer το 1991 [43] και έγινε δημοφιλής μετά την εργασία των Hinton και Zemel το 1993 [33].

Ένας Αυτοκωδικοποιητής, όπως φαίνεται και από το Διάγραμμα 3.7, αποτελείται από τα στρώματα κωδικοποίησης (*encoding layers*), τα οποία συμπιέζουν τα δεδομένα εισόδου, το σημείο συμπίεσης (*bottleneck ή code*), που εκφράζει τα συμπιεσμένα δεδομένα εισόδου, και τα στρώματα αποκωδικοποίησης (*decoding layers*), τα οποία ανακατασκευάζουν τα δεδομένα. Τα στρώματα κωδικοποίησης αποτελούν τον κωδικοποιητή (*encoder*) και τα στρώματα αποκωδικοποίησης, τον αποκωδικοποιητή (*decoder*).



Διάγραμμα 3.7: Απεικόνιση της αρχιτεκτονικής ενός αυτοκωδικοποιητή με 2 στρώματα ενσωμάτωσης και 2 στρώματα αποκωδικοποίησης. Πηγή: "Applied Deep Learning - Part 3: Autoencoders" by Arden Dertat, Medium, October 3, 2017.

Έστω $\mathbf{x}$ το σύνολο δεδομένων, f η συνάρτηση για τον κωδικοποιητή και g η συνάρτηση για τον αποκωδικοποιητή. Τότε, τα δεδομένα εξόδου είναι της μορφής:

$$\hat{\mathbf{x}} = g(f(\mathbf{x})),$$

με τον αποκωδικοποιητή να ανακατασκευάζει το $\hat{\mathbf{x}}$, από τα δεδομένα εισόδου $\mathbf{x}$.

Συνήθως, οι συναρτήσεις του κωδικοποιητή και του αποκωδικοποιητή ορίζονται ως πολυστρωματικά perceptrons (MLPs). Ως παράδειγμα, ένας MLP κωδικοποιητής είναι μια συνάρτηση της μορφής

$$f_{\mathbf{W},\mathbf{b}}(\mathbf{x}) = \sigma(\mathbf{W}\mathbf{x} + \mathbf{b}),$$

όπου το σ αποτελεί τη συνάρτηση ενεργοποίησης (π.χ. $\tanh, \text{ReLU}, \text{SELU}$ κ.λπ), το $\mathbf{W}$ τον πίνακα βαρών και το $\mathbf{b}$ είναι το διάνυσμα της μεροληψίας.

Για την προσαρμογή των υπερπαραμέτρων, δηλαδή των βαρών και του διανύσματος της μερο-

ληψίας, χρειάζεται η ελαχιστοποίηση μιας συνάρτησης κόστους (π.χ. MSE, MAE) η οποία "τιμωρεί" το $\hat{\mathbf{x}}$ όσο είναι διαφορετικό από το $\mathbf{x}$ και έχει τη μορφή

$$loss = \min_{\theta_f, \theta_g} \|\mathbf{x} - \hat{\mathbf{x}}\| = \min_{\theta_f, \theta_g} \|\mathbf{x} - g(f(\mathbf{x}))\|,$$

με τα θ_f, θ_g να αποτελούν τα βάρη του κωδικοποιητή και του αποκωδικοποιητή αντίστοιχα.

Κεφάλαιο 4

Μεθοδολογία και Υλοποίηση

Στο συγκεκριμένο κεφάλαιο παρουσιάζεται μια ολοκληρωμένη περιγραφή της διαδικασίας που ακολουθήθηκε για την υλοποίηση της έρευνας. Το κεφάλαιο ξεκινά με την περιγραφή των συνόλων πραγματικών δεδομένων (4.1) Yahoo A1 και της χρονοσειράς New York City Taxi από το Numenta Anomaly Benchmark (NAB) και μετά γίνεται αναφορά στη δομή τους και σε τυχόν προκλήσεις που παρουσιάζονται. Στη συνέχεια, η προεπεξεργασία των δεδομένων (4.2) καλύπτει τα βήματα που εφαρμόστηκαν για να γίνουν τα δεδομένα κατάλληλα για ανάλυση, όπως η οργάνωση των χρονοσειρών σε ομάδες βάσει των ανωμαλιών κάθε χρονοσειράς, κανονικοποίηση και τυποποίηση των δεδομένων, για να βελτιωθούν οι επιδόσεις των αλγορίθμων, εύρεση κυρίαρχης εποχικότητας, μέσω του περιοδογράμματος, αποτασιοποίηση των χρονοσειρών, με στόχο τη σύγκριση των αλγορίθμων τόσο στα αρχικά δεδομένα όσο και στα αποτασιοποιημένα, ώστε να αξιολογηθεί η επίδραση της στην ανίχνευση ανωμαλιών και δημιουργία χρονικών χαρακτηριστικών τα οποία χρησιμοποιήθηκαν ως είσοδοι για τους αλγορίθμους μηχανικής μάθησης.

Η ενότητα υλοποίησης των αλγορίθμων (4.3) επικεντρώνεται στην εφαρμογή των μοντέλων ή αλγορίθμων, συμπεριλαμβανομένης της επιλογής υπερπαραμέτρων, της διαδικασίας εκπαίδευσης και των τεχνικών βελτιστοποίησης. Τέλος, οι μετρικές αξιολόγησης (4.4) παρουσιάζουν τα κριτήρια με τα οποία μετρήθηκε η απόδοση των μοντέλων, όπως ακρίβεια, ανάκληση και βαθμολογία-F1, αλλά γίνεται και η εισαγωγή μιας νέας μετρικής για την αξιολόγηση της χρονοσειράς New York City Taxi (NYC Taxi).

4.1 Περιγραφή Συνόλων Δεδομένων και Περιορισμοί

Η ανάγκη εύρεσης ανωμαλιών σε χρονοσειρές μιας μεταβλητής είναι κρίσιμη σε πολλούς τομείς, όπως η παρακολούθηση της απόδοσης υπολογιστικών συστημάτων, η διαχείριση δικτύων, η πρόβλεψη βλαβών και η βελτιστοποίηση υπηρεσιών. Όπως επισημαίνεται στην επισκόπηση των Ibidunmoye κ.ά. το 2015 [39], η ανίχνευση ανωμαλιών και η ταυτοποίηση σημείων συμφοράς

(*bottlenecks*) απαιτούν την κατανόηση των βασικών στοιχείων του προβλήματος, όπως η φύση των εφαρμογών, η παρατηρησιμότητα των συστημάτων και οι μέθοδοι ανίχνευσης. Για να αναπτυχθούν και να αξιολογηθούν αποτελεσματικοί αλγόριθμοι ανίχνευσης ανωμαλιών, είναι απαραίτητη η ύπαρξη ανοικτών, αξιόπιστων και σχολιασμένων συνόλων δεδομένων. Ωστόσο, η συλλογή τέτοιων δεδομένων αποτελεί μια σημαντική πρόκληση λόγω της δυσκολίας στην συλλογή πραγματικών δεδομένων. Συγκεκριμένα, τα δεδομένα από πραγματικά συστήματα είναι δύσκολο να συλλεχθούν λόγω ζητημάτων ιδιωτικότητας, ασφάλειας και εμπιστευτικότητας. Πολλές εταιρείες δεν μπορούν ή δεν θέλουν να μοιραστούν δεδομένα που μπορεί να περιέχουν ευαίσθητες πληροφορίες. Αυτό δημιουργεί ένα κενό στην έρευνα, καθώς τα δεδομένα από πραγματικά συστήματα είναι απαραίτητα για την ανάπτυξη και τη δοκιμή αλγορίθμων που λειτουργούν σε πραγματικές συνθήκες. Ενώ τα δεδομένα από πειραματικά περιβάλλοντα (*environmental testbeds*) μπορούν να χρησιμοποιηθούν, συχνά δεν αντανακλούν πλήρως την πολυπλοκότητα και τις μεταβλητές των παραγωγικών συστημάτων. Η επιλογή των σωστών εφαρμογών και φόρτων εργασίας για να προσομοιωθούν ενδιαφέρουσες συμπεριφορές είναι μια μη τετριμμένη εργασία, καθώς οι συνθήκες παραγωγής μπορεί να περιλαμβάνουν απρόβλεπτους παράγοντες που είναι δύσκολο να αναπαραχθούν τεχνητά. Για να εκπαιδευτούν και να αξιολογηθούν αλγόριθμοι μηχανικής μάθησης ή στατιστικές μέθοδοι ανίχνευσης ανωμαλιών, απαιτούνται σύνολα δεδομένων που έχουν σχολιαστεί με ακρίβεια. Η σήμανση ανωμαλιών από ανθρώπους είναι χρονοβόρα και απαιτεί εμπειρογνώμονες, γεγονός που καθιστά τη δημιουργία τέτοιων συνόλων δεδομένων μια σημαντική επένδυση. Όπως επισημαίνεται στο έργο τους [39], η ανάλυση των ριζικών αιτιών (*root cause analysis*) των ανωμαλιών και η ταυτοποίηση σημείων συμφόρησης απαιτούν δεδομένα που έχουν σημειωθεί με ακρίβεια, ώστε να μπορούν να εκπαιδευτούν αλγόριθμοι που ανταποκρίνονται σε πραγματικές ανάγκες.

Το Yahoo! Webscope Dataset (S5), το οποίο δημοσιεύτηκε από την Yahoo [77], προσπαθεί να αντιμετωπίσει αυτές τις προκλήσεις παρέχοντας τόσο πραγματικά όσο και συνθετικά δεδομένα. Το σύνολο πραγματικών δεδομένων (A1-Benchmark) περιλαμβάνει δεδομένα από την πραγματική κίνηση παραγωγής από τις υπηρεσίες ή πλατφόρμες της Yahoo! και οι ανωμαλίες τους έχουν σημειωθεί από ανθρώπους, προσφέροντας μια αξιόπιστη βάση για έρευνα. Τα συνθετικά δεδομένα (A2-Benchmark, A3-Benchmark, A4-Benchmark) δημιουργούνται με βάση ρεαλιστικές κατανομές, επιτρέποντας τη δοκιμή αλγορίθμων σε ελεγχόμενες συνθήκες. Αυτό το σύνολο δεδομένων είναι ιδιαίτερα χρήσιμο για την ανάπτυξη και τη σύγκριση μεθόδων ανίχνευσης ανωμαλιών.

Το Numenta Anomaly Benchmark (NAB) [44] για Χρονοσειρές αποτελείται από 58 σύνολα δεδομένων από διαφορετικούς τομείς, όπως κυκλοφοριακή συμφόρηση, χρήση δικτύου, διαδικτυακές διαφημίσεις, στα οποία σύνολα οι ανωμαλίες έχουν καταγραφεί βάσει των οδηγιών σήμανσης ανωμαλιών [44]. Επίσης, υπάρχουν και σύνολα δεδομένων για τα οποία γνωρίζεται ήδη ο λόγος ύπαρξης των ανωμαλιών.

Στα πλαίσια της διπλωματικής, από το σύνολο δεδομένων Yahoo! Webscope (S5), επιλέγονται μόνο τα πραγματικά δεδομένα του A1-Benchmark, επειδή οι χρονοσειρές μιας μεταβλητής περιέχουν φυσικό θόρυβο, ατέλειες και απρόβλεπτες συμπεριφορές, οι οποίες είναι δύσκολο να αναπαραχθούν

τεχνητά, σε αντίθεση με τα υπόλοιπα 3 σύνολα δεδομένων. Επίσης, τα A2, A3, A4 σύνολα δεδομένων περιέχουν μόνο ανωμαλίες σημείων, ενώ το A1 περιέχει όλων των ειδών τις ανωμαλίες (σημείων, ακραίων συλλογικών σημείων, σημείων υπό όρους, σημεία αλλαγής μετατόπισης).

Από το Numenta Anomaly Benchmark (NAB) γίνεται επιλογή ενός από του πιο διάσημου συνόλου δεδομένων χρονοσειρών μιας μεταβλητής στον τομέα ανίχνευσης ανωμαλιών, που είναι το NYC Taxi σύνολο δεδομένων και εκφράζει την ζήτηση ταξί στην Νέα Υόρκη από τις 01/07/2014 μέχρι τις 31/01/2015 και η κάθε χρονική στιγμή του συνόλου δεδομένων καθορίζεται συγκεντρώνοντας τον συνολικό αριθμό επιβατών ταξί ανά 30 λεπτά.

Στην έρευνά τους το 2015, οι Keogh κ.ά. [81] επιχείρησαν να σημειώσουν σημαντική πρόοδο στον τομέα της ανίχνευσης ανωμαλιών σε δεδομένα χρονοσειρών, αναφέροντας τις ατέλειες διαφόρων διασήμων συνόλων δεδομένων σε αυτόν τον τομέα. Μέσα σε αυτά, ανήκουν και το Yahoo! με το NAB (Numenta Anomaly Benchmark). Οι ερευνητές κατέληξαν στο συμπέρασμα ότι τα δεδομένα αυτά παρουσιάζουν τουλάχιστον μία από τις τέσσερις κύριες ατέλειες που αναφέρουν:

- **Ασημαντότητα:** Ένα σύνολο δεδομένων μπορεί να είναι τόσο απλό που να επιλύεται με μια γραμμή κώδικα, χωρίς να απαιτείται σύνθετη ανάλυση.
- **Λανθασμένη σήμανση ανωμαλιών:** Οι ανωμαλίες μπορεί να έχουν σημειωθεί με υποκειμενικό τρόπο, καθώς η διαδικασία σήμανσης εξαρτάται από τον άνθρωπο που την πραγματοποιεί.
- **Μη ρεαλιστική πυκνότητα ανωμαλιών:** Σε ορισμένα σύνολα δεδομένων, οι ανωμαλίες μπορεί να είναι τόσο πολλές που να μην μπορούν να θεωρηθούν ακραίες τιμές, καταστρέφοντας έτσι την υπόθεση ότι πρόκειται για σπάνιες εκρήξεις.
- **Προκατάληψη λειτουργίας μέχρι αστοχίας:** Τα δεδομένα μπορεί να μην αντιπροσωπεύουν όλες τις πιθανές καταστάσεις λειτουργίας, οδηγώντας σε εσφαλμένα συμπεράσματα σχετικά με την απόδοση ενός συστήματος.

Στα δεδομένα του Yahoo! Webscope (S5), το μεγαλύτερο ποσοστό ανωμαλιών στις περισσότερες χρονοσειρές συγκεντρώνεται προς το τέλος των δεδομένων, γεγονός που μπορεί να οδηγήσει σε προκατάληψη κατά την αξιολόγηση των αλγορίθμων. Επιπλέον, υπάρχουν αντίγραφα δεδομένων, δηλαδή χρονοσειρές που είναι ουσιαστικά ίδιες, μειώνοντας έτσι την ποικιλομορφία και την αξιοπιστία του συνόλου. Ακόμη, αρκετές ανωμαλίες φαίνεται να έχουν λανθασμένη σήμανση, δημιουργώντας αβεβαιότητα ως προς την ακρίβεια των ετικετών. Ένα ακόμη σημαντικό ζήτημα είναι η ασημαντότητα, ιδιαίτερα στα υποσύνολα A2, A3 και A4, τα οποία μπορούν να επιλυθούν με κώδικα μόνο τριών σειρών, όπως αποδείχθηκε στην έρευνα των Keogh και των συνεργατών του. Για τον λόγο αυτό, στην παρούσα μελέτη επιλέχθηκε μόνο το A1 Benchmark, καθώς παρουσίασε το χαμηλότερο ποσοστό επιτυχίας και θεωρήθηκε το πιο απαιτητικό και κατάλληλο για την αξιολόγηση των αλγορίθμων.

Στο σύνολο δεδομένων NYC Taxi του NAB (Numenta Anomaly Benchmark), παρατηρούνται 5 ανωμαλίες, οι οποίες αντιστοιχούν σε σημαντικά γεγονότα, όπως ο μαραθώνιος της Νέας Υόρκης, η

Ημέρα Ευχαριστιών, τα Χριστούγεννα, η Πρωτοχρονιά και μια ημέρα ακραίας χιονοθύελλας. Ωστόσο, η σήμανση αυτών των ανωμαλιών φαίνεται να είναι υποκειμενική, καθώς υπάρχουν και άλλες σημαντικές ημέρες που θα μπορούσαν να χαρακτηριστούν ως ανωμαλίες, όπως η Ημέρα της Ανεξαρτησίας, η ημέρα μνήμης του Martin Luther King και η Ημέρα της Εργασίας.

Γνωρίζοντας αυτά τα προβλήματα στα επιλεγμένα σύνολα δεδομένων, είναι δυνατή η συνέχεια της προεπεξεργασίας και της αναλυτικότερης μελέτης τους. Παρά τις ατέλειες, τα δεδομένα αυτά εξακολουθούν να προσφέρουν πολύτιμη πληροφορία για την ανάπτυξη και αξιολόγηση αλγορίθμων ανίχνευσης ανωμαλιών, υπό την προϋπόθεση ότι λαμβάνονται υπόψη οι περιορισμοί τους και εφαρμόζονται κατάλληλες τεχνικές για την αντιμετώπιση των ζητημάτων που προκύπτουν.

4.2 Προεπεξεργασία Δεδομένων

4.2.1 Ομαδοποίηση των Δεδομένων Yahoo A1

Το σύνολο δεδομένων A1 της Yahoo! αποτελείται από 67 διαφορετικές χρονοσειρές. Οι χρονικές σημάνσεις έχουν παρατηρηθεί ανά ώρα. Οι περισσότερες χρονοσειρές είναι στάσιμες και κατά μέσο όρο κάθε χρονοσειρά αποτελείται από 1420 χρονικές στιγμές, από τις οποίες το 1.9 % είναι ανωμαλίες.


Για την αντιμετώπιση του προβλήματος της ασημαντότητας, επειδή οι περισσότερες χρονοσειρές είναι στάσιμες με ανωμαλίες σημείων και για την πιο ακριβή αξιολόγηση των αλγορίθμων, έχοντας πάρει έμπνευση από το έργο των Ibidunmoye κ.ά. [40], που ομαδοποίησαν το Yahoo A1 dataset σε τέσσερις διακριτές κατηγορίες με βάση ιδιότητες χρονοσειρών, όπως η στασιμότητα, η τάση, η εποχικότητα και οι αλλαγές στο επίπεδο, προτείνεται μια διαφορετική προσέγγιση ομαδοποίησης που προσαρμόζεται σε διαφορετικούς ερευνητικούς στόχους. Ενώ η δουλειά τους επικεντρώθηκε στην αξιολόγηση των αλγορίθμων τους ανάλογα με τη φύση των χρονοσειρών (κυρίως λόγω του ότι μέρος της υλοποίησης των αλγορίθμων τους βασίζεται στη χρήση διαγραμμάτων ελέγχου που εξαρτώνται από τις ιδιότητες της χρονοσειράς), τα κριτήρια ομαδοποίησης στην παρούσα διπλωματική βασίζονται σε τύπους ανωμαλιών, όπως ανωμαλίες σημείων, ανωμαλίες σημείων υπό όρους και ανωμαλίες συσσωρευμένων σημείων, επιτρέποντας τον προσδιορισμό των αλγορίθμων με την καλύτερη απόδοση, ανάλογα με τη φύση των ανωμαλιών κάθε χρονοσειράς.

Γι' αυτό γίνεται ο εξής διαχωρισμός στο σύνολο δεδομένων A1 της Yahoo!:


- Yahoo A1A: Αποτελείται από 13 χρονοσειρές που περιέχουν ανωμαλίες σημείων.
- Yahoo A1B: Αποτελείται από 7 κυρίως στάσιμες χρονοσειρές με αλλαγή μετατόπισης.
- Yahoo A1C: Αποτελείται από 6 χρονοσειρές οι οποίες παρουσιάζουν ανωμαλίες συσσωρευμένων σημείων και ανωμαλίες σημείων υπό όρους.

- Yahoo A1D: Αποτελείται από 6 χρονοσειρές με τάση, εποχικότητα και αλλαγή μετατόπισης και περιέχει κάθε είδους ανωμαλία.


Στο Διάγραμμα 4.1 παρουσιάζονται ενδεικτικά κάποιες χρονοσειρές που αντιπροσωπεύουν την ομάδα στην οποία ανήκουν.




(i) A1A: Ανωμαλίες Σημείων.



(ii) A1B: Ανωμαλίες αλλαγής μετατόπισης.



(iii) A1C: Ανωμαλίες συσσωρευμένων σημείων και σημείων υπό όρους.




(iv) A1D: Όλων των ειδών ανωμαλίες.

Διάγραμμα 4.1: Χαρακτηριστικά παραδείγματα χρονοσειρών για κάθε ομάδα.

Στο Διάγραμμα 4.2, μέσω της γραφικής παράστασης βιολιού, αναλύονται οι κατανομές των ανωμαλιών για κάθε υποομάδα δεδομένων του Yahoo! A1. Η υποομάδα A1A, η οποία περιλαμβάνει ακραίες ανωμαλίες, παρουσιάζει ένα σχετικά μικρό πλήθος ανωμαλιών, καθώς αυτές εμφανίζονται λιγότερο συχνά στα δεδομένα. Η κατανομή των ανωμαλιών είναι πυκνή, αλλά όχι ευρεία δεδομένου ότι οι περισσότερες χρονοσειρές έχουν παρόμοιο αριθμό από αυτές. Η υποομάδα A1B, που αφορά ανωμαλίες σημείων μετατόπισης, έχει ένα μεγαλύτερο πλήθος ανωμαλιών σε σύγκριση με την A1A, κάτι που αντανακλάται στην ευρύτερη κατανομή της, επειδή οι ανωμαλίες μετατόπισης είναι σημειωμένες στα περισσότερα υποσύνολα ως συσσωρευμένες. Η υποομάδα A1C, η οποία χαρακτηρίζεται από ανωμαλίες συσσωρευμένων σημείων και υπό όρους, παρουσιάζει τον μεγαλύτερο αριθμό ανωμαλιών, όπως φαίνεται και στη χρονοσειρά (iii) του Διαγράμματος 4.1. Αυτό οφείλεται στο γεγονός ότι οι ανωμαλίες αυτές αφορούν ομάδες σημείων που παρουσιάζουν ανωμαλία συλλογικά, οδηγώντας σε μια ευρεία κατανομή στο γράφημα βιολιού. Η κατανομή δεν είναι πυκνή, επειδή η υποομάδα περιέχει χρονοσειρές με ανωμαλίες σημείων υπό όρους. Τέλος, η υποομάδα A1D, η οποία περιλαμβάνει ανωμαλίες κάθε είδους, δηλαδή συνδυασμούς ακραίων ανωμαλιών, σημείων μετατόπισης, συσσωρευμένων σημείων και σημείων υπό όρους, έχει το δεύτερο μεγαλύτερο πλήθος ανωμαλιών. Η κατανομή

της στο γράφημα βιολιού είναι ευρεία και σχετικά πυκνή στο κάτω μέρος, αντανακλώντας την ποικιλομορφία των ανωμαλιών που περιλαμβάνονται σε αυτή την υποομάδα. Συνολικά, το Διάγραμμα 4.2 παρέχει μια σαφή εικόνα της συχνότητας και της φύσης των ανωμαλιών σε κάθε υποομάδα, επιβεβαιώνοντας και επεκτείνοντας τις παρατηρήσεις από το Διάγραμμα 4.1.



Διάγραμμα 4.2: Κατανομή των ανωμαλιών στις τέσσερις ομάδες δεδομένων Yahoo! A1.

4.2.2 Εύρεση Εποχικότητας για τα Δεδομένα

Στο πλαίσιο της ανάλυσης χρονοσειρών, η φασματική προσέγγιση αποτελεί ένα χρήσιμο εργαλείο για την αναγνώριση περιοδικοτήτων ή επαναλαμβανόμενων μοτίβων που δεν είναι άμεσα εμφανή στο χρονικό πεδίο. Η προσέγγιση αυτή εδράζεται στη θεωρία σημάτων και συστημάτων, όπως αναλύεται εκτενώς από τους Stoica και Moses [70]. Για τον σκοπό αυτό, χρησιμοποιήθηκε το περιοδόγραμμα (*periodogram*), μία από τις βασικές μεθόδους εκτίμησης της φασματικής πυκνότητας ισχύος (*Power Spectral Density – PSD*) ενός σήματος.

Η φασματική πυκνότητα ισχύος (*Power Spectral Density – PSD*) ενός σήματος περιγράφει την κατανομή της ισχύος του ως προς τις συχνότητες που το συνθέτουν. Σύμφωνα με την ανάλυση Fourier, οποιοδήποτε φυσικό σήμα μπορεί να αναλυθεί ως άθροισμα ή ολοκλήρωμα από απλές ημιτονοειδείς συνιστώσες. Η PSD αφορά το πώς κατανέμεται η ισχύς αυτών των συνιστωσών στο φασματικό πεδίο.

Στην πράξη, η PSD χρησιμοποιείται κυρίως για σήματα που εκτείνονται θεωρητικά στο άπειρο ή για στατιστικά στάσιμες χρονοσειρές. Σε τέτοιες περιπτώσεις, δεν έχει νόημα η συνολική ενέργεια (η οποία τείνει στο άπειρο), αλλά η ισχύς ανά μονάδα χρόνου, που είναι πεπερασμένη. Η PSD λοιπόν δίνει ένα μέτρο της πυκνότητας ισχύος ανά συχνότητα και συνδέεται άμεσα με τη διακύμανση (*variance*) ενός στοχαστικού σήματος. Στατιστικά, θεωρείται ότι η PSD αντιπροσωπεύει το μέσο φασματικό περιεχόμενο του σήματος, ακόμη και στην περίπτωση όπου δεν υπάρχει φυσική ισχύς, αλλά στατιστική μεταβλητότητα.

Μαθηματικά, η PSD ενός σήματος ορίζεται ως ο μετασχηματισμός Fourier της συνάρτησης αυτοσυσχέτισης του σήματος (κοινώς, της χρονοσειράς, που αποτελεί διακριτή συνάρτηση), σύμφωνα

με το θεώρημα Wiener–Khinchin [52]. Σε περιπτώσεις όπου η συνάρτηση αυτοσυσχέτισης δεν είναι εύκολα διαθέσιμη, η εκτίμηση της PSD μπορεί να πραγματοποιηθεί με τη χρήση του περιοδογράμματος, το οποίο βασίζεται στον διακριτό μετασχηματισμό Fourier (DFT) του σήματος.

Για τα δύο σύνολα δεδομένων, Yahoo! Webscope και NYC Taxi, πραγματοποιήθηκε μια ανάλυση για την εύρεση της ισχυρότερης εποχικότητας στις χρονοσειρές, χρησιμοποιώντας το περιοδογράμμα. Από την ανάλυση αυτή διαπιστώθηκε ότι στα περισσότερα υποσύνολα δεδομένων του Yahoo!, δεν υπάρχει κυρίαρχη εποχικότητα, κυρίως λόγω της στασιμότητας των χρονοσειρών, της μικρής κλίμακας περιοδικότητας και της παρουσίας θορύβου στα δεδομένα. Ωστόσο, σε ορισμένες χρονοσειρές του Yahoo! παρατηρείται ισχυρή ημερήσια εποχικότητα μεγέθους 24, καθώς τα δεδομένα λαμβάνονται ανά μία ώρα. Στις χρονοσειρές που δεν εμφανίζουν κυρίαρχη εποχικότητα, εντοπίζεται μια ασθενής ημερήσια εποχικότητα, η οποία όμως δεν είναι αρκετά έντονη για να θεωρηθεί κυρίαρχη.

Από την άλλη πλευρά, στη χρονοσειρά του NYC Taxi, παρατηρείται ισχυρή ημερήσια εποχικότητα μεγέθους 48, καθώς τα δεδομένα καταγράφονται ανά μισή ώρα. Αυτή η εποχικότητα αντανakλά τις καθημερινές διακυμάνσεις στη χρήση των ταξί, οι οποίες είναι έντονα επηρεασμένες από τις ώρες αιχμής, τις νυχτερινές διαδρομές και άλλες καθημερινές δραστηριότητες.

4.2.3 Τυποποίηση και Κανονικοποίηση των Δεδομένων

Πριν την εφαρμογή των μεθόδων για την ανίχνευση των ανωμαλιών είναι αναγκαία η τυποποίηση (*standardization*) ή η κανονικοποίηση (*normalization*) των συνόλων δεδομένων, που αποτελούν δύο βασικές τεχνικές προεπεξεργασίας δεδομένων.

Η τυποποίηση είναι η διαδικασία μετασχηματισμού των δεδομένων έτσι ώστε να έχουν μηδενικό μέσο όρο ($\text{mean} = 0$) και τυπική απόκλιση ίση με 1 ($\text{standard deviation} = 1$). Μαθηματικά, η τυποποίηση ορίζεται ως:

$$\hat{x} = \frac{x - \mu}{\sigma},$$

όπου x είναι η αρχική τιμή, μ ο μέσος όρος των δεδομένων, σ η τυπική τους απόκλιση και $\hat{x}$ είναι η τυποποιημένη τιμή.

Η κανονικοποίηση δεν αποτελεί ίδια διαδικασία με την τυποποίηση. Συγκεκριμένα, η πρώτη μετασχηματίζει τα δεδομένα σε μια συγκεκριμένη κλίμακα, συνήθως μεταξύ 0 και 1, με την πιο συνηθισμένη μέθοδο κανονικοποίησης να είναι η μέθοδος Min-Max Scaling, η οποία ορίζεται ως:

$$x_{norm} = \frac{x - x_{min}}{x_{max} - x_{min}},$$

όπου x είναι η αρχική τιμή, x_{min} αποτελεί την ελάχιστη τιμή του συνόλου δεδομένων, x_{max} την μέγιστη τιμή και το x_{norm} τα κανονικοποιημένα δεδομένα.

Επειδή η κανονικοποίηση είναι ευαίσθητη στις ακραίες τιμές, οι οποίες υπάρχουν στα δεδομένα

που θα χρησιμοποιηθούν στην διπλωματική, είναι προτιμότερο να τυποποιηθούν πριν εφαρμοστούν οι μέθοδοι ανίχνευσης ανωμαλιών. Ειδικότερα, οι Shanker κ.ά. το 1996 [62] βρήκαν ότι σε τυποποιημένα δεδομένα μικρότερου μεγέθους, οι αλγόριθμοι βαθιάς μάθησης συγκλίνουν πιο γρήγορα.

Όμως, στην εργασία που εισάγεται η ιδέα των Μηχανών Διανυσμάτων Υποστήριξης Μίας Κλάσης από τους Schölkopf κ.ά. το 1999 [60], προτιμάται η κανονικοποίηση των δεδομένων πριν την εφαρμογή του αλγορίθμου, ανεξάρτητα αν υπάρχουν ακραίες τιμές. Αυτό συμβαίνει, επειδή εξισορροπεί την επίδραση των χαρακτηριστικών με διαφορετικές κλίμακες, βελτιώνει τη σύγκλιση του αλγορίθμου και αντιμετωπίζει την επίδραση των ακραίων τιμών. Επιπλέον, εξασφαλίζει τη συμβατότητα με τους πυρήνες, καθιστώντας όλα τα χαρακτηριστικά ισότιμα στους υπολογισμούς. Οπότε, πριν την εφαρμογή όλων των μεθόδων γίνεται τυποποίηση στα δεδομένα εκτός της μεθόδου OC-SVM που εκτελείται κανονικοποίηση.

4.2.4 Αποτασιοποίηση των Δεδομένων

Οι περισσότερες στατιστικές μέθοδοι ανάλυσης χρονοσειρών βασίζονται στην υπόθεση ότι οι χρονοσειρές παρουσιάζουν στασιμότητα ως προς τη μέση τιμή και τη διακύμανση. Ωστόσο, στην περίπτωση των μεθόδων μηχανικής μάθησης και των νευρωνικών δικτύων, αυτή η προϋπόθεση δεν είναι απαραίτητη και αποτελεί θέμα συζήτησης. Αρκετές έρευνες υποστηρίζουν ότι δεν χρειάζεται να μετασχηματιστούν οι χρονοσειρές σε στάσιμες, καθώς τα νευρωνικά δίκτυα έχουν την ικανότητα να αναγνωρίζουν μη σταθερές τάσεις. Για παράδειγμα οι Sharda και Patil το 1992 [63], μέσω εμπειρικής μελέτης σε 101 διαφορετικές χρονοσειρές, διαπίστωσαν ότι τα νευρωνικά δίκτυα μπορούν να εντοπίσουν αυτόματα την εποχικότητα σε μονομεταβλητές χρονοσειρές. Παρόμοια συμπεράσματα έχουν προκύψει και από άλλες εργασίες των Franses και Daisma [26] το 1997, που βρήκαν ότι τα νευρωνικά δίκτυα μπορούν να μεταδώσουν οπτική πληροφορία σχετικά με το πώς και πότε μεταβάλλονται οι εποχικές διακυμάνσεις και των Tang και Fishwick το 1993 [71], που σύγκριναν την μέθοδο Box-Jenkins (αναφέρθηκε στο Κεφάλαιο 3.1.2) με νευρωνικά δίκτυα σε 16 χρονοσειρές μικρού και μεγάλου μεγέθους και ανακάλυψαν ότι τα νευρωνικά δίκτυα δίνουν παρόμοια ή καλύτερα αποτελέσματα.

Παρόλα αυτά, υπάρχουν και μελέτες που φέρνουν αντιθετικά αποτελέσματα. Οι Faraway και Chatfield το 2002 [25] σύγκριναν τα νευρωνικά δίκτυα με την μέθοδο Box-Jenkins και του Holt-Winters στο διάσημο σύνολο δεδομένων αεροπορικής εταιρείας που περιέχει τάση και εποχικότητα. Ανακάλυψαν ότι τα νευρωνικά δίκτυα δεν μπορούν να ανακαλύψουν την τάση και την εποχικότητα τόσο εύκολα όσο οι άλλες μέθοδοι. Ομοίως, οι Zhang και Qi το 2005 [84], σε μια εμπειρική μελέτη, διαπίστωσαν ότι η χρήση αποτασιοποιημένων και αποεποχικοποιημένων δεδομένων οδηγεί σε καλύτερα αποτελέσματα. Συγκεκριμένα, βρήκαν ότι ο συνδυασμός των δύο τεχνικών αποδίδει καλύτερα, συμπεραίνοντας ότι τα νευρωνικά δίκτυα δεν μπορούν να εντοπίσουν αποτελεσματικά τις εποχικές διακυμάνσεις και τις τάσεις.

Για την εξαγωγή πιο αξιόπιστων και ακριβών συμπερασμάτων, στη συγκεκριμένη διπλωματική

πραγματοποιήθηκε επιπλέον αξιολόγηση των αλγορίθμων στο αποτασιοποιημένο υποσύνολο Yahoo! A1D, το μοναδικό που παρουσίαζε εμφανή τάση. Η αποτασιοποίηση εφαρμόστηκε μόνο στο συγκεκριμένο σύνολο δεδομένων, καθώς τα υπόλοιπα δεν παρουσίαζαν στατιστικά σημαντική μακροχρόνια μεταβολή. Επιλέχθηκε μία μόνο εφαρμογή γραμμικής διαφοροποίησης πρώτης τάξης ($d = 1$), η οποία κρίθηκε επαρκής για την απομάκρυνση των βασικών γραμμικών τάσεων. Οι τάσεις στο A1D είναι ήπιες και σχεδόν γραμμικές, χωρίς έντονα μη γραμμικά μοτίβα ή πολυπλοκότητα, γεγονός που καθιστά επιπλέον διαφοροποιήσεις περιττές — καθώς θα μπορούσαν να εισάγουν θόρυβο και να μειώσουν την ευκρίνεια των τοπικών ανωμαλιών.

Παράλληλα, δεν πραγματοποιήθηκε αποεποχικοποίηση των χρονοσειρών, καθώς, σύμφωνα με τη βιβλιογραφία, τα νευρωνικά δίκτυα έχουν τη δυνατότητα να αναγνωρίζουν εσωτερικά και να προσαρμόζονται σε εποχικές μεταβολές, ακόμη και χωρίς ρητή απομάκρυνση της εποχικότητας. Επιπλέον, οι χρονοσειρές του Yahoo! εμφανίζουν εκτός από ημερήσια, και ασθενή εποχικότητα, επομένως η αποεποχικοποίηση δεν γίνεται να είναι ενιαία για κάθε είδους χρονοσειρά.

4.2.5 Δημιουργία Χαρακτηριστικών

Οι αλγόριθμοι μηχανικής μάθησης που έχουν επιλεγθεί, δεν είναι κατασκευασμένοι για την ανίχνευση ανωμαλιών σε δεδομένα χρονοσειρών. Αναλυτικότερα, στην περίπτωση που εφαρμοσθούν αυτοί οι αλγόριθμοι στα δεδομένα, θα μπορούν να βρουν μόνο τις ακραίες τιμές τους, χωρίς να λαμβάνουν υπόψη τους τις χρονικές εξαρτήσεις, την τάση και την εποχικότητα της χρονοσειράς. Αυτό έχει ως αποτέλεσμα οι αλγόριθμοι να αδυνατούν να ανιχνεύσουν τις ανωμαλίες σημείων υπό όρους, συσσωρευμένων σημείων και σημείων αλλαγής μετατόπισης. Γι' αυτό το λόγο υπάρχει ανάγκη εισαγωγής χρονικών (*temporal*) χαρακτηριστικών στα μοντέλα.

Στα πλαίσια της διπλωματικής γίνεται η επιλογή των παρακάτω χαρακτηριστικών, αλλά πριν δοθούν, είναι αναγκαίος ο ορισμός του κυλιόμενου παραθύρου (*rolling window*).

Έστω μια χρονοσειρά T με μήκος n , και μια υποακολουθία $T_{i;l}$ με μήκος l . Ένα κυλιόμενο παράθυρο $W_{i;m}$ στην T ορίζεται ως ένα σύνολο συνεχόμενων σημείων με μήκος m (όπου $l \leq m \leq n$), το οποίο επεκτείνεται προς τα εμπρός από το σημείο t_i και περιλαμβάνει την υποακολουθία $T_{i;l}$. Δηλαδή:

$$W_{i;m} = \{t_{i-m+1}, t_{i-m+2}, \dots, t_{i-l}, t_{i-l+1}, t_{i-l+2}, \dots, t_{i-1}, t_i\},$$

όπου $m \leq i \leq n$.

Έτσι, μέσω της έννοιας του κυλιόμενου παραθύρου προκύπτουν τα χαρακτηριστικά του κυλιόμενου μέσου (*rolling mean*) και της κυλιόμενης διακύμανσης (*rolling variance*). Δίνονται οι παρακάτω ορισμοί:

Έστω μια χρονοσειρά $T = \{t_1, t_2, \dots, t_n\}$ με μήκος n . Ο κυλιόμενος μέσος με μέγεθος παραθύρου m (όπου $m \leq n$) ορίζεται ως ο μέσος όρος των τιμών της χρονοσειράς που περιλαμβάνονται σε ένα κυλιόμενο παράθυρο μήκους m . Για κάθε χρονική στιγμή i , ο κυλιόμενος μέσος μ_i υπολογίζεται ως

$$\mu_i = \frac{1}{m} \sum_{j=i-m+1}^i x_j,$$

με τον κυλιόμενο μέσο να εξομαλύνει τα δεδομένα, αφαιρώντας τον θόρυβο και να αναγνωρίζει τις τάσεις της χρονοσειράς. Έτσι, προβλέπονται οι βραχυπρόθεσμες τάσεις.

Έστω μια χρονοσειρά $T = \{t_1, t_2, \dots, t_n\}$ με μήκος n . Η κυλιόμενη διακύμανση με μέγεθος παραθύρου m (όπου $m \leq n$) ορίζεται ως η διακύμανση των τιμών της χρονοσειράς που περιλαμβάνονται σε ένα κυλιόμενο παράθυρο μήκους m . Για κάθε χρονική στιγμή i , η κυλιόμενη διακύμανση σ_i^2 υπολογίζεται ως

$$\sigma_i^2 = \frac{1}{m} \sum_{j=i-m+1}^i (x_j - \mu_i)^2,$$

με την κυλιόμενη διακύμανση να μετράει τη μεταβλητότητα των δεδομένων σε ένα κινητό παράθυρο και να βοηθά στην ανίχνευση αλλαγών στην συμπεριφορά των δεδομένων.

Αρκετά χρήσιμα χαρακτηριστικά είναι και οι μέγιστες και ελάχιστες τιμές σε κάθε χρονικό διάστημα, που υπολογίζονται μέσω του κυλιόμενου παραθύρου και βοηθάνε στην ανάλυση εύρους τιμών και στην πρόβλεψη ακραίων γεγονότων.

Επιπλέον χαρακτηριστικά που χρησιμοποιήθηκαν είναι η ημιτονοειδής και συνημιτονοειδής κωδικοποίηση, που είναι ιδιαίτερα χρήσιμες για την ανάλυση περιοδικών δεδομένων, καθώς καταγράφουν επαναλαμβανόμενα μοτίβα με συμπαγή και αποδοτικό τρόπο. Αυτές οι μέθοδοι μετατρέπουν διακριτές ή κατηγορικές χρονικές μεταβλητές (όπως η ώρα της ημέρας ή η μέρα της εβδομάδας) σε συνεχείς τιμές, διευκολύνοντας την επεξεργασία τους από αλγορίθμους μηχανικής μάθησης. Επιπλέον, εξομαλύνουν απότομες μεταβάσεις στα δεδομένα, προσφέροντας μια ομαλή αναπαράσταση που βελτιώνει την ερμηνεία και την πρόβλεψη, ιδιαίτερα σε προβλήματα όπως η πρόβλεψη χρονοσειρών. Οι κωδικοποιήσεις αυτές δίνονται από τους παρακάτω τύπους

$$x_{sin}(t) = \sin\left(\frac{2\pi t}{T}\right),$$

$$x_{cos}(t) = \cos\left(\frac{2\pi t}{T}\right),$$

με το T να εκφράζει το μέγεθος της περιόδου. Για παράδειγμα, αν υπάρχει ημερήσια εποχικότητα 24 ωρών, αυτή η αναπαράσταση είναι χρήσιμη επειδή επιτρέπει στα μοντέλα μηχανικής μάθησης να κατανοήσουν ότι η ώρα της ημέρας έχει μια κυκλική φύση και ότι τα μεσάνυχτα και το μεσημέρι είναι στενά συνδεδεμένα, ακόμα κι αν μπορεί να είχαν αναπαρασταθεί ως ξεχωριστοί αριθμοί σε μια κανονική κωδικοποίηση ($x_{sin}(0) = x_{sin}(12) = 0$).

Στο Yahoo! A1, η περίοδος επιλέγεται ως $T = 24$, όπως και το μέγεθος του κυλιόμενου πα-

ραθύρου για τον υπολογισμό των κυλιόμενων μέσων και διακύμανσης. Αυτό γίνεται επειδή στο A1 υπάρχουν αρκετές χρονοσειρές που πρέπει να εξεταστούν, οπότε για να είναι γρηγορότερη και αποδοτικότερη η ανάλυση, γίνεται παραδοχή για ημερήσια εποχικότητα (ακόμα και να είναι ασθενής). Για το NYC Taxi, γνωρίζεται ότι υπάρχει ημερήσια εποχικότητα, αλλά επειδή τα δεδομένα εισάγονται κάθε μισή ώρα, επιλέγεται $T = 48$, όπως και το μέγεθος του κυλιόμενου παραθύρου.

Τέλος, για την ενίσχυση της απόδοσης των αλγορίθμων, έγινε χρήση χρονικών χαρακτηριστικών όπως η ώρα (*hour*), η ημέρα της εβδομάδας (*day_of_week*), ο μήνας (*month*) και η ημέρα του μήνα (*day_of_month*), τα οποία έχουν ως στόχο να βοηθήσουν τους αλγορίθμους να κατανοήσουν και να εκμεταλλευτούν τις χρονικές εξαρτήσεις και τις εποχικές τάσεις στα δεδομένα. Το *hour* αναφέρεται στη συγκεκριμένη ώρα της ημέρας, το *day_of_week* στην ημέρα της εβδομάδας, το *month* στον μήνα και το *day_of_month* στην ημέρα του μήνα. Αυτά τα χαρακτηριστικά επιτρέπουν την αναγνώριση ημερήσιων, εβδομαδιαίων και εποχικών μοτίβων, προσφέροντας στους αλγορίθμους τη δυνατότητα να λαμβάνουν υπόψη τις χρονικές εξαρτήσεις και να προσαρμόζονται στις εποχικές τάσεις που επηρεάζουν τη συμπεριφορά των χρονοσειρών.

4.3 Υλοποίηση των Αλγορίθμων

Για την πραγματοποίηση των πειραμάτων επιλέχθηκε η πλατφόρμα Google Colaboratory [18]. Σε κάθε συνεδρία (*session*) του Google Colab, ήταν διαθέσιμα 12.5 GB μνήμης RAM και 2 εικονικές κεντρικές μονάδες επεξεργασίας (CPUs). Επειδή τα δεδομένα χρονοσειρών τα οποία επιλέχθηκαν δεν είναι μεγάλου όγκου και δεν έγινε χρήση σύνθετων μοντέλων εύρεσης ανωμαλιών, δεν υπάρχει ανάγκη καρτών γραφικών (GPUs) για πιο γρήγορους υπολογισμούς.

Το πειραματικό κομμάτι εκπονήθηκε σε γλώσσα προγραμματισμού Python [72] και έγινε χρήση των παρακάτω βιβλιοθηκών. Συγκεκριμένα η βιβλιοθήκη NumPy [31] χρησιμοποιήθηκε για την αποτελεσματική διαχείριση και επεξεργασία πολυδιάστατων πινάκων και μαθηματικών πράξεων, ενώ η Pandas [51] για την ανάγνωση, καθαρισμό και οργάνωση των δεδομένων σε δομημένη μορφή. Η Matplotlib [37] και η Seaborn [76] χρησιμοποιήθηκαν για οπτικές αναπαραστάσεις, η SciPy [74] για το περιοδογράμμο, η Stumpy [45] για τον υπολογισμό του προφίλ πίνακα, μέσω του αλγορίθμου STOMP που είχε αναφερθεί στο Κεφάλαιο 3.2.6, η StatsModels [61] για στατιστικά μοντέλα χρονοσειρών, η TensorFlow/Keras [1] για τη δημιουργία και εκπαίδευση νευρωνικών δικτύων, η XGBoost [17] για την υλοποίηση του αλγορίθμου XGBoost και η Scikit-learn [53] για την υλοποίηση των υπόλοιπων μοντέλων μηχανικής μάθησης.

Επειδή οι τρόποι εύρεσης ανωμαλιών σε δεδομένα χρονοσειρών είναι διαφορετικοί για κάθε αλγόριθμο, για την πιο αποτελεσματική μελέτη του προβλήματος, διαχωρίζονται οι αλγόριθμοι σε δύο ομάδες. Η πρώτη ομάδα (Ομάδα I) είναι αυτή των αλγορίθμων μηχανικής μάθησης, στους οποίους εισάγονται τα χρονικά χαρακτηριστικά. Επίσης, προστίθεται ο αλγόριθμος του Προφίλ Πίνακα, ο οποίος, αν και δεν δέχεται χρονικά χαρακτηριστικά, αποτελεί μια εξειδικευμένη μέθοδο για την ανί-

χνευση συλλογικών και υπό όρους ανωμαλιών σε χρονοσειρές, και για τον λόγο αυτό περιλαμβάνεται στην ίδια κατηγορία για λόγους λειτουργικής σύγκρισης. Στην Ομάδα II ανήκουν οι προβλεπτικοί αλγόριθμοι, στους οποίους ανήκουν οι στατιστικές μέθοδοι, τα νευρωνικά δίκτυα, αλλά και ο XGBoost, ο μοναδικός αλγόριθμος μηχανικής μάθησης που εξαιρείται από την πρώτη ομάδα, επειδή εφαρμόζεται ως μοντέλο παλινδρόμησης. Ανεξάρτητα για το αν χρησιμοποιείται με αυτόν τον τρόπο, επειδή ο XGBoost δεν είναι κατασκευασμένος για χρονικά δεδομένα, εισάγονται και σε αυτόν χρονικά χαρακτηριστικά.

Στην Ομάδα I εφαρμόζονται οι αλγόριθμοι στα δεδομένα με τα χρονικά τους χαρακτηριστικά με τεχνική μη εποπτευόμενης μάθησης. Αναλυτικότερα, οι αλγόριθμοι εκπαιδεύονται σε ολόκληρη την χρονοσειρά και μετά δοκιμάζονται σε όλα τα δεδομένα, βγάζοντας μια βαθμολογία ανωμαλίας όπου κρίνουν αν τα σημεία είναι κανονικά ή ανωμαλίες. Ο μοναδικός αλγόριθμος που χρησιμοποιείται με τεχνική ήμι-εποπτευόμενης μάθησης είναι ο OC-SVM, ο οποίος εκπαιδεύεται μόνο στα κανονικά (μη ανώμαλα) δεδομένα και δοκιμάζεται σε όλα τα δεδομένα και υποβοηθείται από αυτήν την μέθοδο, όπως αναφέρεται και στην εργασία στην οποία προτάθηκε [60]. Ο αλγόριθμος Προφίλ Πίνακα, αποτελεί μια τεχνική εύρεσης μοτίβων και ανωμαλιών σε χρονοσειρές, οπότε δεν υπόκειται σε εκπαίδευση.

Οι υπερπαραμέτροι που χρησιμοποιούνται για κάθε αλγόριθμο της Ομάδας I, φαίνονται στον Πίνακα 4.1. Ο προσδιορισμός των βέλτιστων υπερπαραμέτρων γίνεται μέσω του αλγορίθμου Αναζήτησης Πλέγματος (*Grid-Search*), που αποτελεί μια εξαντλητική μέθοδο, όπου εξετάζει όλους τους πιθανούς συνδυασμούς των υπερπαραμέτρων και βρίσκει τις καλύτερες τιμές. Για το Yahoo A1, ο προσδιορισμός των βέλτιστων υπερπαραμέτρων γίνεται μέσω της βαθμολογίας-F1, ενώ στο NYC Taxi του NAB, γίνεται μέσω της βαθμολογίας NAB.

Για τον αλγόριθμο του Δάσους Απομόνωσης (*Isolation Forest*), χρησιμοποιήθηκαν οι εξής υπερπαραμέτροι στην αναζήτηση πλέγματος: `n_estimators = [50, 100, 200]`, `max_samples = ['auto', 0.5, 0.75]`, `contamination = ['auto', 0.01, 0.05, 0.1, 0.2, 0.3]`, `max_features = [12]`. Για τη Μηχανή Διανυσμάτων Υποστήριξης Μίας Κλάσης (*One-Class SVM*), δοκιμάστηκαν οι τιμές `nu = [0.01, 0.05, 0.1]`, `kernel = ['rbf']`, και `gamma = ['scale', 'auto']`. Στον Τοπικό Παράγοντα Αποκλίσεων (*Local Outlier Factor*), εξετάστηκαν οι παράμετροι `n_neighbors = [5, 10, 20, 30, 40]` και `contamination = ['auto', 0.01, 0.02, 0.05, 0.1]`. Για τον DBSCAN, χρησιμοποιήθηκαν οι τιμές `eps = [0.5, 1.0, 1.5, 2.0]` και `min_samples = [5, 10, 20]`. Τέλος, για το Προφίλ Πίνακα (*Matrix Profile*), δοκιμάστηκαν τα μεγέθη παραθύρων `window_sizes = [10, 24, 50, 75, 100, 150]` και τα κατώφλια `thresholds = [80, 85, 90, 95, 99]` (σε ποσοστιαίες μονάδες).

Οι αλγόριθμοι της Ομάδας I εφαρμόζονται τόσο στα αρχικά δεδομένα, συμπεριλαμβανομένων των χρονικών τους χαρακτηριστικών (*temporal features*), όσο και στα δεδομένα χωρίς αυτά. Ο κύριος στόχος αυτής της διπλής εφαρμογής είναι η διεξαγωγή συγκριτικής ανάλυσης των αποτελεσμάτων σε κάθε σύνολο δεδομένων, ώστε να εξακριβωθεί σε ποια μορφή δεδομένων (με ή χωρίς χρονικά χαρακτηριστικά) οι αλγόριθμοι παρουσιάζουν βελτιωμένη απόδοση. Αυτή η διαδικασία αποτελεί κρίσιμο βήμα για την αξιολόγηση της επίδρασης των χρονικών χαρακτηριστικών στην αποτελεσματικότητα

Αλγόριθμος	Υπερπαράμετρος	Λειτουργία
Δάσος Απομόνωσης (IF)	n_estimators	Αριθμός των δέντρων στο δάσος
	max_samples	Μέγιστος αριθμός δειγμάτων για κάθε δέντρο
	contamination	Ποσοστό ανωμαλιών στα δεδομένα
	max_features	Αριθμός των χαρακτηριστικών για κάθε δέντρο
Μηχανή Διανυσμάτων Υποστήριξης Μίας Κλάσης (OCSVM)	nu	Παράμετρος που ελέγχει το ποσοστό των σφαλμάτων και των διανυσμάτων υποστήριξης
	kernel	Πυρήνας που χρησιμοποιείται για τον μετασχηματισμό των δεδομένων
	gamma	Παράμετρος του πυρήνα για μη γραμμικούς μετασχηματισμούς
Τοπικός Παράγοντας Αποκλίσεων (LOF)	n_neighbors	Αριθμός γειτόνων για τον υπολογισμό της τοπικής πυκνότητας
	contamination	Ποσοστό ανωμαλιών στα δεδομένα
DBSCAN	eps	Μέγιστη απόσταση μεταξύ δύο δειγμάτων για να θεωρηθούν γείτονες
	min_samples	Ελάχιστος αριθμός δειγμάτων σε μια γειτονιά για να θεωρηθεί πυκνή περιοχή
Προφίλ Πίνακα (MP)	threshold	Κατώφλι πάνω από το οποίο μια τιμή θεωρείται ανώμαλη ή σημαντική
	window_size	Μέγεθος του παραθύρου (αριθμός παρατηρήσεων) για ανάλυση δεδομένων

Πίνακας 4.1: Υπερπαράμετροι και Λειτουργίες των Αλγορίθμων της Ομάδας I.

των αλγορίθμων.

Οι αλγόριθμοι της Ομάδας II εφαρμόζονται με διαφορετικό τρόπο σε σύγκριση με εκείνους της πρώτης ομάδας. Επειδή πρόκειται για προβλεπτικούς αλγόριθμους, εκπαιδεύονται σε ένα αρχικό τμήμα των χρονοσειρών και αξιολογούνται στο υπόλοιπο τμήμα. Αυτή η προσέγγιση εφαρμόζεται λόγω της διάσπαρτης φύσης των ανωμαλιών στις χρονοσειρές, γεγονός που καθιστά απαραίτητη τη μείωση του μεγέθους του τμήματος εκπαίδευσης, ώστε να αποφευχθεί να χαθούν ανωμαλίες στο σύνολο δοκιμής.

Οι αλγόριθμοι Holt-Winters (HWEAST) και SARIMA ανήκουν στην κατηγορία των μοντέλων χρονοσειρών και, ως εκ τούτου, δεν απαιτούν διαδικασία μάθησης. Από την άλλη πλευρά, οι αλγόριθμοι XGBoost και το γραμμικό μοντέλο ανήκουν στην κατηγορία της εποπτευόμενης μάθησης. Τέλος, μεταξύ των νευρωνικών δικτύων, οι MLP και LSTM εμπίπτουν επίσης στην εποπτευόμενη μάθηση, ενώ ο Αυτοκωδικοποιητής ανήκει στην κατηγορία της μη εποπτευόμενης μάθησης.

Στο σύνολο δεδομένων Yahoo A1, το ποσοστό εκπαίδευσης και δοκιμής διαφέρει ανάλογα με το υποσύνολο δεδομένων. Συγκεκριμένα, στα υποσύνολα A1A, A1C και A1D, η εκπαίδευση πραγματοποιείται στο πρώτο 30% των χρονοσειρών, ενώ η δοκιμή γίνεται στο υπόλοιπο 70%. Στο υποσύνολο A1B, λόγω της παρουσίας ανωμαλιών μετατόπισης στις αρχές ορισμένων χρονοσειρών, το ποσοστό εκπαίδευσης μειώνεται στο 20%, ενώ το ποσοστό δοκιμής αυξάνεται στο 80%. Για το σύνολο δεδομένων NYC Taxi, το οποίο είναι σημαντικά μεγαλύτερο και παρουσιάζει τις περισσότερες ανωμαλίες προς το τέλος της χρονοσειράς, η εκπαίδευση πραγματοποιείται στο πρώτο 40% της, ενώ η δοκιμή γίνεται στο υπόλοιπο 60%.


Η υλοποίηση των αλγορίθμων της Ομάδας II οργανώνεται σε τρεις κατηγορίες. Η πρώτη κατηγορία περιλαμβάνει τους αλγόριθμους Holt-Winters (HWEST) και SARIMA, οι οποίοι ανήκουν στα μοντέλα χρονοσειρών. Η δεύτερη κατηγορία περιλαμβάνει τους αλγόριθμους XGBoost και το γραμμικό μοντέλο, ενώ η τρίτη κατηγορία αποτελείται από τα νευρωνικά δίκτυα. Ο διαχωρισμός αυτός δεν βασίζεται στα είδη μάθησης, αλλά στις μεταβλητές και στους τρόπους με τους οποίους εκπαιδεύονται οι αλγόριθμοι.

Ένας επιπλέον λόγος για τον διαχωρισμό αυτόν είναι η διαφορετική συμπεριφορά των αλγορίθμων στα δεδομένα δοκιμής. Συγκεκριμένα, όλοι οι αλγόριθμοι της Ομάδας II, εκτός των HWEST και SARIMA, έχουν τη δυνατότητα να "δουν το μέλλον", καθώς μπορούν να χρησιμοποιήσουν τιμές από τα δεδομένα δοκιμής, ανάλογα με το παράθυρο πρόβλεψης που έχει οριστεί. Για παράδειγμα, όλα τα νευρωνικά δίκτυα (MLP, LSTM, AE), καθώς και το γραμμικό μοντέλο (LM), εφαρμόζονται στο σύνολο δοκιμής με τη μορφή κυλιόμενου παραθύρου, προκειμένου να προσαρμόζονται σωστά στη δυναμική των χρονοσειρών και να αξιοποιούν τη χρονική εξάρτηση των δεδομένων. Για παράδειγμα, αν το παράθυρο πρόβλεψης έχει μέγεθος 24, τότε τα μοντέλα παίρνουν τις τελευταίες 24 τιμές από το σύνολο δοκιμής και προβλέπουν την αμέσως επόμενη τιμή. Αυτή η διαδικασία επαναλαμβάνεται για κάθε νέο σημείο πρόβλεψης, όπου το παράθυρο "κυλάει" προς τα εμπρός, συμπεριλαμβάνοντας νέες τιμές και αποκλείοντας τις παλαιότερες. Ομοίως, ο XGBoost λειτουργεί με βάση την τεχνική του gradient boosting, όπου χρησιμοποιεί τις προηγούμενες τιμές της χρονοσειράς ως χαρακτηριστικά για την πρόβλεψη της επόμενης τιμής.

Αντίθετα, οι HWEST και SARIMA δεν διαθέτουν αυτή την ικανότητα, καθώς κάθε πρόβλεψή τους βασίζεται αποκλειστικά στην αμέσως προηγούμενη πρόβλεψη και όχι σε πραγματικές τιμές από το σύνολο δοκιμής. Αυτό οδηγεί σε μακροχρόνιες προβλέψεις με αυξημένη ανακρίβεια, ιδιαίτερα σε περιπτώσεις όπου οι χρονοσειρές παρουσιάζουν μεταβαλλόμενες συνθήκες, όπως στις ομάδες A1B (μετατοπίσεις) και A1D (τάση στα δεδομένα). Η έλλειψη προσαρμοστικότητας σε πραγματικές τιμές από το σύνολο δοκιμής κάνει τους HWEST και SARIMA λιγότερο αποτελεσματικούς σε τέτοιες περιπτώσεις.

Λόγω των μικρών διαστημάτων εκπαίδευσης στα σύνολα δεδομένων Yahoo και NYC Taxi, καθίσταται απαραίτητη η εισαγωγή μιας εναλλακτικής μεθόδου, της Διασταυρούμενης Επικύρωσης σε Χρονοσειρές (*Time Series Cross Validation*), ώστε να αντιμετωπιστούν τα προβλήματα που προκύπτουν από την περιορισμένη διαθεσιμότητα δεδομένων εκπαίδευσης και να βελτιωθεί η ακρίβεια των

προβλέψεων.



Διάγραμμα 4.3: Λειτουργία της Διασταυρούμενης Επικύρωσης σε Χρονοσειρές.

Η διασταυρωμένη επικύρωση σε χρονοσειρές (TSCV) απαιτεί ιδιαίτερη προσοχή, καθώς η χρονική σειρά των δεδομένων δεν πρέπει να παραβιάζεται. Σε αντίθεση με την κλασική διασταυρωμένη επικύρωση, όπου τα δεδομένα μπορούν να ανακατευτούν, στις χρονοσειρές χρησιμοποιείται η TSCV, η οποία διατηρεί τη χρονική σειρά. Σε αυτήν την προσέγγιση, το σύνολο εκπαίδευσης αυξάνεται σταδιακά, ενώ το σύνολο δοκιμής μετακινείται μπροστά στο χρόνο, όπως φαίνεται και στο Διάγραμμα 4.3, προσομοιώνοντας έτσι την πραγματική χρήση του μοντέλου σε νέα δεδομένα, επαναλαμβάνοντας τη διαδικασία 10 φορές σε μια χρονοσειρά μεγέθους 100. Αυτή η μέθοδος αποφεύγει την διαρροή δεδομένων (*data leakage*) και εξασφαλίζει ότι το μοντέλο δεν χρησιμοποιεί πληροφορίες από το μέλλον για την πρόβλεψη του παρελθόντος, παρέχοντας μια αξιόπιστη εκτίμηση της απόδοσής του.

Έτσι, για τους δύο αυτούς αλγορίθμους χρησιμοποιείται αποκλειστικά η τεχνική του TSCV, ώστε να μπορούν να έχουν πιο ακριβείς προβλέψεις σε πιο σύνθετα δεδομένα χρονοσειρών. Επίσης, γίνεται χρήση TSCV και για τους αλγορίθμους XGBoost και LM στο σύνολο εκπαίδευσης για την βελτιστοποίηση των υπερπαραμέτρων τους. Το πλήθος των υποσυνόλων TSCV διαφέρει ανάλογα τον αλγόριθμο.

4.3.1 Πρώτη Κατηγορία Υλοποίησης (Holt Winters - SARIMA)

Στα υποσύνολα δεδομένων A1A και A1C, τα οποία αποτελούνται κυρίως από στάσιμες χρονοσειρές, δεν χρησιμοποιήθηκε η TSCV. Η εφαρμογή της περιορίστηκε στα υποσύνολα A1B, όπου παρατηρείται αλλαγή μετατόπισης, και A1D, όπου υπάρχει τάση στα δεδομένα. Στο A1B, χρησιμοποι-

ήθηκαν τρία υποσύνολα TSCV, καθώς οι μετατοπίσεις του επιπέδου δεν είναι πολλές και κυριαρχεί η στασιμότητα. Στο A1D, χρησιμοποιήθηκαν εικοσιπέντε υποσύνολα TSCV, με στόχο να επιτρέψουν στους αλγορίθμους να αντιληφθούν επαρκώς την τάση των χρονοσειρών. Η μεγάλη διαφορά στον αριθμό των υποσυνόλων οφείλεται κυρίως στην ανάγκη για καλύτερη προσαρμογή των αλγορίθμων στις τάσεις.

Αλγόριθμοι	Υπερπαραμέτροι	Σύνολο Δεδομένων
HWEST	trend = "none" "add" seasonal = "add" seasonal_periods = 24, 48	A1A, A1B, A1C, NYC Taxi A1D Όλα τα σύνολα δεδομένων Yahoo A1, NYC Taxi
SARIMA	p, q = [1, 2], [1, 2] d = 0 1 P, D, Q, m = 1, 1, 1, 24	Yahoo A1 A1A, A1B, A1C A1D Yahoo A1
	p, d, q, P, D, Q, m = 2, 0, 1, 2, 1, 1, 48	NYC Taxi

Πίνακας 4.2: Τιμές των υπερπαραμέτρων για τους αλγορίθμους HWEST και SARIMA στα σύνολα δεδομένων.

Σε όλα τα σύνολα δεδομένων, όπως φαίνεται στον Πίνακα 4.2, για την εκθετική εξομάλυνση Holt-Winters (HWEST) χρησιμοποιήθηκε *προσθετική* εποχικότητα και τάση (η τάση χρησιμοποιήθηκε μόνο στο A1D, ενώ στα υπόλοιπα υποσύνολα είχε μηδενική τιμή). Η μεταβλητή περιόδων εποχικότητας ορίστηκε σε 24 για τα δεδομένα Yahoo και σε 48 για το NYC Taxi. Η επιλογή της προσθετικής εποχικότητας έναντι της πολλαπλασιαστικής οφείλεται σε τεχνικούς περιορισμούς. Συγκεκριμένα, τα δεδομένα Yahoo A1 περιλαμβάνουν χρονοσειρές με μηδενικές και αρνητικές τιμές, γεγονός που καθιστά την πολλαπλασιαστική εποχικότητα αντιπαραγωγική. Επιπλέον, η εποχικότητα στα δεδομένα έχει σταθερό εύρος και δεν εξαρτάται από το επίπεδο της χρονοσειράς, δηλαδή δεν μεταβάλλεται με την πάροδο του χρόνου. Η επιλογή της προσθετικής εποχικότητας εξασφαλίζει συνοχή με τον αλγόριθμο SARIMA, ο οποίος επίσης βασίζεται σε προσθετική εποχικότητα.

Για τον αλγόριθμο SARIMA, στα δεδομένα Yahoo, λόγω του μεγάλου αριθμού χρονοσειρών, γίνεται η παραδοχή ότι οι παράμετροι P, D, Q είναι σταθερές, λόγω της σταθερής εποχικότητας των χρονοσειρών, με $m = 24$ (ημερήσια εποχικότητα). Για τις παραμέτρους p και q, πραγματοποιήθηκε αναζήτηση πλέγματος για την εύρεση των τιμών που ελαχιστοποιούν το Μέσο Απόλυτο Σφάλμα (MAE). Η παράμετρος διαφοροποίησης τάσης (d) ορίστηκε σε 1 μόνο στο A1D, όπου οι χρονοσειρές παρουσιάζουν τάση.

Για το σύνολο δεδομένων NYC Taxi, το οποίο αποτελεί μετρίου μεγέθους χρονοσειρά (11.000 χρονικές στιγμές), η χρήση ενός μεγάλου αριθμού υποσυνόλων TSCV είναι ανέφικτη λόγω της υψηλής απαίτησης σε μνήμη (RAM). Για τον λόγο αυτό, η TSCV εφαρμόστηκε μόνο στο τελευταίο 70% της χρονοσειράς, με 20 υποσύνολα, όπου το μέγεθος της δοκιμής ήταν 200 χρονικές στιγμές. Για τον

αλγόριθμο SARIMA, λόγω της υψηλής υπολογιστικής πολυπλοκότητας της αναζήτησης πλέγματος, χρησιμοποιήθηκαν τα διαγράμματα ACF και PACF για την εύρεση των παραμέτρων. Το PACF ήταν σαφές για την εύρεση των q και Q , ενώ το ACF δεν ήταν τόσο κατατοπιστικό για τα p και P . Ωστόσο, εμπειρικά διαπιστώθηκε ότι διαφορές κατά 1 στις τιμές των υπερπαραμέτρων p , P δεν οδηγούσαν σε σημαντική μείωση του σφάλματος MAE, οπότε επιλέχθηκαν συγκεκριμένες.

Σε γενικές γραμμές, η χρήση TSCV συνέβαλε στη βελτίωση της γενίκευσης των στατιστικών αλγορίθμων στα δεδομένα, ωστόσο συνοδεύτηκε από σημαντική αύξηση της υπολογιστικής πολυπλοκότητας, επηρεάζοντας αρνητικά την αποδοτικότητά τους.

4.3.2 Δεύτερη Κατηγορία Υλοποίησης (XGBoost, LM)

Για τους αλγόριθμους XGBoost και το γραμμικό μοντέλο (LM), στο σύνολο εκπαίδευσης πραγματοποιήθηκε αναζήτηση πλέγματος με χρήση TSCV (2 υποσυνόλων) για την εύρεση των βέλτιστων υπερπαραμέτρων ως προς το MAE. Στη συνέχεια, τα μοντέλα αξιολογήθηκαν στο σύνολο δοκιμής. Για τον XGBoost, οι υπερπαραμέτροι που χρησιμοποιήθηκαν παρουσιάζονται στον Πίνακα 4.3.

Υπερπαραμέτρος	Λειτουργία	Τιμές
n_estimators	Αριθμός των δέντρων στο σύνολο	50
learning_rate	Ρυθμός μάθησης, ελέγχει τη συνεισφορά κάθε δέντρου	0.01, 0.1, 0.2
max_depth	Μέγιστο βάθος κάθε δέντρου, ελέγχει την πολυπλοκότητα του αλγορίθμου	3, 5, 7
reg_alpha	Παράμετρος L1 κανονικοποίησης (Lasso)	0, 0.1, 0.5
reg_lambda	Παράμετρος L2 κανονικοποίησης (Ridge)	1, 1.5, 2
lagged_values	προηγούμενες τιμές της χρονοσειράς για κατανόηση εξαρτήσεων από το μοντέλο	3

Πίνακας 4.3: Λειτουργία και τιμές των υπερπαραμέτρων του XGBoost.

Η χρήση του $n_estimators=50$ επιλέχθηκε εμπειρικά, καθώς η χρήση παραπάνω δέντρων στο σύνολο (*ensemble*), δεν βελτιώνει την απόδοση του αλγορίθμου, ενώ ταυτόχρονα μειώνεται η πολυπλοκότητα της αναζήτησης πλέγματος. Για όλες τις υπόλοιπες υπερπαραμέτρους επιλέχθηκαν αρκετές τιμές, ώστε να βρεθεί αυτή που ελαχιστοποιεί το μέσο απόλυτο σφάλμα MAE.

Μια κοινή υπερπαραμέτρος και για τους δύο αλγορίθμους είναι η χρήση προηγούμενων τιμών

της χρονοσειράς (υστερήσεων - lags). Για το γραμμικό μοντέλο, οι προηγούμενες τιμές χρησιμοποιήθηκαν ως παρατηρήσεις εξαρτημένων μεταβλητών, ενώ για τον XGBoost, χρησιμοποιήθηκαν ως χαρακτηριστικά. Ο αριθμός των προηγούμενων τιμών ορίστηκε σε 3, καθώς σε όλα τα σύνολα δεδομένων (Yahoo A1 και NYC Taxi), οι πρώτες τρεις προηγούμενες τιμές είχαν την υψηλότερη αυτοσυσχέτιση. Η επιλογή αυτή έγινε για να διατηρηθεί η απλότητα των μοντέλων και να αποφευχθεί η πολυσυγγραμμικότητα, η οποία μπορεί να κάνει τις εκτιμήσεις των συντελεστών ασταθείς.

4.3.3 Τρίτη Κατηγορία Υλοποίησης (Νευρωνικά Δίκτυα)

Όπως φαίνεται στον Πίνακα 4.4 στα νευρωνικά δίκτυα, οι υπερπαράμετροι επιλέχθηκαν με βάση την απόδοση, την υπολογιστική πολυπλοκότητα και την ικανότητα γενίκευσης του μοντέλου. Η χρήση του Adam ως βελτιστοποιητή οφείλεται στην αποτελεσματικότητά του στη διαχείριση ρυθμών μάθησης και στην ταχεία σύγκλιση και ως του πιο συνήθους χρησιμοποιημένου βελτιστοποιητή σε ακαδημαϊκές εργασίες. Η επιλογή 2 στρωμάτων είναι μια ισορροπία μεταξύ πολυπλοκότητας και απλότητας, καθώς περισσότερα στρώματα μπορεί να οδηγήσουν σε υπερεκπαίδευση, ενώ λιγότερα μπορεί να μην αρκούν για την αναπαράσταση των δεδομένων. Το μέγεθος παρτίδας 32 είναι ένας συμβιβασμός μεταξύ σταθερότητας (μικρές παρτίδες) και ταχύτητας (μεγάλες παρτίδες), ενώ οι 75 εποχές επιλέχθηκαν για να εξασφαλιστεί επαρκής εκπαίδευση χωρίς υπερβολική υπολογιστική φόρτωση. Αυτές οι επιλογές βασίζονται σε πειραματικές δοκιμές για βέλτιστη απόδοση. Επίσης, για όλα τα νευρωνικά δίκτυα (MLP, LSTM, AE) επιλέχθηκε κυλιόμενο παράθυρο εισόδου μεγέθους 24, ώστε αφενός να καλύπτεται πλήρως η ημερήσια εποχικότητα (ασθενής ή ισχυρή) των χρονοσειρών και αφετέρου να εξασφαλίζεται η παροχή επαρκούς ιστορικού πλαισίου στο μοντέλο, όπως απαιτείται για την επεξεργασία σειριακών δεδομένων. Για το σύνολο δεδομένων Yahoo A1 χρησιμοποιείται παράθυρο 24 ωρών, ενώ για το NYC Taxi, όπου η εποχικότητα εμφανίζεται ανά μισή ώρα, επιλέγεται παράθυρο μήκους 48 ώστε να καλύπτεται πλήρως ο ημερήσιος κύκλος.

Επειδή το LSTM, το οποίο είναι το πιο σύνθετο από τα τρία χρησιμοποιούμενα νευρωνικά δίκτυα, ενδέχεται να παρουσιάσει φαινόμενα υπερεκπαίδευσης (*overfitting*) ή υποεκπαίδευσης (*underfitting*) — κυρίως λόγω του σχετικά μικρού μεγέθους του συνόλου εκπαίδευσης — κρίθηκε απαραίτητη η ενσωμάτωση τεχνικών τακτοποίησης της εκπαίδευσης. Για τον σκοπό αυτό εφαρμόστηκε η μέθοδος *early stopping*, η οποία παρακολουθεί την απόδοση του μοντέλου στο επικυρωτικό σύνολο (*validation set*) κατά τη διάρκεια της εκπαίδευσης.

Συγκεκριμένα, επιλέχθηκε να παρακολουθείται η τιμή της απώλειας, η οποία υπολογίζεται συγκρίνοντας τις προβλεπόμενες τιμές ($\hat{y}$) με τις πραγματικές τιμές (y) μέσω μιας συνάρτησης απώλειας (στην συγκεκριμένη περίπτωση το MAE) στο επικυρωτικό σύνολο (*val_loss*), και να διακόπτεται η εκπαίδευση, εάν δεν παρατηρηθεί βελτίωση για 50 συνεχόμενες εποχές (*patience*). Παράλληλα, ορίστηκε το μοντέλο να επαναφέρει αυτόματα τα βάρη που αντιστοιχούν στη βέλτιστη απόδοση στο *validation set*, διασφαλίζοντας ότι το τελικό μοντέλο δεν θα βασίζεται σε υπερπροσαρμοσμένες ή υποβαθμισμένες εκδόσεις των παραμέτρων του.

Αλγόριθμος	Υπερπαράμετρος	Λειτουργία
Πολυστρωματικό Perceptron (MLP)	Αριθμός κρυμμένων στρωμάτων	2
	Νευρώνες σε κάθε στρώμα	16, 16
	Συνάρτηση Ενεργοποίησης	ReLU
	Βελτιστοποιητής, Συνάρτηση Απώλειας	Adam, MAE
	Μέγεθος Παρτίδας, Εποχές	32, 75
Δίκτυο Μακράς Βραχύχρονης Μνήμης (LSTM)	Αρχιτεκτονική	2 στοιβαγμένα LSTM στρώματα
	Νευρώνες σε κάθε στρώμα	4, 4
	Βελτιστοποιητής, Συνάρτηση Απώλειας	Adam, MAE
	Μέγεθος Παρτίδας, Εποχές	32, 75
Αυτοκωδικοποιητής (AE)	Αρχιτεκτονική	2 στρώματα κωδικοποίησης (32,16) και 2 στρώματα αποκωδικοποίησης (16,32)
	Συνάρτηση Ενεργοποίησης	ReLU για κωδικοποιητή και αποκω- δικοποιητή, γραμμική για την έξοδο
	Βελτιστοποιητής, Συνάρτηση Απώλειας	Adam, MAE
	Μέγεθος Παρτίδας, Εποχές	32, 75

Πίνακας 4.4: Υπερπαράμετροι και Λειτουργίες των Νευρωνικών Δικτύων της Ομάδας II.

Για κάθε αλγόριθμο της Ομάδας II, οι ανωμαλίες υπολογίζονται μέσω στατικού ή δυναμικού ορίου. Σε όλους τους αλγορίθμους, για κάθε πρόβλεψη στο σύνολο δοκιμής, υπολογίζεται η απόλυτη διαφορά της πρόβλεψης, έναντι της πραγματικής τιμής ($\hat{e}(t_i) = |\hat{y}(t_i) - y(t_i)|$), για όλες τις χρονικές στιγμές t_i . Ο μοναδικός αλγόριθμος για τον οποίο χρησιμοποιείται διαφορετική μέθοδος, είναι ο Αυτοκωδικοποιητής, ο οποίος εξαιτίας της χρήσης κυλιόμενου παραθύρου, ανακατασκευάζει όλα τα δεδομένα του παραθύρου και δεν κάνει πρόβλεψη, οπότε χρειάζεται κάθε φορά να λαμβάνεται το μέσο απόλυτο σφάλμα του παραθύρου, MAE ($\hat{e} = \frac{1}{N} \sum_{i=1}^N |\hat{y}(t_i) - y(t_i)|$). Με αυτόν τον τρόπο προκύπτουν σφάλματα σε κάθε χρονική στιγμή του συνόλου δοκιμής των χρονοσειρών.

4.3.4 Στατικό Όριο

Για την δημιουργία του στατικού ορίου (*static threshold*), υπολογίζεται η μέση τιμή και η διασπορά όλων των σφαλμάτων του συνόλου δοκιμής, τα οποία αντιπροσωπεύονται ως διάνυσμα e .

$$threshold = mean(e) + k * std(e),$$

όπου $mean(e)$ είναι η μέση τιμή και $std(e)$ είναι η τυπική απόκλιση των σφαλμάτων. Το k είναι μια σταθερά που καθορίζει πόσες τυπικές αποκλίσεις μακριά από τον μέσο όρο όριζεται το όριο. Η τιμή

του k επιλέγεται ανάλογα με την εφαρμογή και την αυστηρότητα του ορίου. Σχετίζεται άμεσα με την κανονική κατανομή (*normal distribution*) και τον εμπειρικό κανόνα (*empirical rule*). Για παράδειγμα, αν $k = 3$, αυτό σημαίνει ότι το 99.7% των δεδομένων βρίσκεται εντός τριών τυπικών αποκλίσεων ($\pm 3\sigma$) από τον μέσο όρο. Αν $k = 2$, το 95%, αν $k = 1$, το 68%. Προφανώς, όσο μεγαλύτερο είναι το k , τόσο πιο αυστηρό είναι το όριο.

4.3.5 Δυναμικό Όριο

Το δυναμικό όριο (*dynamic threshold*) βασίζεται στη χρήση ενός κυλιόμενου παραθύρου μεγέθους W . Για κάθε υπακολουθία που προκύπτει από το κυλιόμενο παράθυρο, υπολογίζεται ένα όριο χρησιμοποιώντας τον τύπο του στατικού ορίου. Αυτή η προσέγγιση επιτρέπει στο όριο να προσαρμόζεται δυναμικά στις αλλαγές στην τάση, στην εποχικότητα και στις μετατοπίσεις της χρονοσειράς, προσφέροντας καλύτερη ανταπόκριση σε μη στάσιμες συνθήκες.

Αυτή η ιδέα πάρθηκε από την εργασία του Khanin Arthur [4], του αρχηγού της ομάδας Μηχανικής Μάθησης στην εταιρεία Akvelon, ο οποίος σύγκρινε το στατικό και το δυναμικό όριο για τους αλγορίθμους SARIMA, CNN (Συνελικτικό Νευρωνικό Δίκτυο) και LSTM σε χρονοσειρές του NAB, οι οποίες παρουσίαζαν αλλαγές μετατόπισης. Τα αποτελέσματα της εργασίας του έδειξαν ότι το δυναμικό όριο προσφέρει σημαντικά καλύτερες επιδόσεις από το στατικό. Αν και η δημοσίευση του Arthur δεν ανήκει σε ακαδημαϊκό περιοδικό, η ιδέα είναι αρκετά ενδιαφέρουσα και αξίζει να εξεταστεί σε χρονοσειρές όπως αυτές του Yahoo A1, οι οποίες παρουσιάζουν ποικίλα χαρακτηριστικά.

Επειδή οι χρονοσειρές του Yahoo A1 έχουν ποικίλη φύση, χρησιμοποιήθηκαν οι εξής τιμές $k = [1.5, 2, 2.5, 3]$ για το στατικό όριο. Για το δυναμικό όριο, χρησιμοποιήθηκαν συνδυασμοί των παραπάνω τιμών k με διαφορετικά μεγέθη κυλιόμενου παραθύρου $W = [100, 200, 300, 500]$, με τις βέλτιστες τιμές να βρίσκονται μέσω του αλγορίθμου grid-search, με βάση τη βαθμολογία F1. Στην περίπτωση του συνόλου δεδομένων NYC Taxi, η οποία είναι αρκετά γνωστή και χαρακτηρίζεται από χαμηλό θόρυβο, δεν χρησιμοποιήθηκε δυναμικό όριο. Αντίθετα, εφαρμόστηκε ένα αυστηρό στατικό όριο με $k = 3$, το οποίο θεωρήθηκε κατάλληλο για την ανίχνευση ανωμαλιών σε αυτή τη χρονοσειρά.

4.4 Μετρικές Αξιολόγησης

Για την ορθή αξιολόγηση των μεθόδων εύρεσης ανωμαλιών σε χρονοσειρές μιας μεταβλητής, έγινε χρήση των παρακάτω μετρικών αξιολόγησης:

4.4.1 Ακρίβεια

Η Ακρίβεια (*Precision*) ορίζεται ως η αναλογία των σωστά ταξινομημένων παρατηρήσεων σε σχέση με το σύνολο των σωστά και λάθος ταξινομημένων παρατηρήσεων από τη θετική κλάση:

$$\text{Ακρίβεια} = \frac{TP}{TP + FP}.$$

4.4.2 Ανάκληση/Ευαισθησία

Η Ανάκληση (*Recall*) ορίζεται ως η αναλογία των σωστά ταξινομημένων παρατηρήσεων σε σχέση με το σύνολο των σωστά ταξινομημένων παρατηρήσεων από τη θετική κλάση καθώς και των ψευδώς αρνητικών περιπτώσεων

$$\text{Ανάκληση} = \frac{TP}{TP + FN},$$

όπου:

- True Positives (TP): Ο αριθμός των ανωμαλιών που έχουν ανιχνευτεί σωστά ως ανωμαλίες.
- False Positives (FP): Ο αριθμός των δεδομένων που έχουν επισημανθεί από τον αλγόριθμο ως ανωμαλίες, αν και στην πραγματικότητα είναι κανονικές περιπτώσεις.
- False Negatives (FN): Ο αριθμός των ανωμαλιών που δεν έχουν ανιχνευτεί.

Με λίγα λόγια, στην ανίχνευση ανωμαλιών η Ακρίβεια εκφράζει από όλα τα δεδομένα που το μοντέλο χαρακτήρισε ως ανωμαλίες, πόσα ήταν πραγματικά ανωμαλίες και η Ανάκληση από όλες τις πραγματικές ανωμαλίες στο σύνολο δεδομένων, πόσες ανίχνευσε το μοντέλο.

4.4.3 Βαθμολογία F1

Ως Βαθμολογία F1 (*F1 Score*) ορίζεται ο αρμονικός μέσος της Ανάκλησης και της Ακρίβειας.

$$\text{Βαθμολογία } F1 = 2 \cdot \frac{\text{Ακρίβεια} \cdot \text{Ανάκληση}}{\text{Ακρίβεια} + \text{Ανάκληση}}.$$

Οι παραπάνω μετρικές θα χρησιμοποιηθούν για την αξιολόγηση των μεθόδων στο σύνολο δεδομένων Yahoo! Webscope (S5). Για το NYC Taxi σύνολο δεδομένων του NAB, επειδή οι ανωμαλίες είναι σε μορφή παραθύρων, δηλαδή η διάρκειά τους είναι για πολλές συνεχόμενες χρονικές στιγμές, οι παραπάνω μετρικές δεν αρκούν για την ορθή αξιολόγηση των αλγορίθμων. Οπότε γίνεται η χρήση μιας νέας μετρικής, η οποία προτάθηκε από τους δημιουργούς του NAB συνόλου δεδομένων στην εργασία τους [44].

4.4.4 Βαθμολογία NAB

Δοθέντος ενός παραθύρου ανωμαλίας, η βαθμολογία NAB (*NAB Score*) χρησιμοποιεί μια σιγμοειδή υπολογιστική συνάρτηση, ώστε να αποδώσει βάρη στις εντοπισμένες ανωμαλίες ανάλογα με τη χρονική τους θέση εντός του παραθύρου. Η συνάρτηση έχει τη μορφή:

$$\sigma^{\mathbf{A}}(y) = (A_{TP} - A_{FP}) \left(\frac{1}{1 + e^{5y}} \right) - 1,$$

όπου $y \in [-1, 1]$ είναι η σχετική θέση της ανωμαλίας μέσα στο παράθυρο: η αρχή του παραθύρου αντιστοιχεί στο $y = -1$, ενώ το τέλος στο $y = 0$. Η παράμετρος $\mathbf{A}$ αναφέρεται στο προφίλ εφαρμογής (*application profile*), το οποίο καθορίζει τα βάρη:

$$\mathbf{A} = (A_{TP}, A_{FP}, A_{FN}),$$

αντίστοιχα για τα *True Positives*, *False Positives* και *False Negatives*. Τα βάρη ικανοποιούν τους περιορισμούς:

$$0 \leq A_{TP} \leq 1, \quad -2 \leq A_{FN}, A_{FP} \leq 0.$$

Η παραπάνω συνάρτηση σχεδιάστηκε έτσι ώστε το άκρο του παραθύρου ($y = 0$) να αντιστοιχεί σε μηδενική συνεισφορά ($\sigma^{\mathbf{A}}(0) = 0$), ενώ οι εντοπισμοί κοντά στην αρχή του παραθύρου ($y \approx -1$) αποδίδουν σχεδόν τη μέγιστη βαθμολογία A_{TP} , και οι καθυστερημένες εντοπίσεις (εκτός παραθύρου, $y > 0$) τιμωρούνται με αρνητική συνεισφορά που τείνει προς A_{FP} . Η σιγμοειδής μορφή της συνάρτησης εξασφαλίζει ομαλή μετάβαση μεταξύ αυτών των τιμών, με αυστηρότερη ποινή όσο πιο καθυστερημένος είναι ο εντοπισμός. Με αυτόν τον τρόπο, επιβραβεύεται η γρήγορη αντίδραση ενός αλγορίθμου.

Αθροιστικά, το μη επεξεργασμένο σκορ για κάθε αρχείο δεδομένων d προκύπτει ως

$$S_d^{\mathbf{A}} = \sum_{y \in Y_d} \sigma^{\mathbf{A}}(y) + A_{FN} f_d,$$

όπου το Y_d είναι το σύνολο των ανιχνεύσεων που εμπίπτουν στα αντίστοιχα παράθυρα ανωμαλίας του αρχείου d , με τη διευκρίνιση ότι κρατείται μόνο η πρώτη εντόπιση ανά παράθυρο, καθώς οι πολλαπλές ανιχνεύσεις θεωρούνται πλεονάζουσες. Ο όρος f_d εκφράζει τον αριθμό των παραθύρων ανωμαλίας που δεν εντοπίστηκαν καθόλου από τον αλγόριθμο (false negatives), ενώ η συνάρτηση $\sigma^{\mathbf{A}}(y)$ αποδίδει το βάρος της κάθε ανίχνευσης, ανάλογα με τη χρονική της θέση εντός του παραθύρου, επηρεασμένη από τις παραμέτρους του εκάστοτε προφίλ εφαρμογής.

Η τελική βαθμολογία ενός αλγορίθμου ως προς ένα συγκεκριμένο προφίλ χρήσης προκύπτει από το άθροισμα όλων των $S_d^{\mathbf{A}}$ για κάθε αρχείο $d \in D$. Με αυτόν τον τρόπο, η αξιολόγηση λαμβάνει

υπόψη όχι μόνο το ποσοτικό πλήθος σωστών ή λανθασμένων εντοπισμών, αλλά και το *πότε* αυτοί συνέβησαν, κάτι ιδιαίτερα κρίσιμο σε εφαρμογές έγκαιρου εντοπισμού (π.χ. ανίχνευση βλαβών ή επιθέσεων).

Αξίζει να σημειωθεί ότι ο σχεδιασμός της συνάρτησης και η χρήση διαφορετικών προφίλ (όπως *standard*, *reward low FP*, *low FN*) επιτρέπουν την προσαρμογή του συστήματος αξιολόγησης σε διαφορετικά σενάρια προτεραιοτήτων, γεγονός που καθιστά τη βαθμολογία NAB μία από τις πιο εύλικτες και ολοκληρωμένες μετρικές στην αξιολόγηση ανιχνευτών ανωμαλιών.

Το NAB framework παρέχει τρία διαφορετικά προφίλ αξιολόγησης, ανάλογα με το ποια πτυχή της ανίχνευσης ανωμαλιών είναι σημαντικότερη: η γενική ισορροπία, η αποφυγή ψευδών συναγερμών ή η ελαχιστοποίηση μη εντοπισμένων ανωμαλιών. Τα προφίλ αυτά ορίζουν διαφορετικές τιμές για τις παραμέτρους A_{TP} , A_{FP} , A_{FN} :

- **Standard Profile:**

$$A_{TP} = 1.0, \quad A_{FP} = -0.11, \quad A_{FN} = -1.0.$$

Εξισορροπεί την ακρίβεια και την πληρότητα. Ιδανικό για γενικές περιπτώσεις.

- **Low False Positives (Low FP) Profile:**

$$A_{TP} = 1.0, \quad A_{FP} = -0.22, \quad A_{FN} = -1.0.$$

Δίνει μεγαλύτερη ποινή στα false positives, προτιμώντας αλγόριθμους που αποφεύγουν υπερυαισθητούς εντοπισμούς.

- **Low False Negatives (Low FN) Profile:**

$$A_{TP} = 1.0, \quad A_{FP} = -0.11, \quad A_{FN} = -2.0.$$


Τιμωρεί αυστηρά τους μη εντοπισμένους συναγερμούς (false negatives), δίνοντας έμφαση στην ευαισθησία του συστήματος.

Σε όλα τα προφίλ, η συνάρτηση $\sigma^A(y)$ αποδίδει:

- **Θετική τιμή** για έγκαιρη ανίχνευση εντός παραθύρου.
- **Αρνητική τιμή** για καθυστερημένη ανίχνευση ή ψευδές alarm.
- **Σταθερή ποινή** ίση με A_{FN} για κάθε ανωμαλία που δεν εντοπίστηκε.

Η επιλογή προφίλ εξαρτάται από τις απαιτήσεις της εφαρμογής. Για παράδειγμα, σε ένα σύστημα υγείας προτιμάται το *Low FN*, ενώ σε περιβάλλον με μεγάλο κόστος ψευδών συναγερμών (π.χ. χρηματοοικονομικά) είναι καταλληλότερο το *Low FP*.

Από την έρευνα των Singh και Olinsky το 2017 [67], οι οποίοι ανέλυσαν τις ατέλειες στην υπολογιστική σιγμοειδή συνάρτηση του NAB προκύπτει ότι υπάρχουν ορισμένα ζητήματα στην υλοποίηση της, όπως την παρουσιάζουν στην εργασία του NAB οι Lavin και Ahmad [44]. Συγκεκριμένα το πρόβλημα απεικονίζεται στο Διάγραμμα 4.4.



Διάγραμμα 4.4: Ενδεικτική λειτουργία της υπολογιστικής σιγμοειδούς συνάρτησης NAB. Πηγή: [44]

Στο Διάγραμμα 4.4 παρατηρείται ότι όσο πιο νωρίς βρεθεί η ανωμαλία στο παράθυρο, τόσο πιο πολύ προσεγγίζει το 1. Αν σε ένα παράθυρο εντοπιστούν παραπάνω από μια ανωμαλίες, η αμέσως επόμενη αγνοείται. Αν πριν από το παράθυρο (στα αριστερά) εντοπιστεί ανωμαλία, θεωρείται false positive (FP) και η συνάρτηση αποδίδει ποινή βάρους -1. Στην περίπτωση που βρεθεί ανωμαλία εκτός παραθύρου, αλλά προς τα δεξιά και λίγο πιο έξω, θεωρείται near-miss detection και αποδίδεται ελαφρύτερη ποινή. Τέλος, αν η ανωμαλία βρίσκεται αρκετά μακριά από το παράθυρο, πάλι αποδίδεται ποινή -1.

Το πρόβλημα έγκειται στο ότι καμία υπερπαραμετροποίηση που προτείνεται από την εργασία των Lavin και Ahmad [44] δεν αντιστοιχεί στο συγκεκριμένο παράδειγμα. Ωστόσο, μια ειδική παραμετροποίηση, η οποία παρατηρείται στο αρχείο GitHub του NAB [56], φαίνεται να ταιριάζει. Συγκεκριμένα το παράδειγμα είναι έγκυρο αν $A_{TP} - A_{FP} = 2$ και $A_{FN} = -1$. Επιπλέον, δουλεύοντας στο πλαίσιο (framework) του NAB, δεν είναι δυνατός ο προσδιορισμός των βέλτιστων υπερπαραμέτρων των μεθόδων εύρεσης ανωμαλιών μέσω της μεθόδου αναζήτησης πλέγματος. Λαμβάνοντας υπόψη όλα τα παραπάνω, δημιουργήθηκε μια διαφορετική εκδοχή της συνάρτησης NAB. Για την ακρίβεια, για την αξιολόγηση των αποτελεσμάτων, υλοποιήθηκαν οι συναρτήσεις **sigmoid**, **sigmoid_score**, **compute_raw_score_debug** και **create_anomaly_windows**.

Η συνάρτηση **sigmoid** χρησιμοποιείται ως βασικό δομικό στοιχείο για τον υπολογισμό του σκορ ανιχνεύσεων (*detection score*) μέσω της συνάρτησης **sigmoid_score**. Η λειτουργία της βασίζεται στη συμπίεση μιας αριθμητικής τιμής εντός του διαστήματος $[0, 1]$, γεγονός που την καθιστά κατάλληλη για προβλήματα ταξινόμησης, όπως είναι και η ανίχνευση ανωμαλιών (anomaly detection), η οποία μπορεί να διατυπωθεί ως πρόβλημα δυαδικής ταξινόμησης μη ισορροπημένων κατηγοριών. Η sigmoid

είναι ιδιαίτερα χρήσιμη, καθώς προσφέρει μια ομαλή και συνεχώς μεταβαλλόμενη έξοδο, διευκολύνοντας έτσι την αξιολόγηση της συμπεριφοράς του συστήματος ανίχνευσης.

Η συνάρτηση **sigmoid_score** χρησιμοποιεί τη sigmoid συνάρτηση για να υπολογίσει ένα σκορ που εκφράζει την ποιότητα μιας ανίχνευσης, με βάση τη σχετική θέση της y ως προς ένα προκαθορισμένο παράθυρο ανωμαλίας (*anomaly window*). Η τιμή της παραμέτρου y καθορίζει τη χρονική απόσταση της ανίχνευσης από το παράθυρο:

- Αν $y \leq 0$, η ανίχνευση βρίσκεται εντός ή ακριβώς στα αριστερά του παραθύρου.
- Αν $0 < y \leq 3.0$, η ανίχνευση θεωρείται *near-miss*, δηλαδή βρίσκεται κοντά στο παράθυρο.
- Αν $y > 3.0$, η ανίχνευση είναι πολύ μακριά από το παράθυρο.

Η **sigmoid_score** συνάρτηση εφαρμόζει μια κλιμακωμένη έκδοση της sigmoid για τον υπολογισμό του σκορ ως εξής:

$$\text{sigmoid_score}(y) = \begin{cases} -1.0, & \text{αν } y > 3.0 \\ & (\text{πολύ μεγάλη ποινή για μακρινές ανιχνεύσεις}), \\ 2 \cdot \left(\frac{1}{1 + e^{5y}} \right) - 1.0, & \text{αν } y \leq 3.0 \\ & (\text{κλιμακωμένη τιμή μεταξύ } -1.0 \text{ και } 1.0). \end{cases}$$

Η επιλογή του συντελεστή 5 στην εκθετική συνάρτηση της sigmoid συνάρτησης δεν αιτιολογείται από τους Lavin και Ahmad [44], ωστόσο παρέχει μια απότομη πτώση του σκορ εκτός παραθύρου, τονίζοντας τη σημασία του εντοπισμού εντός ή πλησίον της περιοχής ανωμαλίας. Η κλιμάκωση της sigmoid συνάρτησης επιτρέπει τη διαφοροποίηση της βαθμολόγησης, ώστε να λαμβάνονται υπόψη σενάρια όπως οι ανιχνεύσεις κοντά αλλά εκτός του παραθύρου, προσδίδοντας ευελιξία στην αξιολόγηση μέσω ποινών ή ανταμοιβών ανάλογα με την ακρίβεια της ανίχνευσης.

Η συνάρτηση **compute_raw_score_debug** χρησιμοποιεί την **sigmoid_score** συνάρτηση για να υπολογίσει το συνολικό σκορ ενός συστήματος ανίχνευσης, λαμβάνοντας υπόψη την απόσταση κάθε ανίχνευσης από τα πραγματικά παράθυρα ανωμαλιών. Επιπλέον, η συνάρτηση υποστηρίζει αναλυτική εκτύπωση (debugging), διευκολύνοντας την κατανόηση της επίδρασης κάθε μεμονωμένης ανίχνευσης στο τελικό αποτέλεσμα, είτε αυτή είναι σωστή (true positive) είτε σφάλμα (false positive ή false negative). Η συγκεκριμένη συνάρτηση αποτελεί τον πυρήνα της διαδικασίας αξιολόγησης του συστήματος ανίχνευσης.

Παράλληλα, η συνάρτηση **create_anomaly_windows** εξυπηρετεί τη μετατροπή της λίστας των δυαδικών ετικετών (binary labels) σε μια λίστα παραθύρων ανωμαλιών. Κάθε παράθυρο ορίζεται ως

μια συνεχόμενη ακολουθία από τιμές 1, που αντιστοιχούν σε χρονικές περιόδους όπου παρατηρούνται ανωμαλίες. Η συνάρτηση επιστρέφει λίστα από πλειάδες (tuples), όπου κάθε πλειάδα περιλαμβάνει τους δείκτες έναρξης και λήξης του αντίστοιχου παραθύρου. Αυτή η διαδικασία είναι απαραίτητη, καθώς η παραγόμενη δομή μπορεί να αξιοποιηθεί από τη συνάρτηση **compute_raw_score_debug** για τον υπολογισμό του τελικού σκορ αξιολόγησης.

Κεφάλαιο 5

Αποτελέσματα και Συζήτηση

Στο κεφάλαιο αυτό παρουσιάζονται και αναλύονται τα αποτελέσματα των πειραμάτων που πραγματοποιήθηκαν για την ανίχνευση ανωμαλιών σε χρονοσειρές μονοδιάστατων δεδομένων. Η αξιολόγηση έγινε χρησιμοποιώντας δύο διαφορετικά σύνολα δεδομένων: το Yahoo A1, το οποίο χωρίζεται σε τέσσερις διακριτές ομάδες χρονοσειρών (A1A, A1B, A1C και A1D), και το NAB NYC Taxi σύνολο δεδομένων. Κάθε ομάδα στο σύνολο Yahoo παρουσιάζει διαφορετικά χαρακτηριστικά ανωμαλιών, όπως ακραίες τιμές, μετατόπιση μέσου όρου, συσσωρευμένες ανωμαλίες και υπό όρους. Στην ομάδα A1D, επιπλέον, εφαρμόστηκε γραμμική αποτασιοποίηση των δεδομένων για σύγκριση των επιδόσεων. Το σύνολο δεδομένων NYC Taxi αποτελείται από πέντε διαφορετικά παράθυρα ανωμαλιών, τα οποία είναι ανωμαλίες ακραίων σημείων που βασίζονται σε ημερομηνίες υψηλής ζήτησης ταξί.

Τα δεδομένα υποβλήθηκαν σε τυποποίηση ή κανονικοποίηση (ανάλογα την μέθοδο) πριν από την εφαρμογή των αλγορίθμων, ώστε να διασφαλιστεί δίκαιη σύγκριση. Οι αλγόριθμοι που αξιολογήθηκαν περιλαμβάνουν στατιστικές μεθόδους πρόβλεψης (Γραμμικό Μοντέλο (LM), Εκθετική Εξομάλυνση Holt-Winters (HWE), SARIMA, μεθόδους μηχανικής μάθησης (Δάσος Απομόνωσης (IF), Τοπικός Παράγοντας Αποκλίσεων (LOF), Μηχανή Διανυσμάτων Υποστήριξης (OCSVM), DBSCAN, Προφίλ Πίνακα (MP), XGBoost) και βαθιά νευρωνικά δίκτυα (Πολυεπίπεδο Perceptron (MLP), Δίκτυο Μακράς Βραχύχρονης Μνήμης (LSTM), Αυτοκωδικοποιητής (AE).

Ιδιαίτερη προσοχή δόθηκε στην αξιολόγηση της επίδρασης των χρονικών χαρακτηριστικών (temporal columns) στις μεθόδους μηχανικής μάθησης, τα οποία ανήκουν στην Ομάδα I, καθώς και στη σύγκριση στατικών και δυναμικών κατωφλίων (static vs dynamic thresholds) στις μεθόδους πρόβλεψης (Ομάδα II). Για την ποσοτική σύγκριση χρησιμοποιήθηκαν οι μετρικές Ακρίβειας, Ανάκλησης και Βαθμολογίας F1 για το σύνολο δεδομένων Yahoo A1, ενώ για το NYC Taxi προστέθηκε και η Βαθμολογία NAB. Η στατιστική σημαντικότητα των διαφορών αξιολογήθηκε με τον έλεγχο προσημασμένης διάταξης του Wilcoxon (*Wilcoxon Signed-Rank Test*). Τα αποτελέσματα απεικονίζονται μέσω ραβδογραμμάτων (*barplots*), διαγράμματα Ακρίβειας-Ανάκλησης (*Precision-Recall plots*) και θηκογραμμάτων (*boxplots*), προκειμένου να γίνει ευκολότερη η συγκριτική ανάλυση και να εξαχθούν

συμπεράσματα σχετικά με την αποτελεσματικότητα των μεθόδων.

Το κεφάλαιο διαρθρώνεται ως εξής: Αρχικά περιγράφεται ο Έλεγχος Προσημασμένης Διάταξης του Wilcoxon και μετά παρουσιάζεται η αναλυτική αξιολόγηση των αποτελεσμάτων για κάθε σύνολο δεδομένων (Yahoo και NYC Taxi) ξεχωριστά. Ακολουθεί συνοπτική παρουσίαση των κύριων ευρημάτων και συμπερασμάτων της ανάλυσης, ενώ τέλος αναφέρονται πιθανές βελτιώσεις και επεκτάσεις της παρούσας έρευνας, καθώς και προτάσεις για μελλοντική έρευνα.

5.0.1 Χρήση και Επιλογή του Ελέγχου Προσημασμένης Διάταξης του Wilcoxon

Για τη στατιστική σύγκριση των επιδόσεων των αλγορίθμων μεταξύ διαφορετικών εκδοχών των συνόλων δεδομένων επιλέχθηκε ο έλεγχος Προσημασμένης Διάταξης του Wilcoxon (*Wilcoxon Signed Ranked test*), ο οποίος προτάθηκε από τον Frank Wilcoxon το 1945 [79]. Πρόκειται για έναν μη παραμετρικό στατιστικό έλεγχο ο οποίος χρησιμοποιείται για τη σύγκριση δύο εξαρτημένων δειγμάτων ή ζευγών μετρήσεων, χωρίς την απαίτηση κανονικότητας στις διαφορές τους. Σε αντίθεση με το *t-test* για συζευγμένα δείγματα, το Wilcoxon εφαρμόζεται ιδανικά σε μικρά δείγματα ή σε περιπτώσεις όπου η κατανομή των διαφορών είναι άγνωστη ή μη κανονική — συνθήκες που συνήθως ισχύουν στην αξιολόγηση αλγορίθμων σε πολλαπλά σετ δεδομένων.

5.0.2 Μαθηματική Διατύπωση

Έστω δύο συσχετισμένα δείγματα

$$\mathbf{X} = \{X_1, X_2, \dots, X_n\} \quad \text{και} \quad \mathbf{Y} = \{Y_1, Y_2, \dots, Y_n\},$$

και έστω οι αντίστοιχες διαφορές

$$D_i = X_i - Y_i, \quad \text{για } i = 1, \dots, n.$$

Στη συνέχεια:

1. Υπολογίζονται οι απόλυτες τιμές $|D_i|$ και τους αποδίδονται τάξεις μεγεθών (*ranks*) σε αύξουσα σειρά.
2. Κάθε rank R_i λαμβάνει το πρόσημο της αντίστοιχης διαφοράς.
3. Υπολογίζονται τα αθροίσματα των θετικών και αρνητικών ranks:

$$W^+ = \sum_{\text{όπου } D_i > 0} R_i, \quad W^- = \sum_{\text{όπου } D_i < 0} R_i.$$

4. Το στατιστικό του ελέγχου είναι:

$$W = \min(W^+, W^-).$$

Το τεστ ελέγχει τη μηδενική υπόθεση:

$$H_0 : \text{Η διάμεσος των διαφορών } D_i \text{ είναι μηδέν}$$

(ή ισοδύναμα, $\mathbf{X}$ και $\mathbf{Y}$ προέρχονται από την ίδια κατανομή),

έναντι της εναλλακτικής:

$$H_1 : \text{Η διάμεσος των διαφορών διαφέρει από το μηδέν.}$$

Για μικρά δείγματα ($n \leq 25$), όπως και στην παρούσα διπλωματική εργασία, η κατανομή του στατιστικού W κάτω από το H_0 δεν προσεγγίζεται μέσω της κανονικής κατανομής αλλά προσδιορίζεται ακριβώς, με βάση το πλήθος όλων των πιθανών συνδυασμών προσήμων που μπορούν να αντιστοιχηθούν στις n κατατάξεις:

$$\mathbb{P}(W = w) = \frac{\text{Αριθμός τρόπων να προκύψει } W = w}{2^n}.$$

Οι πιθανότητες αυτές έχουν υπολογιστεί και καταγραφεί σε ειδικούς πίνακες (πίνακες κρίσιμων τιμών Wilcoxon). Η πιθανότητα το W να πάρει μια τιμή όσο και η παρατηρούμενη του ή πιο ακραία συγκρίνεται με την βοήθεια των πινάκων με το δεδομένο επίπεδο σημαντικότητας α του παραπάνω ελέγχου, ώστε να ληφθεί η απόφαση να απορριφθεί ή όχι η H_0 .

Στο πλαίσιο της παρούσας μελέτης, το τεστ χρησιμοποιείται για να αξιολογηθεί αν οι παρατηρούμενες αυξομειώσεις στις τιμές F1 Score για κάθε αλγόριθμο είναι στατιστικά σημαντικές όταν γίνεται μετάβαση από στατικά σε δυναμικά όρια, από σύνολα με τάση (A1D) σε αποτασιοποιημένα (A1DD) ή από εκδοχές με χρονικά χαρακτηριστικά (temp) σε εκδοχές χωρίς (no_temp). Αυτό προσδίδει παραπάνω αξιοπιστία στα ευρήματα, διαχωρίζοντας τις πραγματικά σημαντικές μεταβολές από εκείνες που ενδέχεται να οφείλονται σε τυχαία διακύμανση.

5.1 Ανάλυση Αποτελεσμάτων

Η ανάλυση των αποτελεσμάτων οργανώνεται σε δύο ξεχωριστές κατηγορίες για λόγους σαφήνειας και συστηματικότητας: στο πρώτο υποκεφάλαιο διερευνώνται τα ευρήματα για το σύνολο δεδομένων Yahoo A1, όπου εξετάζονται λεπτομερώς οι επιδόσεις των αλγορίθμων σε σχέση με τις ιδιαιτερότητες αυτών των χρονοσειρών, ενώ στο δεύτερο υποκεφάλαιο η έρευνα επικεντρώνεται στο σύνολο δεδομένων NYC Taxi, που έχει έντονη εποχικότητα και διακυμάνσεις στη ζήτηση (π.χ. αργίες, φυσικές καταστροφές), αλλά και παράθυρα ανωμαλιών (*anomaly windows*) που απαιτεί από τα

μοντέλα όχι μόνο να ανιχνεύουν αποκλίσεις, αλλά να το κάνουν εντός συγκεκριμένου χρονικού περιθωρίου. Αυτή η διαχωριστική προσέγγιση επιτρέπει μια πιο εστιασμένη και ουσιαστική ερμηνεία των αποτελεσμάτων για κάθε τύπο δεδομένων ξεχωριστά.

5.1.1 Σύνολο Δεδομένων Yahoo A1

A1A							A1B						
Ομάδα I							Ομάδα I						
	temp			no_temp				temp			no_temp		
	P	R	F1	P	R	F1		P	R	F1	P	R	F1
IF	0.62	0.96	0.68	0.66	0.93	0.71	IF	0.37	0.74	0.41	0.18	0.48	0.20
LOF	0.55	0.82	0.62	0.65	0.95	0.72	LOF	0.48	0.53	0.44	0.14	0.25	0.14
OCSVM	0.23	0.41	0.26	0.39	0.76	0.46	OCSVM	0.39	0.53	0.43	0.16	0.46	0.17
DBSCAN	0.41	0.93	0.51	0.80	0.94	0.82	DBSCAN	0.34	0.61	0.40	0.48	0.12	0.17
	P		R		F1			P		R		F1	
MP	0.41		0.83		0.48		MP	0.49		0.52		0.47	
Ομάδα II							Ομάδα II						
	static			dynamic				static			dynamic		
	P	R	F1	P	R	F1		P	R	F1	P	R	F1
AE	0.28	0.46	0.30	0.21	0.54	0.27	AE	0.45	0.45	0.43	0.57	0.52	0.53
MLP	0.51	0.88	0.60	0.33	0.86	0.45	MLP	0.42	0.39	0.35	0.42	0.50	0.43
LSTM	0.58	0.90	0.63	0.29	0.87	0.41	LSTM	0.37	0.31	0.25	0.41	0.51	0.43
XGboost	0.71	0.96	0.75	0.32	0.92	0.44	XGboost	0.33	0.29	0.22	0.31	0.51	0.36
LM	0.56	0.85	0.62	0.36	0.85	0.48	LM	0.30	0.21	0.18	0.22	0.31	0.22
SARIMA	0.70	0.84	0.70	0.31	0.89	0.49	SARIMA	0.28	0.11	0.28	0.32	0.56	0.46
HWEST	0.71	0.84	0.71	0.37	0.89	0.49	HWEST	0.30	0.07	0.27	0.37	0.45	0.46
A1A σύνολο							A1B σύνολο						

Πίνακας 5.1: Αποτελέσματα μέσης Ακρίβειας (P), μέσης Ανάκλησης (R) και μέσης Βαθμολογίας F1 για τα σύνολα δεδομένων A1A και A1B.

Οι αλγόριθμοι είναι χωρισμένοι σε τέσσερις κατηγορίες. Οι δύο κατηγορίες προέρχονται από τους αλγορίθμους μηχανικής μάθησης της Ομάδας I και οι άλλες δύο από τους προβλεπτικούς αλγορίθμους της Ομάδας II, οι οποίες αναφέρθηκαν στο Κεφάλαιο 4.3. Οι αλγόριθμοι μηχανικής μάθησης με χρονικά χαρακτηριστικά λαμβάνουν στο τέλος την κατάληξη (`_temp`), από το "temporal", ενώ οι αλγόριθμοι χωρίς αυτά, λαμβάνουν στο τέλος την κατάληξη (`_no_temp`). Εξαιρείται ο αλγόριθμος Προφίλ Πίνακα (MP), ο οποίος δεν μπορεί να δεχθεί χρονικά χαρακτηριστικά. Οι προβλεπτικοί αλγόριθμοι, αν έχουν εφαρμοσθεί με στατικό όριο, παίρνουν την κατάληξη (`_static`), ενώ, αν έχουν εφαρμοσθεί με δυναμικό, παίρνουν την κατάληξη (`_dynamic`).

Επιπλέον, για κάθε σύνολο δεδομένων υπολογίστηκαν χωριστά οι μέσες τιμές της Ακρίβειας, της Ανάκλησης και της Βαθμολογίας F1 για κάθε αλγόριθμο, αντί να προκύψει η μέση F1 ως συνάρτηση

του μέσου όρου της Ακρίβειας και της Ανάκλησης. Ο λόγος για αυτήν την επιλογή έγκειται στο γεγονός ότι η Βαθμολογία F1, ως αρμονικός μέσος των δύο αυτών μετρικών, δεν είναι ούτε γραμμική ούτε συμμετρική ως προς τις συνιστώσες της. Η F1 είναι σχεδιασμένη ώστε να «τιμωρεί» μεγάλες αποκλίσεις μεταξύ Ακρίβειας και Ανάκλησης, δίνοντας χαμηλότερη τιμή όταν οι δύο διαφέρουν σημαντικά. Συνεπώς, αν πρώτα υπολογιστεί ο μέσος όρος της Ακρίβειας και ο μέσος όρος της Ανάκλησης για ένα σύνολο χρονοσειρών και στη συνέχεια εφαρμοστεί ο τύπος του αρμονικού μέσου, το αποτέλεσμα που προκύπτει δεν θα είναι ισοδύναμο με τον πραγματικό μέσο όρο των επιμέρους F1 βαθμολογιών ανά αλγόριθμο. Για τον λόγο αυτό, η αξιολόγηση πραγματοποιήθηκε με βάση τον μέσο όρο των ήδη υπολογισμένων F1-score ανά χρονοσειρά.

Η σύγκριση των αποτελεσμάτων στον Πίνακα 5.1 για τα σύνολα A1A και A1B αποκαλύπτει ξεκάθαρες διαφοροποιήσεις ανάμεσα στους αλγόριθμους, τις ομάδες, αλλά και τις κατηγορίες πειραματικών συνθηκών. Στο σύνολο A1A του Yahoo Webscope S5, το οποίο περιλαμβάνει 13 χρονοσειρές με ακραίες τιμές, στην Ομάδα I (μοντέλα μηχανικής μάθησης, στην οποία εντάσσεται και ο αλγόριθμος του Προφίλ Πίνακα), παρατηρείται ότι οι εκδόσεις χωρίς χρονικά χαρακτηριστικά (no_temp) υπερέχουν σχεδόν σε όλες τις μετρικές, με πιο εντυπωσιακή επίδοση να παρουσιάζει ο DBSCAN με μέση βαθμολογία F1 0.82, ξεπερνώντας κάθε άλλο αλγόριθμο. Ο αλγόριθμος Δάσους Απομόνωσης (IF) διατηρεί σταθερά υψηλή μέση ανάκληση και στις δύο εκδοχές, ενώ ο Τοπικός Παράγοντας Αποκλίσεων (LOF) και η Μηχανή Διανυσμάτων Υποστήριξης Μιας Κλάσης (OCSVM), χωρίς χρονικά χαρακτηριστικά εμφανίζουν σημαντική βελτίωση έναντι της διαφορετικής τους εκδοχής, με αύξηση στη μέση ακρίβεια και ανάκληση, οδηγώντας σε υψηλότερο μέσο F1. Στην Ομάδα II (προβλεπτικά μοντέλα), ο XGBoost με χρήση στατικού ορίου υπερέχει ξεκάθαρα σε όλες τις μετρικές, με μέσο F1-score 0.75, ενώ ακολουθούν οι αλγόριθμοι Εκθετικής Εξομάλυνσης Holt Winters (HWE) και SARIMA, με στατικό όριο, με μέσες τιμές 0.71 και 0.70 αντίστοιχα, που επίσης έχουν υψηλή μέση ανάκληση, γεγονός που καταδεικνύει την αποτελεσματικότητα των παραδοσιακών στατιστικών προσεγγίσεων σε αυτό το σύνολο.

Τα παραπάνω αποτελέσματα επιβεβαιώνονται και από το αντίστοιχο ραβδόγραμμα του A1A στο Διάγραμμα 5.1(i), στο οποίο αξιολογήθηκε η επίδοση των αλγορίθμων εντοπισμού ανωμαλιών με βάση τον μέσο δείκτη βαθμολογίας F1. Γενικά, παρατηρείται ότι οι αλγόριθμοι που χρησιμοποιούν μη-χρονικά χαρακτηριστικά ή στατικά όρια υπερτερούν σε σχέση με εκείνους που ενσωματώνουν χρονική πληροφορία ή δυναμικά όρια. Οι μέθοδοι βαθιάς μάθησης (LSTM, Αυτοκωδικοποιητής, MLP) με δυναμικά όρια, παρουσιάζουν χαμηλότερες επιδόσεις, με τα μέσα F1-scores να πέφτουν κάτω από το 0.45. Αυτό υποδηλώνει ότι, για περιπτώσεις με απλές ακραίες τιμές, πιο ελαφριές μέθοδοι που βασίζονται σε παραδοσιακές προσεγγίσεις, όπως ομαδοποίηση και μη εποπτευόμενη μάθηση χωρίς χρονική εξάρτηση, είναι πιο αποτελεσματικές. Η χρήση στατικού ορίου φαίνεται να αποδίδει καλύτερα σε αυτό το σύνολο δεδομένων, σε σύγκριση με το δυναμικό, ειδικά όταν οι ακραίες τιμές είναι ευδιάκριτες και όχι χρονικά εξαρτώμενες.


Στο A1B, τώρα, που αποτελείται από 7 χρονοσειρές που χαρακτηρίζονται από μετατοπίσεις στη μέση τιμή (mean shift), οι οποίες αποτελούν πιο δύσκολα ανιχνεύσιμες ανωμαλίες σε σχέση με τις

απλές ακραίες τιμές του A1A, παρατηρείται διαφορετική συμπεριφορά στον Πίνακα 5.1. Αρχικά, η υψηλότερη μέση βαθμολογία F1 φτάνει στο 0.53, έναντι του 0.82 στο σύνολο A1A, φαινόμενο που φανερώνει την δύσκολια εύρεσης ανωμαλιών μετατόπισης της μέσης τιμής της χρονοσειράς. Στην Ομάδα I, τα αποτελέσματα παρουσιάζουν διαφορά μεταξύ χρονικών και μη χρονικών χαρακτηριστικών, με τον IF να εμφανίζει την υψηλότερη μέση ανάκληση στα χρονικά (0.74) και με τον DBSCAN να έχει κάκιστη στα μη χρονικά (0.12). Αξιοσημείωτο είναι ότι ο αλγόριθμος του Προφίλ Πίνακα επιτυγχάνει την καλύτερη επίδοση σε μέσο F1 (0.47), με επίσης την υψηλότερη μέση ακρίβεια (0.49), αποτελώντας εξαίρεση ως κλασσική (*baseline*) μέθοδος. Στην Ομάδα II, αντίστροφα από το A1A, τα δυναμικά μοντέλα εμφανίζουν καλύτερη απόδοση από τα στατικά. Για παράδειγμα, ο Αυτοκωδικοποιητής (AE) με δυναμικό όριο έχει F1 με μέση τιμή 0.53, υπερέχοντας της εκδοχής του με το στατικό. Επιπλέον, ο SARIMA με δυναμικό όριο υπερέχει σημαντικά του στατικού, ειδικά ως προς την μέση ανάκληση (0.56 έναντι 0.11), γεγονός που υποδεικνύει ότι σε αυτό το σύνολο τα χρονικά μοτίβα απαιτούσαν δυναμική προσαρμογή.


Παρόμοια αποτελέσματα διαπιστώνονται και από το ραβδόγραμμα του Διαγράμματος 5.1(ii). Εκτός από την κυριαρχία του Αυτοκωδικοποιητή και των απλών στατιστικών αλγορίθμων SARIMA και HWEST με δυναμικά όρια, παρατηρείται και η ξεκάθαρη υπεροχή των αλγορίθμων που χρησιμοποιούν δυναμικά όρια, έναντι των στατικών εκδόσεών τους. Αντίθετα, οι μέθοδοι που χρησιμοποιούν μη-χρονικά χαρακτηριστικά παρουσιάζουν σημαντικά χαμηλότερες επιδόσεις σε σύγκριση με τις διαφορετικές εκδοχές τους, με τις μέσες τιμές F1 να κυμαίνονται μεταξύ 0.14 και 0.20.

Η ανάλυση του διαγράμματος μέσης ακρίβειας-ανάκλησης για το υποσύνολο A1A, στο Διάγραμμα 5.2(i), αποκαλύπτει ενδιαφέρουσες συμπεριφορές των επιμέρους αλγορίθμων ως προς την ευαισθησία και την ακρίβεια τους στον εντοπισμό ακραίων τιμών. Οι αλγόριθμοι DBSCAN, IF και LOF χωρίς χρονικά χαρακτηριστικά παρουσιάζουν υψηλή μέση ανάκληση και ακρίβεια. Συγκεκριμένα και οι δύο εκδόσεις τους έχουν πολύ υψηλή μέση ανάκληση (άνω του 0.8), αλλά οι μη χρονικές εκδόσεις υπερέχουν στην ακρίβεια. Όλοι οι προβλεπτικοί αλγόριθμοι έχουν και αυτοί με τη σειρά τους υψηλή μέση ανάκληση άνω του 0.8, αλλά πάλι αυτοί με το στατικό όριο υπερέχουν σε ακρίβεια αυτούς με το δυναμικό, φαινόμενο που φανερώνει ότι οι αλγόριθμοι με το δυναμικό όριο αν και βρίσκουν τις ανωμαλίες, δίνουν πολλές λανθασμένες ανιχνεύσεις. Τέλος, οι αλγόριθμοι του Αυτοκωδικοποιητή (AE) και του OCSVM δίνουν απογοητευτικά αποτελέσματα με χαμηλή μέση ανάκληση και ακρίβεια.

Στο υποσύνολο A1B, του Διαγράμματος 5.2(ii), παρατηρείται ότι ο Αυτοκωδικοποιητής με δυναμικό όριο (AE_dynamic) επιτυγχάνει την υψηλότερη μέση ακρίβεια από όλους τους αλγόριθμους, διατηρώντας παράλληλα ικανοποιητική ανάκληση, γεγονός που επιβεβαιώνει την καταλληλότητά του για την ανίχνευση πιο διακριτικών ανωμαλιών. Η μέθοδος του Προφίλ Πίνακα (MP) εμφανίζει, επίσης, υψηλή μέση ανάκληση και ικανοποιητική ακρίβεια, καταλαμβάνοντας μία από τις κορυφαίες θέσεις στο διάγραμμα. Αντίθετα, οι αλγόριθμοι που βασίζονται αποκλειστικά σε μη-χρονικά χαρακτηριστικά, όπως οι IF, LOF και OCSVM, παρουσιάζουν σημαντική πτώση στην μέση ακρίβεια, έχοντας ανάκληση κάτω του 0.5. Αξιοσημείωτο είναι επίσης το γεγονός ότι η χρήση δυναμικών ορίων



(i) A1A



(ii) A1B


Διάγραμμα 5.1: Ραβδογράμματα μέσης βαθμολογίας F1 για τα δεδομένα A1A, A1B.

οδηγεί συχνά σε αύξηση της μέσης ανάκλησης, με ελάχιστη επίδραση στην ακρίβεια (ο μοναδικός αλγόριθμος που παρουσιάζει κακή επίδραση στην ακρίβεια είναι του γραμμικού μοντέλου (LM)), παρατήρηση που υποδηλώνει ότι με τη χρήση δυναμικού ορίου εντοπίζονται παραπάνω ανωμαλίες, αλλά διατηρούνται παρόμοιες λανθασμένες ανιχνεύσεις. Η σύγκριση μεταξύ στατικών και δυναμικών ορίων υποδεικνύει ότι οι δεύτεροι συνεισφέρουν θετικά στην ανίχνευση ανωμαλιών μετατόπισης, βελτιώνοντας την μέση ανάκληση.

Για το υποσύνολο A1A, πραγματοποιήθηκε στατιστική ανάλυση μεταξύ εκδόσεων των αλγορίθμων με διαφορετικές ρυθμίσεις — είτε μεταξύ στατικών και δυναμικών ορίων για τις προβλεπτικές και μεθόδους βαθιάς μάθησης, είτε μεταξύ των χρονικών και μη χρονικών εκδοχών για τις ML-βασισμένες τεχνικές, όπως φαίνεται στον Πίνακα 5.2.


Παρατηρείται σε όλες σχεδόν τις περιπτώσεις (εκτός από τον AE και τον IF), ότι οι διαφορές ήταν στατιστικά σημαντικές, υποδεικνύοντας σαφή ανωτερότητα του στατικού ορίου και των μη χρονικών χαρακτηριστικών στο συγκεκριμένο υποσύνολο.

Συνδυασμένη Μέση Ακρίβεια έναντι Ανάκλησης για Χρονικά έναντι Μη Χρονικών και Στατικά έναντι Δυναμικών Ορίων για το A1A



(i) A1A

Συνδυασμένη Μέση Ακρίβεια έναντι Ανάκλησης για Χρονικά έναντι Μη Χρονικών και Στατικά έναντι Δυναμικών Ορίων για το A1B



(ii) A1B

Διάγραμμα 5.2: Διαγράμματα Μέσης Ακρίβειας-Ανάκλησης για τα A1A, A1B.

Ενδεικτικά, ο XGBoost παρουσίασε μείωση κατά 41.33% με τη χρήση δυναμικού ορίου, ενώ η μετάβαση του DBSCAN από χρονικά σε μη χρονικά χαρακτηριστικά προκάλεσε σημαντική αύξηση της μέσης απόδοσης κατά 63.33%, όπως και στον OCSVM η έλλειψη χρήσης χρονικής πληροφορίας ενίσχυσε την μέση απόδοση κατά 73.03%, βελτιώσεις οι οποίες είναι και στατιστικά σημαντικές. Τέλος, πρέπει να σημειωθεί ότι αν και οι AE, IF δεν έχουν στατιστικά σημαντικές μεταβολές, παραμένουν να βελτιώνονται στις επικρατέστερες ομάδες (στατικό όριο με 10% αύξηση και μη χρονικά χαρακτηριστικά με 3.26% αύξηση αντίστοιχα). Γενικά, η χρήση δυναμικού ορίου είχε αρνητική επίδραση στις προβλεπτικές μεθόδους και της βαθιάς μάθησης για το A1A, όπου οι ανωμαλίες είναι εμφανείς και καθαρές, ενώ οι ML τεχνικές επωφελήθηκαν από τις αφαιρέσεις χρονικών χαρακτηριστικών — με σημαντικές αυξήσεις απόδοσης και στατιστικά αποτελέσματα.

Η ανάλυση των στατιστικών διαφορών στο υποσύνολο A1B φανερώνει σημαντικές διαφοροποιήσεις ως προς την αποτελεσματικότητα των διαφορετικών παραμετροποιήσεων των αλγορίθμων.

Σύγκριση	Wilcoxon Statistic	P-value	✓/✗	Μεταβολή Μέσου F1
Στατικά vs Δυναμικά Όρια				
AE	35.0	0.7537	✗	-10.00%
MLP	5.0	0.0024	✓	-25.00%
LSTM	0.0	0.0022	✓	-34.92%
XGBoost	0.0	0.0002	✓	-41.33%
LM	13.0	0.0215	✓	-22.58%
SARIMA	4.0	0.0017	✓	-30.00%
HWEST	3.0	0.0012	✓	-30.99%
Χρονικά vs Μη Χρονικά Χαρακτηριστικά				
IF	7.0	0.8927	✗	+3.26%
LOF	11.0	0.0281	✓	+14.99%
OCSVM	0.0	0.0022	✓	+73.03%
DBSCAN	0.0	0.0002	✓	+63.33%

Σύγκριση	Wilcoxon Statistic	P-value	✓/✗	Μεταβολή Μέσου F1
Στατικά vs Δυναμικά Όρια				
AE	7.0	0.4631	✗	+23.26%
MLP	12.0	0.8125	✗	+22.86%
LSTM	0.0	0.0431	✓	+72.00%
XGBoost	4.0	0.1730	✗	+63.64%
LM	9.0	0.7532	✗	+22.22%
SARIMA	1.0	0.0313	✓	+64.29%
HWEST	0.0	0.0156	✓	+70.37%
Χρονικά vs Μη Χρονικά Χαρακτηριστικά				
IF	0.0	0.0156	✓	-50.89%
LOF	0.0	0.0156	✓	-67.10%
OCSVM	0.0	0.0156	✓	-59.50%
DBSCAN	1.0	0.0313	✓	-58.41%

A1A

A1B

Πίνακας 5.2: Στατιστική σημαντικότητα (✓) και μεταβολές μέσου F1 Score για τα δεδομένα A1A και A1B. Οι μεταβολές σημειώνονται από Στατικά σε Δυναμικά όρια και από χρονικά σε μη χρονικά χαρακτηριστικά.

Συγκεκριμένα, οι προβλεπτικοί και βαθιάς μάθησης αλγόριθμοι εμφάνισαν στατιστικά σημαντικές αυξήσεις στην μέση βαθμολογία F1 με τη χρήση δυναμικού ορίου — π.χ. το LSTM κατέγραψε αύξηση 72%, το HWEST 70.37% και το SARIMA 64.29%. Ωστόσο, στους υπόλοιπους αλγορίθμους, παρότι η αύξηση ήταν επίσης αξιοσημείωτη (22–64%), δεν επιβεβαιώθηκε η στατιστική σημαντικότητα.

Επίσης, στους αλγόριθμους μηχανικής μάθησης, η προσθήκη χρονικών χαρακτηριστικών (temporal columns) οδήγησε σε ενίσχυση της μέσης απόδοσης. Ο OCSVM, ο DBSCAN, ο LOF και ο IF παρουσίασαν αύξηση της μέσης βαθμολογίας F1 από 50% έως και 67%, ενώ και στις τέσσερις περιπτώσεις η διαφορά ήταν στατιστικά σημαντική. Αυτό υποδηλώνει ότι σε περιπτώσεις ανωμαλιών τύπου αλλαγής μετατόπισης (όπως στο A1B), η χρήση απλών χαρακτηριστικών με χρονική πληροφορία μπορεί να είναι πιο σταθερή προσέγγιση για αυτούς τους αλγορίθμους.

Μέχρι στιγμής, έχει διαμορφωθεί το γενικό συμπέρασμα ότι, για στάσιμα δεδομένα με εμφανείς ακραίες ανωμαλίες, είναι πιο κατάλληλοι οι αλγόριθμοι μηχανικής μάθησης χωρίς χρονικά χαρακτηριστικά, καθώς και οι προβλεπτικοί αλγόριθμοι που βασίζονται σε στατικά όρια. Αντίθετα, όταν τα δεδομένα παρουσιάζουν μεταβολές στη μέση τιμή της χρονοσειράς (π.χ. μετατόπιση), αποδίδουν καλύτερα οι αλγόριθμοι που ενσωματώνουν χρονικά χαρακτηριστικά, καθώς και οι προβλεπτικοί αλγόριθμοι με δυναμικά (προσαρμοζόμενα) όρια. Επίσης, στο A1A παρατηρείται ότι και στα δύο είδη ορίων ότι οι κλασσικές στατιστικές μέθοδοι υπερέχουν των μεθόδων βαθιάς μάθησης (εκτός του LM), με τον XGBoost να παραμένει ανταγωνιστικός, ενώ στο A1B η μόνη τεχνική βαθιάς μάθησης που είναι καλύτερη, είναι αυτή του Αυτοκωδικοποιητή, με τα νευρωνικά δίκτυα να παραμένουν ανταγωνιστικά.

Ο Πίνακας 5.3, που απεικονίζει τα αποτελέσματα για τα σύνολα A1C και A1D αποτυπώνει μια πιο σύνθετη και λιγότερο ξεκάθαρη εικόνα σε σχέση με τα προηγούμενα σύνολα δεδομένων.

A1C							A1D								
Ομάδα I							Ομάδα I								
	temp				no_temp				temp				no_temp		
	P	R	F1		P	R	F1		P	R	F1		P	R	F1
IF	0.52	0.69	0.55		0.39	0.78	0.48		0.35	0.63	0.43		0.26	0.65	0.33
LOF	0.43	0.26	0.31		0.38	0.27	0.30		0.29	0.57	0.37		0.51	0.27	0.34
OCSVM	0.68	0.79	0.72		0.61	0.73	0.65		0.42	0.55	0.46		0.41	0.50	0.44
DBSCAN	0.32	0.68	0.40		0.52	0.07	0.11		0.33	0.68	0.43		0.34	0.14	0.18
	P		R		F1				P		R		F1		
MP	0.41		0.61		0.46				0.14		0.65		0.22		
Ομάδα II							Ομάδα II								
	static				dynamic				static				dynamic		
	P	R	F1		P	R	F1		P	R	F1		P	R	F1
AE	0.39	0.27	0.30		0.46	0.46	0.44		0.26	0.38	0.29		0.16	0.51	0.23
MLP	0.47	0.33	0.35		0.39	0.34	0.35		0.50	0.50	0.46		0.24	0.47	0.30
LSTM	0.49	0.32	0.34		0.56	0.66	0.57		0.46	0.55	0.45		0.24	0.45	0.31
XGboost	0.51	0.49	0.44		0.38	0.16	0.21		0.45	0.47	0.34		0.19	0.48	0.18
LM	0.41	0.23	0.26		0.35	0.27	0.29		0.44	0.27	0.27		0.20	0.33	0.23
SARIMA	0.66	0.22	0.59		0.56	0.30	0.53		0.18	0.34	0.23		0.20	0.51	0.33
HWEST	0.64	0.22	0.62		0.54	0.57	0.54		0.25	0.41	0.32		0.14	0.39	0.27

A1C σύνολο

A1D σύνολο


Πίνακας 5.3: Αποτελέσματα μέσης Ακρίβειας (P), μέσης Ανάκλησης (R) και μέσης Βαθμολογίας F1 για τα σύνολα δεδομένων A1C, A1D.

Στο A1C, η Ομάδα I δείχνει μια αξιοσημείωτη υπεροχή του OCSVM με χρονικά χαρακτηριστικά, το οποίο καταγράφει την υψηλότερη μέση τιμή F1 (0.72), υπερτερώντας και σε μέση ακρίβεια, όπως και μέση ανάκληση έναντι όλων των άλλων μεθόδων, γεγονός που υποδηλώνει μια ισορροπημένη και σταθερή αντίχρευσση. Από την ίδια ομάδα, ο DBSCAN χωρίς χρονικά χαρακτηριστικά παρουσιάζει αστάθεια μεταξύ μέσης ακρίβειας και ανάκλησης, οδηγώντας σε φτωχότερη επίδοση μέσου F1. Αντίστοιχα, στην Ομάδα II, ο HWEST με στατικό όριο εμφανίζει την υψηλότερη μέση βαθμολογία F1 (0.62), ακολουθούμενο από το στατικό SARIMA (0.59), κάτι που υποδηλώνει πως σε αυτό το σύνολο οι στατικές προβλέψεις είχαν πλεονέκτημα, με καλύτερη ακρίβεια αλλά περιορισμένη ανάκληση. Αντίθετα, τα δυναμικά μοντέλα παρουσιάζουν κάποια βελτίωση στην ανάκληση (εκτός του XGBoost), όπως παρατηρείται στο LSTM με δυναμικό όριο ($R = 0.66$), αλλά συχνά αυτό δεν μεταφράζεται σε ανώτερο μέσο F1 λόγω μειωμένης μέσης ακρίβειας.


Για το A1D, η εικόνα είναι ακόμη πιο συγκεχυμένη. Η γενική απόδοση των αλγορίθμων στο συγκεκριμένο σύνολο είναι σχετικά χαμηλή (συγκεκριμένα η χαμηλότερη βαθμολογία F1 από όλα τα σύνολα δεδομένων του Yahoo!).

Αν και ο OCSVM με χρονικά χαρακτηριστικά παραμένει ο καλύτερος σε μέσο F1 (0.46), η διαφορά από τους υπόλοιπους είναι μικρή. Ενδιαφέρον έχει ο DBSCAN, επίσης με χρονικά χαρακτη-

ριστικά, ο οποίος πετυχαίνει την υψηλότερη μέση ανάκληση (0.68), αλλά με σχετικά χαμηλή μέση ακρίβεια, καταλήγοντας σε F1 0.43.



(i) A1C



(ii) A1D

Διάγραμμα 5.3: Ραβδογράμματα μέσης βαθμολογίας F1 για τα δεδομένα A1C, A1D.

Η προσέγγιση MP, παρότι έχει υψηλή μέση ανάκληση μεγέθους 0.65, παρουσιάζει χαμηλή μέση ακρίβεια (0.14), χαρακτηριστικό που δίνει πολύ χαμηλή βαθμολογία F1 (0.22). Στην Ομάδα II, το MLP με στατικό όριο ξεχωρίζει με μέσο F1 0.46, παρουσιάζοντας ισορροπημένη συμπεριφορά σε μέση ακρίβεια και ανάκληση. Το στατικό LSTM ακολουθεί με παρόμοια επίδοση, ενώ τα δυναμικά μοντέλα έχουν γενικά ασθενέστερες επιδόσεις και πάλι, παρά τις επιμέρους βελτιώσεις στην μέση ανάκληση. Συνολικά, στα A1C και A1D διαφαίνεται η δυσκολία των μοντέλων να διαχειριστούν τη φύση των ανωμαλιών, με τις στατικές εκδοχές να διατηρούν συνήθως ένα μικρό πλεονέκτημα, χωρίς όμως ξεκάθαρους νικητές, και με σημαντικές διακυμάνσεις μεταξύ μέσης ακρίβειας και ανάκλησης.

Από το ραβδόγραμμα του Διαγράμματος 5.3(i), παρατηρείται ότι ο OCSVM με χρονικά χαρακτηριστικά (OCSVM_temp) υπερέχει με μέση βαθμολογία F1 ίσο με 0.72, ξεπερνώντας τόσο τις παραδοσιακές όσο και τις πιο σύγχρονες προσεγγίσεις. Στη δεύτερη θέση βρίσκεται ο ίδιος αλγόριθμος χωρίς

χρονικά χαρακτηριστικά (OCSVM_no_temp) με 0.65, ένδειξη ότι ο συγκεκριμένος αλγόριθμος είναι ιδιαίτερα κατάλληλος για αυτό το είδος ανωμαλιών, ενώ ενισχύεται ελαφρώς από την ενσωμάτωση χρονικής πληροφορίας.


Ακολουθούν οι στατιστικές μέθοδοι HWEST και SARIMA σε στατική παραμετροποίηση (0.62 και 0.59 μέσες βαθμολογίες F1 αντίστοιχα), γεγονός που αποδεικνύει ότι η πρόβλεψη βασισμένη σε ιστορικά μοτίβα μπορεί να αναδείξει συσσωρευμένα ή εξαρτημένα μοτίβα ανωμαλιών. Αυτό επιβεβαιώνεται με την ύπαρξη του LSTM με δυναμικό όριο στην πέμπτη θέση (0.57).

Ωστόσο, παρατηρείται και μεγάλη διακύμανση στην απόδοση των υπολοίπων αλγορίθμων. Πολλοί αλγόριθμοι βαθιάς μάθησης και ML-βασισμένες προσεγγίσεις καταγράφουν μέσα F1-scores κάτω από 0.4. Συγκεκριμένα, αλγόριθμοι όπως ο LOF, DBSCAN, LM και MLP εμφανίζουν κακά αποτελέσματα σε κάθε τους εκδοχή. Η χρήση χρονικών χαρακτηριστικών και η επιλογή ορίου (στατικού ή δυναμικού) φαίνεται να έχει σημαντική επίδραση, αλλά όχι απαραίτητα με σαφή κατεύθυνση, με κάποιους αλγόριθμους να επωφελούνται με το ένα και άλλους με το άλλο.

Συνεπώς, προκύπτει ότι, με εξαίρεση το ανταγωνιστικό δυναμικό LSTM, οι περισσότερες μέθοδοι βαθιάς μάθησης — ακόμη και ο XGBoost — υστερούν σε σύγκριση με τους παραδοσιακούς στατιστικούς αλγορίθμους SARIMA και HWEST. Εξαίρεση αποτελεί το γραμμικό μοντέλο, το οποίο, και στις δύο εκδοχές του, παρουσιάζει χαμηλή μέση απόδοση.

Στο υποσύνολο A1D, όπως προαναφέρθηκε, οι επιδόσεις των αλγορίθμων κυμαίνονται σε χαμηλά επίπεδα, υποδηλώνοντας την πολυπλοκότητα των χρονοσειρών. Όπως φαίνεται στο Διάγραμμα 5.3(ii) κορυφαίες επιδόσεις καταγράφονται από τον MLP με στατικό όριο και τον OCSVM με χρονικά χαρακτηριστικά, οι οποίοι επιτυγχάνουν μέση βαθμολογία F1 ίση με 0.46. Ακολουθούν ο LSTM με στατικό όριο (0.45) και ο OCSVM χωρίς χρονικά χαρακτηριστικά (0.44), με μικρές διαφορές. Τα αποτελέσματα δείχνουν ότι οι αλγόριθμοι βαθιάς μάθησης με στατικό όριο μπορούν όντως να αντιληφθούν την τάση των χρονοσειρών (όχι σε επαρκές επίπεδο βέβαια, λόγω των χαμηλών μέσων βαθμολογιών F1), ενώ πάλι ο OCSVM παρουσιάζει σταθερά υψηλά αποτελέσματα.

Αντίθετα, πιο εξειδικευμένοι αλγόριθμοι όπως το MP, ο DBSCAN χωρίς χρονικά χαρακτηριστικά ή ο XGBoost με δυναμικό όριο αποδίδουν χαμηλά (κάτω από 0.25), γεγονός που φανερώνει τη δυσκολία αυτών των μεθόδων να εντοπίσουν πολλαπλά και ετερογενή μοτίβα ανωμαλιών. Γενικά, η χρήση χρονικών χαρακτηριστικών φαίνεται να έχει περιορισμένο όφελος (αν γίνει εξαίρεση του μη χρονικού OCSVM), ενώ η επιλογή μεταξύ στατικού και δυναμικού ορίου δεν παρουσιάζει σαφή υπεροχή. Θα μπορούσε να γίνει ο ισχυρισμός ότι το στατικό όριο είναι ανώτερο του δυναμικού, αφού όλοι οι δυναμικοί αλγόριθμοι παρουσιάζουν μέση βαθμολογία F1 κάτω του 0.33, ενώ το στατικό όριο έχει 3 αλγορίθμους με ψηλότερη μέση βαθμολογία. Το εύρημα αυτό επιβεβαιώνει ότι η ανίχνευση ανωμαλιών σε χρονοσειρές με πολύπλοκη δυναμική απαιτεί συνδυασμό μεθόδων και πιο ευέλικτες προσεγγίσεις, οι οποίες θα μπορούν να μοντελοποιούν μακροχρόνιες εξαρτήσεις και μεταβλητές εποχικές δομές.



Διάγραμμα 5.4: Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για το A1C.


Το διάγραμμα μέσης ακρίβειας-ανάκλησης για το σύνολο A1C, όπως φαίνεται από το Διάγραμμα 5.4, αποκαλύπτει τις σημαντικές διαφορές μεταξύ των κατηγοριών αλγορίθμων, ειδικά όταν πρόκειται για την ανίχνευση συσσωρευμένων ή ανωμαλιών υπό όρους. Ξεχωρίζει ο OCSVM και με τις δύο εκδοχές, ο οποίος καταγράφει κορυφαία απόδοση με πολύ υψηλή μέση ακρίβεια και ανάκληση, επιβεβαιώνοντας την καταλληλότητα του για σενάρια με πιο “λεπτές” αποκλίσεις στο σήμα, όπως και δεδομένα με συλλογικές ανωμαλίες. Σημαντική είναι επίσης η θέση του IF χωρίς χρονικά χαρακτηριστικά, που εμφανίζει πολύ υψηλή μέση ανάκληση (κοντά στο 0.8), αλλά με αισθητή μείωση στην μέση ακρίβεια, υποδεικνύοντας υψηλό αριθμό λανθασμένων ανωμαλιών. Ο IF με χρονικά χαρακτηριστικά αν και έχει μικρότερη μέση ανάκληση, παρουσιάζει μεγαλύτερη μέση ακρίβεια, ένδειξη που αιτιολογεί στο Διάγραμμα 5.3(i) μεγαλύτερη μέση βαθμολογία F1.

Οι στατιστικές μέθοδοι SARIMA και HWEST σε στατική μορφή επιτυγχάνουν υψηλή μέση ακρίβεια, θυσιάζοντας όμως ένα μέρος της μέσης ανάκλησης, που τους καθιστά πιο “προσεκτικούς αλγορίθμους”. Στη δυναμική τους εκδοχή, βέβαια, μειώνεται κατά πολύ η μέση ακρίβεια, αλλά αυξάνεται η μέση ανάκληση (αρκετά μεγαλύτερη αύξηση για τον HWEST).

Επιπλέον, πιο “ελαφριές” μέθοδοι όπως ο DBSCAN με χρονικά χαρακτηριστικά ή ο MP παρουσιάζουν υψηλή μέση ανάκληση αλλά πολύ χαμηλή μέση ακρίβεια, γεγονός που τους καθιστά ακατάλληλους για προβλήματα που οι λανθασμένες ανιχνεύσεις μπορούν να δημιουργήσουν σοβαρές επιπτώσεις. Ο DBSCAN, συγκεκριμένα αποτελεί ιδιαίτερης σημασίας, αφού η μη χρονική εκδοχή, έχει υψηλή μέση ακρίβεια και χαμηλή μέση ανάκληση, που τον καθιστά αλγόριθμο που εντοπίζει λίγες ανωμαλίες, αλλά τις βρίσκει σωστά, ενώ η άλλη του εκδοχή αποτελεί αλγόριθμο που εντοπίζει αρκετά περισσότερες, αλλά με αρκετές λανθασμένες ανιχνεύσεις.

Οι αλγόριθμοι LOF, LM, MLP, βρίσκονται στο κάτω αριστερό τεταρτημόριο του γραφήματος που μας δείχνει ότι σε καμία εκδοχή δεν παρουσιάζουν καλά αποτελέσματα. Αν και όπως αναφέρθηκε, κάποιοι αλγόριθμοι φαίνεται στην δυναμική εκδοχή να παρουσιάζουν περισσότερη ανάκληση και να

θυσιάζουν ακρίβεια έναντι της στατικής, δεν ισχύει το ίδιο για τον XGboost, που παρατηρείται ότι η στατική εκδοχή είναι ανώτερη της δυναμικής.



Διάγραμμα 5.5: Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για το A1D.

Το διάγραμμα μέσης ακρίβειας-ανάκλησης για το σύνολο A1D, όπως φαίνεται από το Διάγραμμα 5.5 επιβεβαιώνει τη μεγάλη πρόκληση που ενέχει η ανίχνευση ανωμαλιών σε δεδομένα με πολυδιάστατη δυναμική, όπως τάση, εποχικότητα και ποικίλοι τύποι απόκλισης, λόγω των χαμηλών τιμών της ακρίβειας και της ανάκλησης. Η ερμηνεία του διαγράμματος γίνεται παρατηρώντας τα τεταρτημόρια ανεξάρτητα των τιμών των μετρικών, αλλά παράλληλα έχοντας στο νου ότι τα αποτελέσματα δεν ήταν ικανοποιητικά. Οι στατικοί MLP, XGBoost και LSTM εμφανίζουν αξιοσημείωτα ισορροπημένες αποδόσεις, προσεγγίζοντας ή ξεπερνώντας το 0.5 σε μέση ανάκληση και ακρίβεια.

Αντίθετα, οι αντίστοιχες εκδοχές με δυναμικά όρια συγκεντρώνονται στο κάτω μισό του διαγράμματος, με σημαντικά χαμηλότερη μέση ακρίβεια, με την μέση ανάκληση τους να κυμαίνεται από 0.3 μέχρι 0.55. Αυτό υποδηλώνει ότι, στο A1D, η χρήση δυναμικού ορίου χωρίς κατάλληλη προσαρμογή οδηγεί σε αυξημένες λανθασμένες ανιχνεύσεις. Σε αυτό το σύνολο, επίσης, οι στατιστικές μέθοδοι HWEST και SARIMA, συνοδεύουν τον συνήθως απογοητευτικό AE με κακά αποτελέσματα, εξαιτίας της χαμηλής μέσης ακρίβειας και μέτριας μέσης ανάκλησης που παρουσιάζουν. Επομένως, διαπιστώνεται ότι, κατά κύριο λόγο, οι αλγόριθμοι βαθιάς μάθησης, των οποίων οι προβλέψεις βασίζονται σε ιστορικά δεδομένα, παρουσιάζουν ανταγωνιστικές — και σε αρκετές περιπτώσεις ανώτερες — επιδόσεις στο συγκεκριμένο σύνολο δεδομένων, αποδεικνύοντας την αυξημένη ικανότητά τους στην κατανόηση της υποκείμενης τάσης.

Η περίπτωση του IF είναι ενδεικτική: η εκδοχή με χρονικά χαρακτηριστικά επιτυγχάνει ισορροπία με μέση ανάκληση πάνω από 0.6 και αξιοπρεπή μέση ακρίβεια (0.33), ενώ η έλλειψη χρονικών χαρακτηριστικών μειώνει σημαντικά τη δεύτερη, μεταβάλλοντας ελάχιστα την πρώτη. Ο DBSCAN αποτελεί ενδιαφέρουσα περίπτωση, που και στις δύο εκδοχές έχει σχεδόν ίδια μέση ακρίβεια, αλλά με χρονικά χαρακτηριστικά αυξάνεται ραγδαία η μέση ανάκληση. Ο LOF με χρονικά χαρακτηριστικά έχει υψηλή ανάκληση, ενώ με τα μη χρονικά χαρακτηριστικά μειώνεται κατά πολύ η μέση ανάκληση

και αυξάνεται η μέση ακρίβεια, που δείχνει ότι ο LOF με χρονικά χαρακτηριστικά δίνει λιγότερη προσοχή στην ανίχνευση, πετυχαίνοντας πολλές λανθασμένες ανωμαλίες. Το Προφίλ Πίνακα, αν και θεωρητικά κατάλληλο για πολλαπλές μορφές ανωμαλιών, καταγράφει πολύ χαμηλή μέση ακρίβεια, αλλά πολύ υψηλή μέση ανάκληση, δείχνοντας την αδυναμία του να μπορεί να εντοπίσει σωστά τις ανωμαλίες, χωρίς να κάνει πολλά λάθη.

Σύγκριση	Wilcoxon Statistic	P-value	✓/✗	Μεταβολή Μέσου F1
Στατικά vs Δυναμικά Όρια				
AE	0.0	0.0431	✓	+46.67%
MLP	7.0	0.5625	✗	0.00%
LSTM	2.0	0.1380	✗	+67.65%
XGBoost	0.0	0.0313	✓	-52.27%
LM	3.0	0.1563	✗	+11.54%
SARIMA	4.0	0.2188	✗	-10.17%
HWEST	3.0	0.1563	✗	-12.90%
Χρονικά vs Μη Χρονικά Χαρακτηριστικά				
IF	2.0	0.1380	✗	-12.53%
LOF	9.0	0.8438	✗	-5.63%
OCSVM	9.0	0.8438	✗	-9.54%
DBSCAN	0.0	0.0313	✓	-71.71%

A1C

Σύγκριση	Wilcoxon Statistic	P-value	✓/✗	Μεταβολή Μέσου F1
Στατικά vs Δυναμικά Όρια				
AE	8.0	0.6875	✗	-20.69%
MLP	4.0	0.2188	✗	-34.78%
LSTM	3.0	0.1563	✗	-31.11%
XGBoost	5.0	0.3125	✗	-47.06%
LM	6.0	0.4375	✗	-14.81%
SARIMA	8.0	0.6875	✗	+43.48%
HWEST	2.0	0.0938	✗	-15.62%
Χρονικά vs Μη Χρονικά Χαρακτηριστικά				
IF	1.0	0.0625	✗	-23.54%
LOF	7.0	0.8927	✗	-6.56%
OCSVM	6.0	0.6858	✗	-4.45%
DBSCAN	1.0	0.0625	✗	-57.48%

A1D

Πίνακας 5.4: Στατιστική σημαντικότητα (✓) και μεταβολές μέσου F1 Score για τα A1C και A1D. Οι μεταβολές σημειώνονται από Στατικά σε Δυναμικά όρια και από χρονικά σε μη χρονικά χαρακτηριστικά.

Συμπερασματικά, στο A1D κατά κύριο λόγο οι προβλεπτικοί αλγόριθμοι με στατικά όρια παρουσιάζουν μεγαλύτερη μέση ακρίβεια έναντι των άλλων εκδόσεών τους και οι αλγόριθμοι μηχανικής μάθησης με χρονικά χαρακτηριστικά έχουν μεγαλύτερη μέση ανάκληση με την ακρίβεια κάποιες φορές να θυσιάζεται (LOF), ενώ άλλες φορές να πριμοδοτείται (OCSVM).

Για το υποσύνολο A1C, όπου οι ανωμαλίες έχουν πιο σύνθετη μορφή (συσσωρευμένες ή υπό όρους ανωμαλίες), τα αποτελέσματα του Wilcoxon test, όπως φαίνονται στον Πίνακα 5.4, σε συνδυασμό με τις ποσοστιαίες μεταβολές μέσης βαθμολογίας F1 φανερώνουν περιορισμένη αλλά ουσιαστική επίδραση της παραμετροποίησης σε ορισμένους αλγορίθμους.

Η σημαντικότερη βελτίωση σημειώνεται στον AE, όπου η μετάβαση από στατικό σε δυναμικό όριο οδήγησε σε αύξηση μέσου F1 κατά 46.67%, με το αποτέλεσμα να είναι στατιστικά σημαντικό. Παρόμοια σημαντική αύξηση (67.65%) καταγράφει και το LSTM, αν και το αποτέλεσμα δεν είναι στατιστικά σημαντικό, ενδεχομένως λόγω του περιορισμένου μεγέθους δείγματος. Συγκεκριμένα, μπορεί να είναι μεγαλύτερη η μέση αύξηση, αλλά η διακύμανση των αποτελεσμάτων του δεν είναι σημαντικά μεγαλύτερη, γεγονός που δεν επιτρέπει την εξαγωγή στατιστικά ασφαλούς συμπεράσματος. Αντίθετα, ο XGBoost παρουσίασε στατιστικά σημαντική μείωση στην μέση απόδοση κατά 52.27% όταν χρησι-

μοποιήθηκε δυναμικό όριο.

Όσον αφορά τις ML μεθόδους, οι αλλαγές από χρονικές σε μη χρονικές εκδοχές δεν φάνηκαν να είναι στατιστικά σημαντικές, με εξαίρεση τον DBSCAN, ο οποίος παρουσίασε μεγάλη μείωση μέσης απόδοσης (-71.71%) και στατιστικά σημαντική διαφορά.

Συμπερασματικά, οι δυναμικές παραμετροποιήσεις στο A1C δεν εγγυώνται βελτίωση λειτουργούν επιλεκτικά σε συγκεκριμένους αλγορίθμους, ενώ σε άλλους μπορεί να επιφέρουν σοβαρή υποβάθμιση μέσης απόδοσης. Όσο, για τη χρήση χρονικών χαρακτηριστικών, με εξαίρεση τον DBSCAN, αν και δεν είναι στατιστικά σημαντικές οι διαφορές, έχουν βελτιώσεις στην βαθμολογία F1, έναντι των μη χρονικών εκδοχών τους.

Για το υποσύνολο A1D, όπου οι ανωμαλίες εμφανίζονται σε πιο σύνθετες μορφές — όπως τάσεις, εποχικότητα και συνδυασμοί διαταραχών — τα αποτελέσματα των στατιστικών ελέγχων δεν ανέδειξαν καμία στατιστικά σημαντική διαφορά μεταξύ των παραμετροποιήσεων. Παρότι παρατηρούνται έντονες ποσοστιαίες μεταβολές, καμία εξ αυτών δεν υποστηρίζεται από στατιστική σημαντικότητα ($p > 0.05$), γεγονός που αποδίδεται είτε στη μικρή διαφορά δείγματος είτε στην έντονη ετερογένεια των χρονοσειρών του A1D.

Ενδεικτικά, η μετάβαση του XGBoost σε δυναμικό όριο συνοδεύεται από πτώση της μέσης απόδοσης κατά 47.06%, ενώ ο MLP και ο LSTM παρουσίασαν μειώσεις άνω του 30%. Αντίθετα, ο SARIMA είχε αύξηση F1 κατά 43.48% με χρήση δυναμικού ορίου, εξαιτίας της ορθής εύρεσης μιας χρονοσειράς με αλλαγή μετατόπισης και τάσης, που είχε ως αποτέλεσμα την αθροιστική εκτόξευση της βαθμολογίας F1, που δείχνει όντως πόσο εύκολα μπορεί να επηρεαστεί από συσσωρευμένες ανωμαλίες το μικρό δείγμα χρονοσειρών. Και πάλι, όμως, το αποτέλεσμα δεν είναι στατιστικά σημαντικό.

Στην κατηγορία χρονικών και μη χρονικών χαρακτηριστικών, όλοι οι αλγόριθμοι μηχανικής μάθησης παρουσίασαν μείωση στην μέση απόδοση — με πιο έντονη περίπτωση τον DBSCAN (-57.48%) — χωρίς όμως καμία στατιστική σημαντικότητα να επιβεβαιώνει αυτές τις διαφορές.


Τα αποτελέσματα επιβεβαιώνουν ότι στο A1D οι παραμετροποιήσεις δεν έχουν καθολικά προβλέψιμη επίδραση στην απόδοση και απαιτείται πιο λεπτομερής συντονισμός ή ακόμα και υβριδικές προσεγγίσεις για να βελτιωθεί η συνολική αποτελεσματικότητα, αν δεν γίνει αναγκαία η χρήση μεγαλύτερου δείγματος χρονοσειρών.

Μετά την αποτασιοποίηση του υποσυνόλου A1D, αξιολογήθηκε η συμπεριφορά των αλγορίθμων βαθιάς μάθησης και προβλεπτικών (με εξαίρεση τους στατιστικούς αλγορίθμους HWEST και SARIMA, που μέσω αυτόματης αφαίρεσης τάσης μπορούν να λειτουργήσουν) με χρήση στατικού και δυναμικού ορίου. Η απομάκρυνση της τάσης αποσκοπούσε στη διευκόλυνση της ανίχνευσης ανωμαλιών, καθώς η παρουσία μακροπρόθεσμων μεταβολών ενδέχεται να επισκιάζει τοπικές αποκλίσεις που είναι κρίσιμες για την ανάλυση.

A1D Αποτασιοποιημένο

	static			dynamic		
	P	R	F1	P	R	F1
AE	0.38	0.52	0.43	0.24	0.67	0.33
MLP	0.47	0.46	0.40	0.21	0.43	0.26
LSTM	0.54	0.55	0.44	0.22	0.60	0.31
XGboost	0.61	0.62	0.53	0.19	0.32	0.15
LM	0.41	0.32	0.28	0.25	0.39	0.29

Πίνακας 5.5: Αποτελέσματα μέσω (P, R, F1) για A1D αποτασιοποιημένο.



Διάγραμμα 5.6: Ραβδογράμματα μέσω F1 για στατικά και δυναμικά όρια στο αποτασιοποιημένο A1D.

Από τα αποτελέσματα του Πίνακα 5.5, σε συνδυασμό με το διπλανό Διάγραμμα 5.6 που παρουσιάζει τις μέσες τιμές F1 των αλγορίθμων, προκύπτει ότι οι αλγόριθμοι με στατικό όριο διατηρούν σημαντικά υψηλότερες επιδόσεις σε σχέση με τις αντίστοιχες εκδοχές τους με δυναμικό όριο. Ο XGBoost σε στατική μορφή καταγράφει την υψηλότερη επίδοση με μέση βαθμολογία F1 ίση με 0.53, την υψηλότερη μέση ακρίβεια (0.61) και μέση ανάκληση (0.62). Ο LSTM ακολουθεί με μέσο F1 0.44, ενώ ο AE φτάνει το 0.43. Αντίθετα, οι δυναμικές εκδοχές αυτών των αλγορίθμων υποφέρουν σημαντικά στην μέση ακρίβεια — π.χ. AE και LSTM με δυναμικό όριο παρουσιάζουν υψηλή μέση ανάκληση (0.67 και 0.60 αντίστοιχα), αλλά με πολύ χαμηλή μέση ακρίβεια, οδηγώντας σε αισθητή μείωση της βαθμολογίας F1. Τέλος, το γραμμικό μοντέλο (LM) βγάζει τακτικά χαμηλά αποτελέσματα. Έτσι, παρατηρείται ότι σε όλες τις περιπτώσεις, η αποτασιοποίηση του συνόλου (όπως φαίνεται ξεκάθαρα και από το ραβδόγραμμα) ευνόησε περισσότερο τις στατικές εκδοχές των αλγορίθμων, έναντι των δυναμικών.

5.1.2 Σύγκριση A1D με την Αποτασιοποιημένη Μορφή του

Η αποτασιοποίηση του συνόλου A1D, (δημιουργία A1DD) επέτρεψε την απομάκρυνση μακροπρόθεσμων τάσεων, διευκολύνοντας θεωρητικά τον εντοπισμό πιο "καθαρών" ανωμαλιών. Η επίδραση της προεπεξεργασίας αυτής αξιολογήθηκε συγκρίνοντας την επίδοση κάθε αλγορίθμου πριν και μετά, υπό στατικό και δυναμικό όριο.

Η αποτασιοποίηση, όπως φαίνεται στο Διάγραμμα 5.7, συνοδευόμενο από τον αντίστοιχο Πίνακα 5.6, που δηλώνει τη στατιστική σημαντικότητα, είχε θετικά αποτελέσματα για τον Αυτοκωδικοποιητή (AE), με αύξηση του μέσου F1 κατά 47.69% στο στατικό και 44.05% στο δυναμικό όριο, δείχνοντας ότι το μοντέλο επωφελείται σημαντικά όταν αφαιρεθούν τα μακροπρόθεσμα μοτίβα της τάσης. Παρόμοια ενίσχυση παρατηρείται και στον XGBoost με στατικό όριο (+52.37%), σε αντίθεση με τη μείωση στην απόδοση του με δυναμικό όριο (-17.53%), γεγονός που φανερώνει ότι η αποτασιο-


ποίηση δεν συνδυάζεται αποτελεσματικά με ευαίσθητα προσαρμοστικά δυναμικά όρια.

Η απόδοση του MLP και LSTM μειώθηκε ελαφρώς και στις δύο ρυθμίσεις, πιθανώς διότι αυτά τα μοντέλα στηρίζονται σε πολύπλοκα χρονικά μοτίβα, τα οποία αλλοιώνονται με την απομάκρυνση της τάσης. Ιδιαίτερο ενδιαφέρον παρουσιάζει το γραμμικό μοντέλο (LM), το οποίο εμφάνισε σταθερή βελτίωση και στα δύο σενάρια — με μέση αύξηση έως 27.39% στο δυναμικό όριο — υποδεικνύοντας ότι γραμμικά μοντέλα μπορεί να ωφελούνται από τέτοιου είδους προεπεξεργασία, που είναι κατανοητό, διότι τεχνικά από μόνα τους δεν μπορούν να αναγνωρίσουν την τάση. Βέβαια, το LM παρουσιάζει τα χειρότερα αποτελέσματα από όλους τους αλγόριθμους, όπως αναφέρθηκε (εξαιρουμένου του δυναμικού XGboost).

Αλγόριθμος	Static (%)	Wilcoxon (W, p)	Dynamic (%)	Wilcoxon (W, p)
AE	+47.69%	10.000, p = 1.0000 (X)	+44.05%	2.000, p = 0.1380 (X)
MLP	-11.73%	8.000, p = 0.6875 (X)	-13.20%	5.000, p = 0.5002 (X)
LSTM	-0.88%	6.000, p = 0.4375 (X)	-1.82%	7.000, p = 0.5625 (X)
XGBoost	+52.37%	1.000, p = 0.1441 (X)	-17.53%	7.000, p = 0.5625 (X)
LM	+5.78%	3.000, p = 0.4652 (X)	+27.39%	5.000, p = 0.3125 (X)

X: Μη στατιστικά σημαντική διαφορά (p > 0.05)


Πίνακας 5.6: Ποσοστιαίες μεταβολές και Wilcoxon για το A1D vs A1DD (αποτασιοποιημένο).



Διάγραμμα 5.7: Ραβδόγραμμα μεταβολών απόδοσης για στατικά και δυναμικά όρια, A1D vs A1DD.

Συμπερασματικά, η αποτασιοποίηση του A1D ευνόησε αλγορίθμους που βασίζονται σε τοπικές μεταβολές, όπως ο AE και ο XGBoost, διευκολύνοντας την ανίχνευση ανωμαλιών. Αντίθετα, σε μοντέλα όπως τα LSTM και MLP η επίδοση μειώθηκε, πιθανόν επειδή η χρήση παραθύρων σταθερού μεγέθους (κυλιόμενο παράθυρο 24 σημείων) περιορίσε την αξιοποίηση μακροχρόνιων μοτίβων, καθιστώντας την τάση έμμεσα χρήσιμη.

Το Διάγραμμα 5.8, που απεικονίζει τη σχέση μέσης ακρίβειας-ανάκλησης για το σύνολο δεδομένων A1D πριν και μετά την αποτασιοποίηση, υπό στατικά και δυναμικά όρια, προσφέρει μια πιο



Διάγραμμα 5.8: Διάγραμμα Μέσης Ακρίβειας-Ανάκλησης για τους αλγορίθμους του A1D έναντι των εκδοχών της αποτασιοποιημένης έκδοσής του.

ποιοτική απεικόνιση της συμπεριφοράς κάθε αλγορίθμου. Παρατηρείται ότι η αποτασιοποίηση ευνοεί κυρίως αλγορίθμους που βασίζονται σε απλούστερες ή πιο τοπικές παραδοχές, όπως το γραμμικό μοντέλο (LM), ο Αυτοκωδικοποιητής (AE) και ο XGBoost με στατικό όριο.


Αντίθετα, ο MLP αποδίδει καλύτερα στο αρχικό (μη αποτασιοποιημένο) A1D, ενώ ο LSTM παρουσιάζει μικρές διαφοροποιήσεις: η στατική του εκδοχή εμφανίζει υψηλότερη μέση ακρίβεια στο αποτασιοποιημένο σύνολο, με ελαφρώς μειωμένη μέση ανάκληση, ενώ το αντίστροφο ισχύει για τη δυναμική εκδοχή του. Ιδιαίτερα εντυπωσιακή είναι η επίδοση του XGBoost με στατικό όριο, ο οποίος, μετά την αποτασιοποίηση, καταγράφει με διαφορά την καλύτερη συνολική απόδοση — ενώ στο αρχικό A1D είχε από τις χαμηλότερες.

Ωστόσο, το διάγραμμα δεν αναδεικνύει τόσο έντονα τη διαφορά που προκαλεί η αποτασιοποίηση, όσο εκείνη που οφείλεται στη χρήση στατικού έναντι δυναμικού ορίου. Οι αλγόριθμοι με στατικό όριο εμφανίζουν σαφώς υψηλότερες τιμές μέσης ακρίβειας, έστω κι αν αυτό συνοδεύεται από μείωση στην μέση ανάκληση. Το γεγονός αυτό υποδηλώνει ότι, παρότι εντοπίζουν λιγότερες ανωμαλίες, αυτές είναι κατά κύριο λόγο έγκυρες — στοιχείο ιδιαίτερα σημαντικό σε εφαρμογές όπου οι ψευδώς θετικές ανιχνεύσεις έχουν σημαντικό κόστος. Αξίζει, τέλος, να σημειωθεί ότι η μέγιστη μέση ακρίβεια που καταγράφηκε στο διάγραμμα φτάνει μόλις το 0.6, αναδεικνύοντας τις προκλήσεις του συγκεκριμένου συνόλου δεδομένων.


5.1.3 Συγκεντρωτική Ανάλυση Yahoo A1

Η συγκεντρωτική ανάλυση των F1-score για όλα τα υποσύνολα (A1A–A1D), στο Διάγραμμα 5.9(i), αναδεικνύει σημαντικά ευρήματα ως προς τη συνολική αξιοπιστία και ευελιξία των αλγορίθμων ανίχνευσης ανωμαλιών. Πρώτο σε απόδοση κατατάσσεται το Δάσος Απομόνωσης (IF) με χρονικά

χαρακτηριστικά, με μέση βαθμολογία F1 0.55, αποδεικνύοντας τη σταθερότητα του αλγορίθμου όταν εμπλουτίζεται με χρονική πληροφορία. Ακολουθούν στατιστικές μέθοδοι πρόβλεψης με στατικό όριο HWEST και SARIMA, με μέσο F1 0.55 και 0.50 αντίστοιχα, δείχνοντας τη σταθερά υψηλή απόδοσή τους σε όλα τα σύνολα δεδομένων και ο στατικός XGboost με βαθμολογία 0.50, ίδια με του SARIMA.



(i) Συγκεντρωτική απόδοση μοντέλων ως προς το μέσο F1.



(ii) Ανάλυση διακύμανσης μεταβολής, ως προς τη διάμεσο του F1.

Διάγραμμα 5.9: Συγκεντρωτικά αποτελέσματα και διακύμανση ανά μοντέλο.

Εντυπωσιακό είναι το γεγονός ότι η στατική παραμετροποίηση (πράσινες μπάρες) κυριαρχεί στην κορυφή του διαγράμματος, ενώ οι περισσότερες δυναμικές εκδοχές (μωβ μπάρες) εμφανίζονται χαμηλότερα — ενδεικτικό ότι σε συνθήκες αυξημένης ετερογένειας, όπως στα Yahoo υποσύνολα, η χρήση σταθερών ορίων προσφέρει καλύτερη γενίκευση. Παράλληλα, οι αλγόριθμοι με μη χρονικά χαρακτηριστικά (πορτοκαλί μπάρες) όπως ο LOF ή ο DBSCAN παρουσιάζουν μέτρια απόδοση, γεγονός που δείχνει ότι σε datasets με έντονη χρονική εξάρτηση, η ενσωμάτωση χρονικών χαρακτηριστικών ευνοείται. Επίσης ενδιαφέρουσα είναι η συνολική απόδοση του OCSVM με χρονικά χαρακτηριστικά, που ενώ κυριαρχεί στα σύνολα δεδομένων A1C, A1D, είναι ο τελευταίος σε απόδοση αλγόριθμος μηχανικής μάθησης, γεγονός που υποδεικνύει την κακή του απόδοση στα σύνολα A1A, A1B, αλλά και την χαμηλή τιμή μέσης F1 βαθμολογίας του A1D.

Οι μέθοδοι βαθιάς μάθησης (LSTM, AE, MLP) παρουσιάζουν μικτή εικόνα. Ο στατικός LSTM παραμένει ανταγωνιστικός (0.46) μαζί με το στατικό MLP (0.46), ενώ η δυναμική του μορφή πέφτει στα 0.39. Αντίθετα, ο Αυτοκωδικοποιητής, ειδικά στην στατική εκδοχή του, καταγράφει την χαμηλότερη συνολική μέση απόδοση (0.32), γεγονός που υποδηλώνει την αδυναμία του μοντέλου στο συγκεκριμένο πρόβλημα. Τέλος, το Προφίλ Πίνακα βρίσκεται στη μέση της κατάταξης με μέσο $F1 = 0.42$, παραμένοντας σταθερός αλλά όχι εντυπωσιακός σε όλα τα υποσύνολα.

Συνολικά, τα ραβδογράμματα αναδεικνύουν την αξία της απλότητας: μοντέλα με στατικό όριο και βασική χρονική ενίσχυση (όπως IF και HWEST) υπερέχουν σε ευρύτερη γκάμα συνθηκών, ενώ οι πιο "έξυπνοι" αλγόριθμοι (βαθιάς μάθησης ή δυναμικά όρια) συχνά υπολείπονται λόγω υπερεκπαίδευσης ή κακής ρύθμισης.

Τα θηκογράμματα που απεικονίζουν τις κατανομές των $F1$ βαθμολογιών όλων των αλγορίθμων σε όλα τα σύνολα δεδομένων του Yahoo (A1A–A1D), στο Διάγραμμα 5.9(ii), προσφέρουν σημαντική πληροφορία για τη σταθερότητα των μοντέλων, πέραν της μέσης απόδοσης. Σημειώνεται ότι τα θηκογράμματα είναι ταξινομημένα ως προς τη διάμεσο του $F1$ και όχι το μέσο.

Ορισμένοι αλγόριθμοι, όπως οι στατικοί HWEST και SARIMA, όπως και ο IF με χρονικά χαρακτηριστικά, όχι μόνο καταγράφουν υψηλή διάμεσο $F1$ score, αλλά παρουσιάζουν και σχετικά συμπεσιμένα κουτιά (μικρή διακύμανση), υποδηλώνοντας συνεπή και προβλέψιμη συμπεριφορά σε όλα τα υποσύνολα. Αντίθετα, αλγόριθμοι όπως ο XGBoost με στατικό όριο ή ο DBSCAN χωρίς χρονικά χαρακτηριστικά εμφανίζουν μεγάλη διασπορά στις τιμές τους, δηλώνοντας ότι, παρότι μπορεί να επιτυγχάνουν υψηλά αποτελέσματα σε κάποια υποσύνολα (π.χ. A1A), υπολείπονται σε άλλα (π.χ. A1D). Παρόμοια λειτουργία έχει και ο OCSVM με χρονικά χαρακτηριστικά, ο οποίος στα A1C, A1D είναι κυρίαρχος, ενώ στα υπόλοιπα έχει κακή απόδοση. Παραπλήσια ακραία αστάθεια παρουσιάζουν ο IF χωρίς χρονικά χαρακτηριστικά, ο αλγόριθμος του Προφίλ Πίνακα και ο AE γενικότερα, με την περίπτωση του στατικού ορίου να είναι η χειρότερη. Βέβαια, ο στατικός XGboost, μπορεί να έχει υψηλή διακύμανση, αλλά ο διάμεσος βρίσκεται στη μέση του θηκογράμματος, αντιθέτως με το DBSCAN, το MP και τον AE, που οι διάμεσοι βρίσκονται προς τα κάτω, παρατήρηση που υποδηλώνει ότι οι τιμές που βρίσκονται πάνω από τη διάμεσο είναι διάσκορπες.

Παρατηρείται, επίσης, ότι οι δυναμικές εκδοχές των περισσότερων αλγορίθμων (μωβ κουτιά) έχουν πολύ μικρότερη διακύμανση από τις στατικές, αλλά παρουσιάζουν και πολύ πιο χαμηλές βαθμολογίες, με πιο έντονους αλγόριθμους που το παρουσιάζουν να είναι οι LM και XGboost.

Συνολικά, το γράφημα επιβεβαιώνει ότι μοντέλα με απλή, στατική παραμετροποίηση και χρονική ενίσχυση, όπως το HWEST, το SARIMA ή το IF, συνδυάζουν υψηλή μέση απόδοση με σταθερή συμπεριφορά, καθιστώντας τα πιο αξιόπιστες επιλογές στις σχετικά μικρού μεγέθους χρονοσειρές του Yahoo A1.

5.1.4 Προβλήματα στην Υλοποίηση

Κατά την ανάλυση των αποτελεσμάτων, παρατηρήθηκαν φαινόμενα υπερεκπαίδευσης (*overfitting*) και υποεκπαίδευσης (*underfitting*) στους αλγορίθμους LSTM και XGBoost, κυρίως σε επιμέρους υποσύνολα του συνόλου δεδομένων Yahoo A1. Παρότι πρόκειται για θεωρητικά ισχυρούς αλγορίθμους, ικανούς να μοντελοποιήσουν μη γραμμικά και χρονικά εξαρτώμενα μοτίβα, η αποτελεσματικότητά τους εξαρτάται σε μεγάλο βαθμό από την επάρκεια και την ποικιλία των δεδομένων εκπαίδευσης, προκειμένου να επιτευχθεί σωστή γενίκευση.

Στην παρούσα μελέτη, ο σχετικά μικρός αριθμός παρατηρήσεων ανά χρονοσειρά (περίπου 1400 χρονικά σημεία), σε συνδυασμό με τον περιορισμένο όγκο του εκπαιδευτικού συνόλου, ώστε να διατηρηθεί η δυνατότητα εντοπισμού ανωμαλιών στο σύνολο δοκιμής, οδήγησε σε δυσκολίες στη γενίκευση των μοντέλων. Συγκεκριμένα, παρατηρήθηκε ότι, σε περιπτώσεις ύπαρξης θορύβου, τα μοντέλα προσαρμόζονταν υπερβολικά στα δεδομένα εκπαίδευσης, ενώ σε πιο "καθαρές" περιπτώσεις, δεν κατάφερναν να μάθουν επαρκώς τη δομή των δεδομένων, οδηγώντας σε υποεκπαίδευση. Το πρόβλημα ήταν ιδιαίτερα έντονο στο LSTM, καθώς πρόκειται για ένα νευρωνικό δίκτυο με σύνθετη αρχιτεκτονική, το οποίο απαιτεί σημαντικά μεγαλύτερο όγκο δεδομένων για να εκπαιδευτεί σωστά και να αποφύγει την υπερπροσαρμογή ή την ανεπαρκή μάθηση.

Τέλος, ο αλγόριθμος Προφίλ Πίνακα παρουσίασε σχετικά χαμηλές επιδόσεις, κυρίως λόγω της μεθόδου επιλογής ορίου ανίχνευσης. Σε αρκετές περιπτώσεις με έντονες ανωμαλίες, όπως στο υποσύνολο A1A, κατά τον υπολογισμό του Προφίλ Πίνακα χρησιμοποιήθηκε ένα στατικό όριο για την επιλογή των υψηλών τιμών προβλεπτικής συνάφειας. Ωστόσο, το όριο αυτό συχνά εντόπιζε και γειτονικά σημεία γύρω από την πραγματική ανωμαλία, τα οποία δεν χαρακτηρίζονται ως ανωμαλίες στο ground truth. Αυτό οδήγησε σε υπερανίχνευση και τελικά σε μείωση της βαθμολογίας F1. Σε άλλα υποσύνολα, η χαμηλή απόδοση του αλγορίθμου αποδόθηκε απλώς στην αδυναμία του να μοντελοποιήσει επαρκώς τα μοτίβα της χρονοσειράς, ανεξαρτήτως της επιλογής ορίου.

5.1.5 Σύνολο Δεδομένων New York City Taxi

Το σύνολο δεδομένων NYC Taxi αποτελεί ένα διαφορετικού τύπου σενάριο σε σχέση με τα σύνολα του Yahoo Webscope S5, καθώς περιλαμβάνει μία μακρά χρονοσειρά αφίξεων ταξί στην περιοχή της Νέας Υόρκης, με χρονική ανάλυση ανά 30 λεπτά και διάρκεια περίπου 6 μηνών. Εδώ, οι ανωμαλίες σχετίζονται με ημερομηνίες υψηλής ζήτησης ταξί (όπως Πρωτοχρονιά ή ο μαραθώνιος της Νέας Υόρκης) και χαρακτηρίζονται από έντονες απότομες αυξήσεις σε αυτή.

Για την αξιολόγηση των αλγορίθμων εφαρμόστηκαν οι μετρικές ακρίβειας, ανάκλησης και βαθμολογίας F1, ενώ παράλληλα χρησιμοποιήθηκε και μια εναλλακτική βαθμολογία ειδικά σχεδιασμένη για το συγκεκριμένο σενάριο, που υπάρχουν ανωμαλίες παραθύρων, η βαθμολογία NAB. Η NAB (Numenta Anomaly Benchmark) βαθμολογία λαμβάνει υπόψη τη χρονική στιγμή της ανίχνευσης και

"τιμωρεί" καθυστερημένες ή πρόωρες ανιχνεύσεις, προσφέροντας μια πιο "λειτουργική" αποτίμηση. Επίσης, μετρήθηκε και το πλήθος παραθύρων ανωμαλίας που εντοπίστηκαν από κάθε αλγόριθμο, δίνοντας επιπλέον πληροφορία για την συμπεριφορά ευαισθησίας του μοντέλου.

Για την ανάλυση των αποτελεσμάτων (το συγκεκριμένο σύνολο δεδομένων αποτελεί μια χρονοσειρά, οπότε δεν γίνεται αναφορά σε μέση τιμή μετρικών) κατασκευάστηκαν ένα διάγραμμα ακρίβειας-ανάκλησης (Precision–Recall plot), ένα γράφημα διασποράς που απεικονίζει τη συσχέτιση μεταξύ της βαθμολογίας NAB και του αριθμού παραθύρων που εντοπίστηκαν (*Windows Found*), καθώς και ένας πίνακας συσχέτισης (*correlation matrix*) μεταξύ των επιμέρους μετρικών. Αυτή η πολυπαραγοντική προσέγγιση επιτρέπει την αξιολόγηση όχι μόνο της απόδοσης, αλλά και της συμπεριφοράς των αλγορίθμων, π.χ. αν "εντοπίζουν σωστά" αλλά με υπερβολικά πολλές λανθασμένες ανωμαλίες, αλλά και χρησιμοποιούνται οι κλασσικές μετρικές, ώστε να μπορούν να ερμηνευτούν σωστά οι λειτουργίες τους. Στα γραφήματα διασποράς (Διάγραμμα 5.10), οι αλγόριθμοι χωρίστηκαν σε αυτούς της μηχανικής μάθησης με χρονικά χαρακτηριστικά (μπλε χρώμα), σε αυτούς χωρίς (πορτοκαλί χρώμα) και στους αλγορίθμους που χρησιμοποιούν στατικό όριο για να ανιχνεύσουν τις ανωμαλίες (πράσινο χρώμα).

NYC TAXI NAB

Αλγόριθμοι	P	R	F1	NAB Score	Παράθυρα που βρέθηκαν
SARIMA	0.50	0.00	0.01	-5	{1} - 1
HWEST	0.89	0.19	0.31	-63	{1,5} - 2
LM	0.17	0.02	0.03	-69	{1,2,3,4,5} - 5
MP 98% THRES ¹	1.00	0.20	0.33	4	{1,3,4,5} - 4
MP 96% THRES ²	0.88	0.35	0.50	-46	{1,2,3,4,5} - 5
MLP	0.71	0.03	0.06	-10	{1,3,4,5} - 4
LSTM	0.89	0.06	0.11	-5	{1,3,4,5} - 4
AE	0.99	0.11	0.2	2	{1,3,4,5} - 4
XGBoost	0.53	0.05	0.09	-40	{1,2,3,4,5} - 5

Πίνακας 5.7: Αποτελέσματα Precision, Recall, F1 και NAB score στη χρονοσειρά NYC TAXI NAB για τους αλγορίθμους χωρίς χρονικά χαρακτηριστικά.

Η αξιολόγηση των αλγορίθμων στη χρονοσειρά του NYC Taxi, η οποία περιλαμβάνει πέντε γνωστά παράθυρα ανωμαλίας, αποκαλύπτει κρίσιμες διαφορές τόσο στην ικανότητα εντοπισμού όσο και στη λειτουργική αποτελεσματικότητα των μεθόδων. Από τον Πίνακα 5.7 παρατηρείται ότι ο αλγόριθμος Προφίλ Πίνακα με 98% στατικό όριο, έχει 1.00 ακρίβεια, οπότε όσες ανωμαλίες έχει εντοπίσει, είναι όντως ανωμαλίες. Επίσης, το Προφίλ Πίνακα με 98% όριο παρουσιάζει και την καλύτερη βαθμολογία NAB μεγέθους 4, έχοντας εντοπίσει 4 παράθυρα, αδυνατώντας να εντοπίσει το δεύτερο παράθυρο ανωμαλίας της χρονοσειράς, την Ημέρα των Ευχαριστιών, που αποτελεί και την πιο δύσκολη ανωμαλία (σημειώνεται ότι για το Προφίλ Πίνακα στο NYC έγινε χρήση διαφορετικών τιμών κυλιόμενου παραθύρου `window_sizes = [48, 2 * 48, 3 * 48, 4 * 48, 5 * 48]`, που συν-

¹ Το 98% threshold ορίζει τις ανωμαλίες ως τις κορυφές του προφίλ απόστασης που ξεπερνούν το 98ο εκατοστημόριο.

² Το ίδιο, για το 96ο εκατοστημόριο

δέονται άμεσα, με την εποχικότητα της χρονοσειράς. Το βέλτιστο κυλιόμενο παράθυρο βρέθηκε ότι είναι μεγέθους 48, όπως και η κυρίαρχη εποχικότητα). Παράλληλα, το Προφίλ Πίνακα με 96% στατικό όριο, αν και είχε μικρότερη ακρίβεια, πέτυχε τη μεγαλύτερη ανάκληση και βαθμολογία F1 από τους υπόλοιπους αλγόριθμους του πίνακα, βρίσκοντας όλα τα παράθυρα, αλλά κάνοντας αρκετές λάθος ανιχνεύσεις έχοντας βαθμολογία NAB -46. Παρόμοιο αποτέλεσμα είχε και το γραμμικό μοντέλο (LM) το οποίο εντόπισε όλες τις ανωμαλίες, αλλά με πολλές λανθασμένες ανιχνεύσεις, αποκτώντας βαθμολογία NAB -69. Σε γενικές γραμμές παρατηρείται ότι όλοι οι αλγόριθμοι παρουσιάζουν πολύ χαμηλή ανάκληση και συνεπώς F1 βαθμολογία, αλλά, εξαιρουμένου του γραμμικού μοντέλου, οι αλγόριθμοι παρουσιάζουν ικανοποιητική ακρίβεια άνω του 0.50. Τέλος, αμέσως υψηλότερη βαθμολογία NAB παρουσιάζει ο Αυτοκωδικοποιητής με τιμή 2, έχοντας βρει τέσσερα παράθυρα.

NYC TAXI NAB

TEMP					
Αλγόριθμος	P	R	F1	NAB Score	Παράθυρα
IF	1.00	0.05	0.10	4	{1,3,4,5} - 4
LOF	0.70	0.01	0.03	-3	{1,4,5} - 3
OCSVM	0.82	0.43	0.56	-82	{1,2,3,4,5} - 5
DBSCAN	0.99	0.10	0.18	4	{1,2,3,4,5} ³ - 5

NO TEMP					
Αλγόριθμος	P	R	F1	NAB Score	Παράθυρα
IF	0.63	0.03	0.06	-15	{1,3,4,5} - 4
LOF	0.10	0.48	0.17	-4243	{1,2,3,4,5} ⁴ - 5
OCSVM	0.32	0.04	0.08	-90	{1,3,4,5} - 4
DBSCAN	1.00	0.00	0.00	1	{1} ⁵ - 1

Πίνακας 5.8: Αποτελέσματα Precision, Recall, F1 και NAB score στη χρονοσειρά NYC TAXI NAB για τους αλγόριθμους με χρονικά χαρακτηριστικά.

Ο Πίνακας 5.8, περιλαμβάνει τους αλγόριθμους μηχανικής μάθησης, για τους οποίους έγινε χρήση χρονικών χαρακτηριστικών, ώστε να συγκριθούν με τις αρχικές εκδοχές τους. Αμέσως, παρατηρείται ότι οι αλγόριθμοι που εντοπίζουν όλα τα παράθυρα είναι οι OCSVM και DBSCAN με χρονικά χαρακτηριστικά, με τους χρονικούς DBSCAN και IF να παρουσιάζουν την υψηλότερη βαθμολογία NAB μεγέθους 4. Όμως, ο IF αδυνατεί να βρει το δεύτερο παράθυρο ανωμαλίας της χρονοσειράς. Από την άλλη, οι αλγόριθμοι χωρίς χρονικά χαρακτηριστικά, εμφανίζουν πολύ χαμηλές βαθμολογίες NAB, με τον καλύτερο να είναι τον DBSCAN, με βαθμολογία 1, εντοπίζοντας απλά ένα παράθυρο ανωμαλίας (το πρώτο παράθυρο, που αποτελεί τον μααραθώνιο της Νέας Υόρκης και είναι η πιο ξεκάθαρη ακραία τιμή), χωρίζοντας τη χρονοσειρά σε 2 ομάδες (clusters). Προφανώς, έχοντας εντοπίσει μόνο αυτό, έχει και ακρίβεια μεγέθους 1. Από την άλλη, ο LOF, έχει υψηλή ανάκληση και F1 βαθμολογία, εντοπίζοντας και τα 5 παράθυρα ανωμαλιών, αλλά έχει κάκιστη απόδοση NAB, μεγέθους -4243, γεγονός που καταδεικνύει ότι δεν είναι ικανός σαν αλγόριθμος να διαχωρίσει ορθά τις ανωμαλίες. Γι'

³Μόνο μια λανθασμένη ανίχνευση

⁴Εντοπίζει "τυφλά" ανωμαλίες

⁵Χωρίζει το σύνολο δεδομένων σε δύο ομάδες - την ανωμαλία και τα κανονικά σημεία

αυτό τον λόγο, γίνεται αποκλεισμός του συγκεκριμένου αλγορίθμου από την περαιτέρω μελέτη των αποτελεσμάτων.


Το διάγραμμα της βαθμολογίας NAB σε συνάρτηση με τον αριθμό εντοπισμένων παραθύρων για τη NYC Taxi χρονοσειρά (Διάγραμμα 5.10(i)) αναδεικνύει τη διάκριση μεταξύ ποσότητας και ποιότητας εντοπισμού. Παρατηρείται ότι η πλήρης κάλυψη των παραθύρων (5/5) δεν συνεπάγεται απαραίτητα και υψηλή NAB βαθμολογία. Ενδεικτικά, αλγόριθμοι όπως οι OCSVM με χρονικά χαρακτηριστικά, XGBoost, γραμμικό μοντέλο (LM) και Προφίλ Πίνακα με στατικό όριο 96% , παρά την απόλυτη κάλυψη των ανωμαλιών, εμφανίζουν αρνητικές NAB βαθμολογίες (-80 έως -40). Το γεγονός αυτό υποδηλώνει είτε κακή χρονική στόχευση (π.χ. καθυστερημένες ή πρόωρες ανιχνεύσεις), σε συνδυασμό με υπερανίχνευση.

Αντιθέτως, αλγόριθμοι όπως το Δάσος Απομόνωσης (IF) με χρονικά χαρακτηριστικά, Αυτοκωδικοποιητής και το Προφίλ Πίνακα με στατικό όριο 98%, αν και εντοπίζουν μόνο 4 από τα 5 παράθυρα, καταγράφουν θετικές NAB βαθμολογίες, γεγονός που υποδηλώνει ότι, σε αυτό το περιβάλλον, η ικανότητα ενός μοντέλου να εντοπίζει εγκαίρως και με ακρίβεια τις ανωμαλίες — χωρίς να ενεργοποιείται αδικαιολόγητα — είναι πιο σημαντική από το να εντοπίζει απλώς κάθε πιθανό περιστατικό, ανεξαρτήτως χρονισμού ή αξιοπιστίας. Ο μοναδικός αλγόριθμος ο οποίος κατάφερε επακριβώς να εντοπίσει τις όλες τις ανωμαλίες και με υψηλή βαθμολογία NAB είναι ο χρονικός DBSCAN.


Παρατηρείται ότι οι μοναδικοί αλγόριθμοι που βασίζονται σε στατικά όρια και εντοπίζουν λιγότερα από τρία παράθυρα ανωμαλιών είναι οι στατιστικοί αλγόριθμοι, όπως ο SARIMA και ο Holt-Winters (HWE). Ο HWE εντοπίζει δύο παράθυρα, αλλά παρουσιάζει πολύ χαμηλή βαθμολογία NAB (-63), γεγονός που υποδηλώνει την παρουσία πολλών ψευδών ενεργοποιήσεων ή χρονικά λανθασμένων εντοπισμών. Ομοίως, ο SARIMA καταγράφει μία μόνο ανωμαλία με αρνητική NAB, φανερώνοντας την αδυναμία του να ανταποκριθεί αποτελεσματικά σε ένα σχετικά σύνθετο και μη-γραμμικό σύνολο δεδομένων. Αντίθετα, ο LOF με χρονικά χαρακτηριστικά επιτυγχάνει έναν ικανοποιητικό συμβιβασμό: εντοπίζει τρία παράθυρα με μικρή NAB ποιότητα, γεγονός που υποδηλώνει περιορισμένες λανθασμένες ανιχνεύσεις και καλύτερη χρονική ακρίβεια. Τέλος, μοντέλα όπως ο DBSCAN χωρίς χρονικά χαρακτηριστικά και ο SARIMA, τα οποία εντοπίζουν μόλις ένα παράθυρο, καταγράφουν NAB βαθμολογίες κοντά στο μηδέν, φανερώνοντας περιορισμένη λειτουργική χρησιμότητα, καθώς αποτυγχάνουν τόσο στην κάλυψη όσο και στη χρονική συνέπεια.

Συνολικά, το διάγραμμα δείχνει ότι το να εντοπίζει ένας αλγόριθμος πολλά παράθυρα ανωμαλιών δεν αρκεί για να θεωρηθεί αποδοτικός. Αυτό που έχει μεγαλύτερη σημασία είναι ο συνδυασμός καλής κάλυψης (εύρεσης παραθύρων ανωμαλιών), σωστού χρονισμού και περιορισμού των ψευδών συναγερμών — στοιχεία που αποτυπώνονται συνολικά μέσω της NAB βαθμολογίας και αντανακλούν πιο ρεαλιστικά την πραγματική του απόδοση.

Το διάγραμμα ακρίβειας έναντι ευαισθησίας (precision vs recall) (Διάγραμμα 5.10(ii)) αποτυπώνει με σαφήνεια τις στρατηγικές συμπεριφοράς των αλγορίθμων σε ένα ρεαλιστικό σενάριο ανωμαλιών.



(i) Σύγκριση NAB Score και εντοπισμένων παραθύρων ανά κατηγορία.




(ii) Διάγραμμα Ακρίβειας έναντι Ανάκλησης.

Διάγραμμα 5.10: Σύγκριση απόδοσης αλγορίθμων στο σύνολο δεδομένων NYC Taxi μέσω διαφορετικών μετρικών.

Ένα σημαντικό μέρος των μοντέλων συγκεντρώνεται στην περιοχή πολύ υψηλής ακρίβειας (άνω του 0.95), όπως οι DBSCAN (με και χωρίς χρονικά χαρακτηριστικά), ο AE, ο MP με όριο 98% και ο χρονικός IF. Αυτό φανερώνει μια κοινή προσέγγιση «συντηρητικού εντοπισμού», όπου οι αλγόριθμοι σηματοδοτούν ανωμαλία μόνο όταν υπάρχει υψηλή βεβαιότητα, αποφεύγοντας ψευδώς θετικά, αλλά με κόστος στη συνολική ανάκληση ($\text{recall} < 0.20$) — κάτι το οποίο είναι αναμενόμενο, δεδομένου ότι στο σύνολο δεδομένων υπάρχουν παραθυρικές ανωμαλίες, και όχι σημειακές. Οι MP με 96% όριο και ο χρονικός OCSVM εμφανίζονται ως οι μόνοι που προσεγγίζουν σχετικά υψηλότερη ευαισθησία (έως 0.35 και 0.43 αντίστοιχα), αλλά παράλληλα διατηρούν υψηλή ακρίβεια άνω του 0.8. Αλγόριθμοι όπως οι XGBoost, SARIMA και LM κατατάσσονται χαμηλά και στους δύο άξονες, γεγονός που επιβεβαιώνει την περιορισμένη αποτελεσματικότητά τους στο συγκεκριμένο πλαίσιο. Το γράφημα συνολικά αναδεικνύει ότι η πολύ υψηλή ακρίβεια δεν συνεπάγεται απαραίτητα ολοκληρωμένη κάλυψη, ούτε όμως απαιτείται εξίσου υψηλή ανάκληση. Αντιθέτως, σε δεδομένα με παράθυρα ανωμαλιών, η

στοχευμένη, έγκαιρη και αξιόπιστη ανίχνευση έστω και μέρους των ανωμαλιών — με όσο το δυνατόν λιγότερα ψευδώς θετικά — είναι συχνά πιο επιθυμητή από την εξαντλητική κάλυψη όλων των περιστατικών.



Διάγραμμα 5.11: Πίνακας συσχέτισης μετρικών αξιολόγησης αλγορίθμων στο NYC Taxi σύνολο δεδομένων.

Ο πίνακας συσχέτισης Pearson των μετρικών αξιολόγησης για τη NYC Taxi χρονοσειρά, από το Διάγραμμα 5.11) αναδεικνύει με ποσοτικό τρόπο τις σχέσεις μεταξύ των βασικών ποσοτικών δεικτών απόδοσης. Η ισχυρότερη θετική συσχέτιση καταγράφεται ανάμεσα στην ανάκληση και τη βαθμολογία F1 (0.99), γεγονός αναμενόμενο, καθώς το F1 εξαρτάται άμεσα από την ανάκληση όταν η ακρίβεια διατηρείται σταθερή και δεδομένου ότι οι ανωμαλίες στην χρονοσειρά παρουσιάζονται ως παράθυρα. Αντίθετα, η ακρίβεια παρουσιάζει ασθενέστερη αλλά θετική συσχέτιση τόσο με το F1 (0.41) όσο και με τη βαθμολογία NAB (0.56), κάτι που επιβεβαιώνει πως η χρονική ακρίβεια των ανιχνεύσεων (που αξιολογείται από το NAB) συνδέεται περισσότερο με το πόσο “σωστά” ενεργοποιείται το μοντέλο παρά με το πόσα παράθυρα τελικά εντοπίζονται. Αντίθετα, η ανάκληση παρουσιάζει αρνητική συσχέτιση με τη βαθμολογία NAB (-0.41), υποδεικνύοντας ότι τα μοντέλα με υψηλή την πρώτη τείνουν να πυροδοτούν πιο επιθετικά, με αποτέλεσμα καθυστερημένες ή πολλαπλές ανιχνεύσεις, οι οποίες “τιμωρούνται” από τη συνάρτηση NAB. Παρόμοια και η βαθμολογία F1 έχει αρνητική συσχέτιση με τη βαθμολογία NAB (-0.37), γεγονός που δείχνει ότι το F1 από μόνο του δεν αποτελεί επαρκές μέτρο λειτουργικής ποιότητας σε σενάρια που η χρονική στιγμή έχει σημασία. Τέλος, ο αριθμός παραθύρων που εντοπίζονται (WINDOWS_FOUND) σχετίζεται μέτρια με την ανάκληση και το F1 (0.34), αλλά αρνητικά με το NAB (-0.26), επιβεβαιώνοντας και πάλι ότι η ποσότητα δεν είναι αρκετή όταν η ποιότητα (χρονισμός) των εντοπισμών δεν είναι κατάλληλη. Συνολικά, ο πίνακας υπογραμμίζει ότι η NAB βαθμολογία είναι λειτουργικά πιο αυστηρή και ευαίσθητη στην ακρίβεια, διαφοροποιούμενη από τις παραδοσιακές μετρικές που εστιάζουν κυρίως στη συνολική κάλυψη.

Παρόλο που ο αριθμός των παραθύρων που εντοπίστηκαν παρουσιάζει αρνητική συσχέτιση με τη βαθμολογία NAB, αυτό οφείλεται κυρίως στο γεγονός ότι αρκετοί αλγόριθμοι που κατάφεραν να εντοπίσουν όλα τα παράθυρα εμφάνισαν τελικά χαμηλές τιμές NAB, λόγω καθυστερημένων ή πολλαπλών ενεργοποιήσεων. Εξαίρεση αποτελεί ο χρονικά εξαρτώμενος αλγόριθμος DBSCAN, ο οποίος

εντόπισε με επιτυχία όλα τα παράθυρα ανωμαλιών, διατηρώντας ταυτόχρονα υψηλή NAB βαθμολογία, με μόλις μία λανθασμένη ανίχνευση. Το γεγονός αυτό αναδεικνύει ότι οι σημαντικότερες μετρικές που πρέπει να λαμβάνονται υπόψη για την αξιολόγηση των μοντέλων είναι η βαθμολογία NAB, η ακρίβεια, η οποία σχετίζεται θετικά με τη NAB, καθώς και ο αριθμός των παραθύρων που εντοπίστηκαν. Ένας αποδοτικός αλγόριθμος οφείλει να εντοπίζει όσο το δυνατόν περισσότερα παράθυρα (κάλυψη), να αποφεύγει τις ψευδείς θετικές ανιχνεύσεις (ακρίβεια), και να το πράττει με χρονική συνέπεια (υψηλή βαθμολογία NAB), διασφαλίζοντας έτσι την επιχειρησιακή αξιοπιστία της ανίχνευσης.

5.2 Συνολική Επισκόπηση Αποτελεσμάτων

Η παρούσα μελέτη εξετάζει την απόδοση διαφόρων τεχνικών ανίχνευσης ανωμαλιών σε χρονοσειρές, μέσα από μια εκτενή πειραματική αξιολόγηση σε τέσσερα υποσύνολα του Yahoo Webscope S5 (A1A–A1D), τα οποία περιλαμβάνουν διαφορετικούς τύπους ανωμαλιών: ακραίες τιμές, μετατοπίσεις μέσης τιμής, συσσωρευμένες αποκλίσεις και πολύπλοκες χρονικές διαταραχές. Αναλύθηκαν δύο κύριες κατηγορίες μεθόδων: αλγόριθμοι μηχανικής μάθησης (με και χωρίς χρονικά χαρακτηριστικά) και προβλεπτικά μοντέλα (με στατικά ή δυναμικά όρια απόφασης). Οι επιδόσεις αξιολογήθηκαν βάσει των μετρικών Ακρίβειας, Ανάκλησης, Βαθμολογίας F1, ενώ πραγματοποιήθηκε και στατιστική ανάλυση (Wilcoxon test) για την ανάδειξη σημαντικών διαφορών μεταξύ παραμετροποιήσεων.

Τα αποτελέσματα καταδεικνύουν ότι η αποτελεσματικότητα κάθε αλγορίθμου εξαρτάται σε μεγάλο βαθμό από τη φύση των ανωμαλιών του εκάστοτε συνόλου δεδομένων. Στο A1A, το οποίο περιλαμβάνει κυρίως σημειακές αποκλίσεις (ακραίες τιμές), παρατηρείται ότι οι μέθοδοι με στατικά κατώφλια υπερτερούν σαφώς έναντι εκείνων με δυναμικά, ενώ συνολικά οι κλασικές στατιστικές μέθοδοι (όπως οι HWEST και SARIMA) αποδίδουν καλύτερα από τις περισσότερες τεχνικές βαθιάς μάθησης (με εξαίρεση το γραμμικό μοντέλο, το οποίο εμφανίζει χαμηλές επιδόσεις). Παράλληλα, απλοί αλγόριθμοι μηχανικής μάθησης χωρίς χρονικά χαρακτηριστικά, όπως οι DBSCAN και το Δάσος Απομόνωσης, επιτυγχάνουν επίσης υψηλή απόδοση. Ο XGBoost διατηρεί σταθερά ανταγωνιστική παρουσία, προσαρμοζόμενος ικανοποιητικά σε διαφορετικές συνθήκες.

Αντίθετα, στο A1B — όπου οι ανωμαλίες σχετίζονται κυρίως με μεταβολές στη στατιστική δομή της χρονοσειράς (κυρίως αλλαγές επιπέδου) — υπερέχουν οι προβλεπτικοί αλγόριθμοι με δυναμικά όρια και οι μέθοδοι μηχανικής μάθησης που αξιοποιούν την χρονική πληροφορία. Από τις τεχνικές βαθιάς μάθησης, μόνο ο Αυτοκωδικοποιητής παρουσιάζει αισθητή υπεροχή, ενώ τα υπόλοιπα νευρωνικά δίκτυα, αν και εμφανίζονται ανταγωνιστικά, δεν ξεπερνούν τις επιδόσεις των παραδοσιακών μοντέλων.

Στο σύνολο A1C, οι περισσότεροι αλγόριθμοι καταγράφουν ικανοποιητικές επιδόσεις, με τον OCSVM που αξιοποιεί χρονικά χαρακτηριστικά να αναδεικνύεται ως ο αποδοτικότερος (μέσο F1 = 0.72). Οι παραδοσιακές στατιστικές μέθοδοι HWEST και SARIMA παρουσιάζουν επίσης αξιόλογα αποτελέσματα, ιδιαίτερα σε παραμετροποιήσεις με στατικά όρια, κυρίως λόγω της υψηλής τους μέσης

ακρίβειας. Συνολικά, δεν διαπιστώνεται ξεκάθαρη υπεροχή κάποιας μεθοδολογίας έναντι των άλλων. Παρ' όλα αυτά, με εξαίρεση το ιδιαίτερα ανταγωνιστικό LSTM, οι περισσότερες τεχνικές βαθιάς μάθησης — συμπεριλαμβανομένου του XGBoost — υπολείπονται σε μέση απόδοση σε σύγκριση με τις κλασικές στατιστικές προσεγγίσεις.

Στο A1D, οι επιδόσεις είναι γενικά χαμηλότερες, εξαιτίας της αυξημένης πολυπλοκότητας των χρονοσειρών. Καμία παραμετροποίηση δεν οδήγησε σε στατιστικά σημαντική βελτίωση. Ωστόσο, προβλεπτικοί αλγόριθμοι με στατικά όρια εμφάνισαν υψηλότερη μέση ακρίβεια, ενώ οι χρονικά εξαρτώμενοι αλγόριθμοι υπερτερούσαν στην μέση ανάκληση, οδηγώντας έτσι σε συγκριτικά υψηλότερη μέση βαθμολογία F1. Επίσης, σημειώνεται ότι στο A1D, οι τεχνικές βαθιάς μάθησης που αξιοποιούν ιστορική πληροφορία τείνουν να επιτυγχάνουν σε αρκετές περιπτώσεις ανώτερες επιδόσεις, επιβεβαιώνοντας την ικανότητά τους να συλλαμβάνουν τη μακροχρόνια δυναμική της χρονοσειράς. Γενικά, στα δύο τελευταία σύνολα (A1C και A1D), ο OCSVM αναδεικνύεται ως ο πιο συνεπής και αποδοτικός αλγόριθμος, ανεξαρτήτως παραμετροποίησης.

Η εφαρμογή γραμμικής αποτασιοποίησης (*linear detrending*) στο A1D ανέδειξε ότι η απομάκρυνση μακροπρόθεσμων τάσεων μπορεί να διευκολύνει την ανίχνευση ανωμαλιών για ορισμένους αλγορίθμους (όπως ο Αυτοκωδικοποιητής, ο XGBoost και το γραμμικό μοντέλο), ιδίως όταν συνδυάζεται με στατικά όρια, αλλά συχνά συνοδεύεται από απώλεια ακρίβειας όταν χρησιμοποιούνται δυναμικά όρια.

Συνολικά, η μελέτη καταλήγει στο συμπέρασμα ότι η επιλογή παραμετροποίησης (χρονικά χαρακτηριστικά, τύπος ορίου) έχει σημαντική επίδραση στην αποτελεσματικότητα των αλγορίθμων, η οποία διαφέρει ανάλογα με τη μορφή της ανωμαλίας. Οι στατικές ρυθμίσεις και η ενίσχυση με βασικά χρονικά χαρακτηριστικά φαίνεται να προσφέρουν πιο σταθερή και αξιόπιστη απόδοση σε ετερογενή περιβάλλοντα. Αντίθετα, οι πιο "έξυπνες" τεχνικές, όπως τα δυναμικά όρια και τα βαθιά μοντέλα, απαιτούν πιο μεγάλα δεδομένα χρονοσειρών, για να αποφευχθούν προβλήματα υπερευαισθησίας ή υπερεκπαίδευσης.

Από την άλλη, η ανάλυση του NYC Taxi συνόλου δεδομένων μέσω του NAB πλαισίου ανέδειξε την κρίσιμη σημασία του χρονισμού στην ανίχνευση ανωμαλιών. Η βαθμολογία NAB, ως λειτουργική μετρική, κατέδειξε ότι οι αλγόριθμοι με υψηλή βαθμολογία F1 ή ανάκληση δεν είναι απαραίτητα οι πιο αποτελεσματικοί στην πράξη, εφόσον αποτυγχάνουν να εντοπίσουν τις ανωμαλίες με ακρίβεια στον χρόνο. Αλγόριθμοι με υψηλή ακρίβεια αλλά περιορισμένη ανάκληση, όπως οι χρονικοί DBSCAN, IF και ο Αυτοκωδικοποιητής, πέτυχαν τις υψηλότερες NAB βαθμολογίες, υποδηλώνοντας ότι η επιλεκτικότητα και ο σωστός συγχρονισμός υπερέχουν της υπερανίχνευσης. Αντίθετα, πιο επιθετικά μοντέλα όπως ο χρονικός OCSVM και το Προφίλ Πίνακα με 96% όριο, παρότι σημείωσαν υψηλή ανάκληση, τιμωρήθηκαν με αρνητικά NAB scores λόγω υπερβολικών λανθασμένων ανιχνεύσεων. Η συσχέτιση μεταξύ NAB και ακρίβειας επιβεβαίωσε τη σημασία της ακρίβειας, ενώ η αρνητική συσχέτιση με την ανάκληση και το F1 αναδεικνύει τον περιορισμό των παραδοσιακών μετρικών σε τέτοια σενάρια.

Ιδιαίτερη αξία έχει και ο αριθμός των παραθύρων ανωμαλίας που εντοπίστηκαν

(WINDOWS_FOUND), καθώς παρέχει μια πιο ποιοτική ένδειξη κάλυψης. Παρότι η υπερβολική ενεργοποίηση τιμωρείται μέσω της NAB, η πλήρης κάλυψη όλων των παραθύρων αποτελεί επιθυμητό στόχο, εφόσον συνοδεύεται από σωστό χρονισμό. Ενδεικτικά, μόνο λίγοι αλγόριθμοι, όπως ο χρονικός DBSCAN, ο χρονικός IF, το Προφίλ Πίνακα με 98% όριο και ο Αυτοκωδικοποιητής, κατάφεραν να εντοπίσουν όλα ή σχεδόν όλα τα παράθυρα με ελάχιστες λανθασμένες ενεργοποιήσεις και πολύ καλή βαθμολογία NAB.

Συμπερασματικά, η μελέτη αναδεικνύει ότι, σε εφαρμογές ανίχνευσης ανωμαλιών σε χρονοσειρές, η αποτελεσματικότητα ενός αλγορίθμου δεν εξαρτάται μόνο από την ικανότητά του να εντοπίζει τις ανωμαλίες, αλλά και από το πότε τις σηματοδοτεί, με ποιον τρόπο, και σε ποιον βαθμό επιτυγχάνει την κάλυψη των παραθύρων, διατηρώντας ταυτόχρονα χαμηλά τα επίπεδα υπερανίχνευσης.

Κεφάλαιο 6

Βελτιώσεις και Μελλοντικές Επεκτάσεις

6.1 Βελτιώσεις και Επεκτάσεις

Η παρούσα διπλωματική επικεντρώθηκε στην εφαρμογή και αξιολόγηση αλγορίθμων ανίχνευσης ανωμαλιών σε μονομεταβλητές χρονοσειρές. Παρότι το NYC Taxi σύνολο δεδομένων αποτελεί μια χαρακτηριστική περίπτωση πραγματικού κόσμου, για πιο ολοκληρωμένα και γενικεύσιμα συμπεράσματα απαιτείται επέκταση της ανάλυσης στα υπόλοιπα, πιο σύνθετα και απαιτητικά υποσύνολα του NAB. Τα δεδομένα αυτά περιλαμβάνουν χρονοσειρές με έντονο θόρυβο, μεταβαλλόμενες εποχικότητες, μετατοπίσεις επιπέδου και σπάνιες ή μη ξεκάθαρες ανωμαλίες. Μια μελλοντική εργασία θα μπορούσε να επικεντρωθεί στη συστηματική ανάλυση αυτών των χρονοσειρών, στην ταξινόμησή τους βάσει δυσκολίας, καθώς και στην αθροιστική αποτίμηση των αποτελεσμάτων των μεθόδων ανά τύπο ανωμαλίας και σύνθετο περιβάλλον.

Επιπλέον, προτείνεται η ενσωμάτωση συνδυαστικών τεχνικών (ensemble ή υβριδικών προσεγγίσεων), είτε εντός της ίδιας κατηγορίας αλγορίθμων είτε μεταξύ διαφορετικών τύπων, όπως στατιστικές μέθοδοι, αλγόριθμοι μηχανικής μάθησης και αλγόριθμοι βαθιάς μάθησης. Η εφαρμογή τεχνικών όπως η πλειοψηφική ψήφος (*majority voting*), ο σταθμισμένος μέσος όρος (*weighted averaging*) ή ο ιεραρχικός συνδυασμός μοντέλων (*stacking*) μπορεί να ενισχύσει τόσο την ακρίβεια όσο και τη σταθερότητα των αποτελεσμάτων, αξιοποιώντας τα συμπληρωματικά πλεονεκτήματα των επιμέρους μοντέλων. Ιδιαίτερα, ο συνδυασμός προβλεπτικών μεθόδων (*forecasting*) με μη εποπτευόμενους ανιχνευτές ανωμαλιών ενδέχεται να προσφέρει αυξημένη ευαισθησία και ανθεκτικότητα, ειδικά σε σύνθετα ή ασταθή περιβάλλοντα. Επιπλέον, τα όρια ανίχνευσης μπορούν να ρυθμίζονται δυναμικά κατά την εκπαίδευση, με βάση τη συμφωνία μεταξύ διαφορετικών μοντέλων, ώστε η τελική απόφαση να είναι πιο συνεπής και αξιόπιστη.

Τέλος, σημαντικό πεδίο βελτίωσης αποτελεί η αποτίμηση της υπολογιστικής πολυπλοκότητας των μοντέλων. Πέρα από την ποιοτική αξιολόγηση, η μέτρηση του μέσου χρόνου εκτέλεσης κάθε μεθόδου ανά χρονοσειρά προσφέρει σημαντικές πληροφορίες σχετικά με την πρακτική τους εφαρμο-

σιμότητα, ειδικά σε σενάρια πραγματικού χρόνου. Οι στατιστικές μέθοδοι συνήθως είναι πολύ αποδοτικές χρονικά, ενώ οι αλγόριθμοι βαθιάς μάθησης παρουσιάζουν υψηλή ακρίβεια με αυξημένο υπολογιστικό κόστος. Οι μέθοδοι μηχανικής μάθησης διαφοροποιούνται ανάλογα με τα χαρακτηριστικά εισόδου και την πολυπλοκότητα του μοντέλου. Μια τέτοια σύγκριση, βασισμένη τόσο στη θεωρητική πολυπλοκότητα όσο και στον πραγματικό χρόνο εκτέλεσης, είναι απαραίτητη για τη βέλτιστη επιλογή μεθόδου ανά περίπτωση χρήσης.

6.2 Προτάσεις για Μελλοντική Έρευνα

Η μελλοντική έρευνα μπορεί να στραφεί σε νέα σύνολα δεδομένων, τα οποία υπερβαίνουν ορισμένους περιορισμούς των Yahoo! Webscope S5 και NAB. Συγκεκριμένα, το UCR Time Series Anomaly Archive [20] που προτάθηκε από τους Keogh κ.ά. το 2018 προσφέρει μονομεταβλητές χρονοσειρές σχεδιασμένες έτσι ώστε να διορθώνουν κοινά προβλήματα των παλαιότερων συνόλων, όπως ασαφής ορισμός πραγματικών ανωμαλιών *ground truth*, σύντομη διάρκεια ή υπερβολικά απλοποιημένα μοτίβα και επίσης είναι μεγαλύτερου μεγέθους, που δίνει την ευκαιρία σε αλγορίθμους με πιο σύνθετες αρχιτεκτονικές, όπως το LSTM, να μην πέσουν θύματα υπερ ή υποεκπαίδευσης. Μέσω της εφαρμογής των μεθόδων σε UCR δεδομένα, μπορεί να αξιολογηθεί η ικανότητα γενίκευσης των αλγορίθμων σε πιο ρεαλιστικά και δύσκολα σενάρια. Επίσης, το UCR παρέχει σαφώς ορισμένες ετικέτες ανωμαλιών, στοιχείο που διευκολύνει την αντικειμενική σύγκριση των αποτελεσμάτων.

Παράλληλα, η εργασία μπορεί να επεκταθεί σε πολυμεταβλητές χρονοσειρές, όπου οι σχέσεις μεταξύ μεταβλητών παίζουν καθοριστικό ρόλο στον εντοπισμό ανωμαλιών. Η αντιμετώπιση τέτοιων δεδομένων απαιτεί εξειδικευμένες μεθόδους, είτε μέσω προσαρμογής υφιστάμενων αλγορίθμων, δηλαδή ήδη καθιερωμένων μεθόδων, είτε μέσω πιο σύνθετων μοντέλων (π.χ. αυτοκωδικοποιητές πολλών μεταβλητών, μοντέλα γραφών). Η ανάλυση σε αυτό το πλαίσιο μπορεί να αποκαλύψει ανωμαλίες που είναι αόρατες όταν εξετάζεται μόνο μία μεταβλητή, καθώς και να προσφέρει καλύτερη ερμηνεία σε εφαρμογές όπου η πολυδιάστατη παρατήρηση είναι ο κανόνας (π.χ. αισθητήρες, βιομετρικά δεδομένα, χρηματοοικονομικά συστήματα).

Τέλος, σημαντικό πεδίο μελλοντικής μελέτης αποτελεί η ανίχνευση ανωμαλιών σε πλαίσια σταδιακής ή επιγραμματικής μάθησης (*incremental* ή *online learning*), με στόχο τον εντοπισμό ανωμαλιών σε πραγματικό χρόνο, καθώς τα δεδομένα φτάνουν σταδιακά. Η σταδιακή μάθηση επιτρέπει στα μοντέλα να προσαρμόζονται δυναμικά σε αλλαγές στη στατιστική συμπεριφορά των δεδομένων (*concept drift* – μεταβολή εννοιών) και είναι ιδιαίτερα χρήσιμη σε εφαρμογές όπως η επιτήρηση συστημάτων, ο βιομηχανικός έλεγχος και η προγνωστική συντήρηση.

Ιδιαίτερη πρόκληση αποτελεί η εφαρμογή της *online* μάθησης σε χρονοσειρές, όπου οι παρατηρήσεις είναι εξαρτημένες από τον χρόνο και συχνά χαρακτηρίζονται από εποχικότητα, τάση ή αλλαγή καθεστώτος. Σε αυτό το πλαίσιο, είναι κρίσιμη η ικανότητα των μοντέλων να ενσωματώνουν νέες πληροφορίες χωρίς να απαιτείται επανεκπαίδευση σε όλο το ιστορικό, καθώς και να εντοπίζουν σταδιακά

μεμονωμένες ανωμαλίες ενώ συμβαίνουν.

Προς αυτή την κατεύθυνση, θα μπορούσαν να προσαρμοστούν υπάρχοντες αλγόριθμοι μηχανικής μάθησης για ανίχνευση ανωμαλιών — όπως το Δάσος Απομόνωσης (*Isolation Forest*), ο Τοπικός Παράγοντας Αποκλίσεων (*Local Outlier Factor – LOF*) και οι Μηχανές Διανυσμάτων Υποστήριξης μιας Κλάσης (*One-Class SVM*) — ώστε να λειτουργούν αποτελεσματικά σε online περιβάλλοντα χρονοσειρών. Με χρήση τεχνικών όπως το κυλιόμενο παράθυρο (*sliding window*), καθίσταται εφικτή η σταδιακή ανίχνευση ανωμαλιών, καθώς τα δεδομένα εισέρχονται, επιτρέποντας στο μοντέλο να προσαρμόζεται συνεχώς στις τρέχουσες συνθήκες.

Η ενσωμάτωση και αξιολόγηση τέτοιων επιγραφμικών μεθόδων σε δεδομένα χρονοσειρών μπορεί να φέρει τη μελέτη ένα βήμα πιο κοντά στην πραγματική χρήση σε παραγωγικά περιβάλλοντα, προσφέροντας λύσεις με άμεση λειτουργική και επιχειρησιακή αξία.

Βιβλιογραφία

- [1] Martín Abadi κ.ά. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. <https://www.tensorflow.org/>. Software available from tensorflow.org. 2015.
- [2] Charu C. Aggarwal. *Outlier Analysis*. 2nd. Springer Publishing Company, Incorporated, 2016. ISBN: 3319475770.
- [3] Fernando Almaguer-Angeles κ.ά. "Choosing machine learning algorithms for anomaly detection in smart building IoT scenarios". Στο: *IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*. IEEE. 2021, σσ. 1–6.
- [4] Khanin Arthur. *Time Series and How to Detect Anomalies in Them*. 2020. URL: <https://becominghuman.ai/time-series-and-how-to-detect-anomalies-in-them-part-i-7f9f6c2ad32e>.
- [5] Julien Audibert κ.ά. "Do deep neural networks contribute to multivariate time series anomaly detection?" Στο: *Pattern Recognition* 132 (Δεκ. 2022), σ. 108945. ISSN: 0031-3203. DOI: 10.1016/j.patcog.2022.108945. URL: <http://dx.doi.org/10.1016/j.patcog.2022.108945>.
- [6] Dana H. Ballard. "Modular learning in neural networks". Στο: *Proceedings of the Sixth National Conference on Artificial Intelligence - Volume 1. AAAI'87*. Seattle, Washington: AAAI Press, 1987, σσ. 279–284. ISBN: 0934613427.
- [7] Y. Bengio, P. Simard και P. Frasconi. "Learning long-term dependencies with gradient descent is difficult". Στο: *IEEE Transactions on Neural Networks* 5.2 (1994), σσ. 157–166. DOI: 10.1109/72.279181.
- [8] H. Beyer. "Tukey, John W.: Exploratory Data Analysis. Addison-Wesley Publishing Company Reading, Mass. — Menlo Park, Cal., London, Amsterdam, Don Mills, Ontario, Sydney 1977, XVI, 688 S." Στο: *Biometrical Journal* 23.4 (Ιαν. 1981), σσ. 413–414. ISSN: 1521-4036. DOI: 10.1002/bimj.4710230408. URL: <http://dx.doi.org/10.1002/bimj.4710230408>.

- [9] Bernhard E. Boser, Isabelle M. Guyon και Vladimir N. Vapnik. "A training algorithm for optimal margin classifiers". Στο: *Proceedings of the fifth annual workshop on Computational learning theory*. COLT92. ACM, Ιούλ. 1992, σσ. 144–152. DOI: 10.1145/130385.130401. URL: <http://dx.doi.org/10.1145/130385.130401>.
- [10] George E. P. Box και Gwilym M. Jenkins. *Time Series Analysis: Forecasting and Control*. 1η έκδοση. ISBN: 0-8162-2066-6. San Francisco: Holden-Day, 1970.
- [11] Mohammad Braei και Sebastian Wagner. "Anomaly detection in univariate time-series: A survey on the state-of-the-art". Στο: *arXiv preprint arXiv:2004.00433* (2020).
- [12] Markus M. Breunig κ.ά. "LOF: identifying density-based local outliers". Στο: *ACM SIGMOD Record* 29.2 (Μάι. 2000), σσ. 93–104. ISSN: 0163-5808. DOI: 10.1145/335191.335388. URL: <http://dx.doi.org/10.1145/335191.335388>.
- [13] Peter J. Brockwell και Richard A. Davis. *Introduction to Time Series and Forecasting*. Springer International Publishing, 2016. ISBN: 9783319298542. DOI: 10.1007/978-3-319-29854-2. URL: <http://dx.doi.org/10.1007/978-3-319-29854-2>.
- [14] Robert G. Brown. *Exponential Smoothing for Predicting Demand*. Cambridge, MA: Arthur D. Little, Inc., 1959.
- [15] Varun Chandola, Arindam Banerjee και Vipin Kumar. "Anomaly detection: A survey". Στο: *ACM computing surveys (CSUR)* 41.3 (2009), σσ. 1–58.
- [16] Ih Chang, George C. Tiao και Chung Chen. "Estimation of Time Series Parameters in the Presence of Outliers". Στο: *Technometrics* 30.2 (Μάι. 1988), σσ. 193–204. ISSN: 1537-2723. DOI: 10.1080/00401706.1988.10488367. URL: <http://dx.doi.org/10.1080/00401706.1988.10488367>.
- [17] Tianqi Chen και Carlos Guestrin. "XGBoost: A Scalable Tree Boosting System". Στο: *CoRR abs/1603.02754* (2016). arXiv: 1603.02754. URL: <http://arxiv.org/abs/1603.02754>.
- [18] Google Colaboratory. URL: <https://colab.research.google.com/>.
- [19] Christopher Colah. *Understanding LSTM Networks*. 2015. URL: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/> (επίσκεψη 27/08/2015).
- [20] Hoang Anh Dau κ.ά. "The UCR Time Series Archive". Στο: *CoRR abs/1810.07758* (2018). arXiv: 1810.07758. URL: <http://arxiv.org/abs/1810.07758>.
- [21] Sina Daubener κ.ά. "Anomaly Detection in Univariate Time Series: An Empirical Comparison of Machine Learning Algorithms". Στο: *International Conference on Machine Learning Applications (ICMLA)*. IEEE. 2021.
- [22] F.Y. Edgeworth. "XLI. On discordant observations". Στο: *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science* 23.143 (Απρ. 1887), σσ. 364–375. ISSN: 1941-5990. DOI: 10.1080/14786448708628471. URL: <http://dx.doi.org/10.1080/14786448708628471>.

- [23] Shereen Elsayed κ.ά. *Do We Really Need Deep Learning Models for Time Series Forecasting?* 2021. arXiv: 2101.02118 [cs.LG]. URL: <https://arxiv.org/abs/2101.02118>.
- [24] Martin Ester κ.ά. "A Density-Based Algorithm for Discovering Clusters in Large Spatial Databases with Noise". Στο: *Knowledge Discovery and Data Mining*. 1996. URL: <https://api.semanticscholar.org/CorpusID:355163>.
- [25] Julian Faraway και Chris Chatfield. "Time Series Forecasting with Neural Networks: A Comparative Study Using the Air Line Data". Στο: *Journal of the Royal Statistical Society Series C: Applied Statistics* 47.2 (Ιαν. 2002), σσ. 231–250. ISSN: 0035-9254. DOI: 10.1111/1467-9876.00109. eprint: https://academic.oup.com/jrsssc/article-pdf/47/2/231/48750370/jrsssc_47_2_231.pdf. URL: <https://doi.org/10.1111/1467-9876.00109>.
- [26] Philip Hans Franses και Gerrit Draisma. "Recognizing changing seasonal patterns using artificial neural networks". Στο: *Journal of Econometrics* 81.1 (1997), σσ. 273–280. ISSN: 0304-4076. DOI: [https://doi.org/10.1016/S0304-4076\(97\)00047-X](https://doi.org/10.1016/S0304-4076(97)00047-X). URL: <https://www.sciencedirect.com/science/article/pii/S030440769700047X>.
- [27] Jerome Friedman, Trevor Hastie και Robert Tibshirani. "Additive logistic regression: a statistical view of boosting (With discussion and a rejoinder by the authors)". Στο: *The Annals of Statistics* 28.2 (Απρ. 2000). ISSN: 0090-5364. DOI: 10.1214/aos/1016218223. URL: <http://dx.doi.org/10.1214/aos/1016218223>.
- [28] Jerome H. Friedman. "Greedy function approximation: A gradient boosting machine." Στο: *The Annals of Statistics* 29.5 (Οκτ. 2001). ISSN: 0090-5364. DOI: 10.1214/aos/1013203451. URL: <http://dx.doi.org/10.1214/aos/1013203451>.
- [29] Frank E. Grubbs. "Procedures for Detecting Outlying Observations in Samples". Στο: *Technometrics* 11.1 (Φεβ. 1969), σσ. 1–21. ISSN: 1537-2723. DOI: 10.1080/00401706.1969.10490657. URL: <http://dx.doi.org/10.1080/00401706.1969.10490657>.
- [30] Tanja Hagemann και Katerina Katsarou. "Reconstruction-based anomaly detection for the cloud: A comparison on the Yahoo! Webscope S5 dataset". Στο: *Proceedings of the 11th International Conference on Cloud Computing and Services Science (CLOSER)*. 2021.
- [31] Charles R. Harris κ.ά. "Array programming with NumPy". Στο: *Nature* 585.7825 (Σεπτ. 2020), σσ. 357–362. DOI: 10.1038/s41586-020-2649-2. URL: <https://doi.org/10.1038/s41586-020-2649-2>.
- [32] D. M. Hawkins. *Identification of Outliers*. Springer Netherlands, 1980. ISBN: 9789401539944. DOI: 10.1007/978-94-015-3994-4. URL: <http://dx.doi.org/10.1007/978-94-015-3994-4>.
- [33] Geoffrey E. Hinton και Richard S. Zemel. "Autoencoders, Minimum Description Length and Helmholtz Free Energy". Στο: *Neural Information Processing Systems*. 1993. URL: <https://api.semanticscholar.org/CorpusID:2445072>.

- [34] Sepp Hochreiter. ``Untersuchungen zu dynamischen neuronalen Netzen". Στο: *Master's thesis, Institut fur Informatik, Technische Universitat, Munchen* 1 (1991), σσ. 1–150.
- [35] Sepp Hochreiter και Jürgen Schmidhuber. ``Long Short-Term Memory". Στο: *Neural Computation* 9.8 (1997), σσ. 1735–1780. DOI: 10.1162/neco.1997.9.8.1735.
- [36] Charles C. Holt. *Forecasting seasonals and trends by exponentially weighted moving averages*. Research Memorandum 52. Carnegie Institute of Technology, 1957.
- [37] J. D. Hunter. ``Matplotlib: A 2D graphics environment". Στο: *Computing in Science & Engineering* 9.3 (2007), σσ. 90–95. DOI: 10.1109/MCSE.2007.55.
- [38] Rob J. Hyndman και George Athanasopoulos. *Forecasting: Principles and Practice*. 3η έκδοση. <https://otexts.com/fpp3/>. OTexts, 2021.
- [39] Olumuyiwa Ibidunmoye, Francisco Hernández-Rodriguez και Erik Elmroth. ``Performance Anomaly Detection and Bottleneck Identification". Στο: *ACM Comput. Surv.* 48.1 (Ιούλ. 2015). ISSN: 0360-0300. DOI: 10.1145/2791120. URL: <https://doi.org/10.1145/2791120>.
- [40] Olumuyiwa Ibidunmoye, Ali-Reza Rezaie και Erik Elmroth. ``Adaptive Anomaly Detection in Performance Metric Streams". Στο: *IEEE Transactions on Network and Service Management* 15.1 (2018), σσ. 217–231. DOI: 10.1109/TNSM.2017.2750906.
- [41] Guolin Ke κ.ά. ``LightGBM: A Highly Efficient Gradient Boosting Decision Tree". Στο: *Advances in Neural Information Processing Systems*. Επιμέλεια υπό I. Guyon κ.ά. Τόμ. 30. Curran Associates, Inc., 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/file/6449f44a102fde848669bdd9eb6b76fa-Paper.pdf.
- [42] Eamonn Keogh και Abdullah Mueen. *Time Series Data Mining Using the Matrix Profile: A Unifying View of Motif Discovery, Anomaly Detection, Segmentation, Classification, Clustering and Similarity Joins*. 2017. URL: https://www.cs.ucr.edu/~eamonn/Matrix_Profile_Tutorial_Part1.pdf.
- [43] Mark A. Kramer. ``Nonlinear principal component analysis using autoassociative neural networks". Στο: *AIChE Journal* 37.2 (Φεβ. 1991), σσ. 233–243. ISSN: 1547-5905. DOI: 10.1002/aic.690370209. URL: <http://dx.doi.org/10.1002/aic.690370209>.
- [44] Alexander Lavin και Subutai Ahmad. ``Evaluating Real-time Anomaly Detection Algorithms - the Numenta Anomaly Benchmark". Στο: *CoRR* abs/1510.03336 (2015). arXiv: 1510.03336. URL: <http://arxiv.org/abs/1510.03336>.
- [45] Sean M. Law. ``STUMPY: A Powerful and Scalable Python Library for Time Series Data Mining". Στο: *The Journal of Open Source Software* 4.39 (2019), σ. 1504.
- [46] Fei Tony Liu, Kai Ming Ting και Zhi-Hua Zhou. ``Isolation Forest". Στο: *2008 Eighth IEEE International Conference on Data Mining*. IEEE, Δεκ. 2008, σσ. 413–422. DOI: 10.1109/icdm.2008.17. URL: <http://dx.doi.org/10.1109/ICDM.2008.17>.

- [47] Fei Tony Liu, Kai Ming Ting και Zhi-Hua Zhou. "Isolation-Based Anomaly Detection". Στο: *ACM Transactions on Knowledge Discovery from Data* 6.1 (Μαρ. 2012), σσ. 1–39. ISSN: 1556-472X. DOI: 10.1145/2133360.2133363. URL: <http://dx.doi.org/10.1145/2133360.2133363>.
- [48] Spyros Makridakis και Michele Hibon. "The M3-competition: results, conclusions and implications". Στο: *International journal of forecasting* 16.4 (2000), σσ. 451–476.
- [49] Spyros Makridakis, Evangelos Spiliotis και Vassilios Assimakopoulos. "Statistical and machine learning forecasting methods: Concerns and ways forward". Στο: *PLOS ONE* 13.3 (2018), e0194889.
- [50] Llew Mason κ.ά. "Boosting Algorithms as Gradient Descent". Στο: *Advances in Neural Information Processing Systems*. Επιμέλεια υπό S. Solla, T. Leen και K. Müller. Τόμ. 12. MIT Press, 1999. URL: https://proceedings.neurips.cc/paper_files/paper/1999/file/96a93ba89a5b5c6c226e49b88973f46e-Paper.pdf.
- [51] Wes McKinney. "Data Structures for Statistical Computing in Python". Στο: *Proceedings of the 9th Python in Science Conference*. Επιμέλεια υπό Stéfan van der Walt και Jarrod Millman. 2010, σσ. 56–61. DOI: 10.25080/Majora-92bf1922-00a.
- [52] Alan V. Oppenheim και Ronald W. Schaffer. *Discrete-Time Signal Processing*. 3rd. Upper Saddle River, NJ, USA: Prentice Hall, 2010.
- [53] F. Pedregosa κ.ά. "Scikit-learn: Machine Learning in Python". Στο: *Journal of Machine Learning Research* 12 (2011), σσ. 2825–2830.
- [54] Liudmila Prokhorenkova κ.ά. *CatBoost: unbiased boosting with categorical features*. 2017. DOI: 10.48550/ARXIV.1706.09516. URL: <https://arxiv.org/abs/1706.09516>.
- [55] Hongzhen Ren κ.ά. "Time-series anomaly detection service at Microsoft". Στο: *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. ACM. 2019, σσ. 3009–3017.
- [56] NAB Github Repository. URL: <https://github.com/numenta/NAB/tree/master/data>.
- [57] D.E. RUMELHART, G.E. HINTON και R.J. WILLIAMS. "Learning Internal Representations by Error Propagation". Στο: *Readings in Cognitive Science*. Elsevier, 1988, σσ. 399–421. ISBN: 9781483214467. DOI: 10.1016/b978-1-4832-1446-7.50035-2. URL: <http://dx.doi.org/10.1016/B978-1-4832-1446-7.50035-2>.
- [58] Cátia M. Salgado κ.ά. "Noise Versus Outliers". Στο: *Secondary Analysis of Electronic Health Records*. Springer International Publishing, 2016, σσ. 163–183. ISBN: 9783319437422. DOI: 10.1007/978-3-319-43742-2_14. URL: http://dx.doi.org/10.1007/978-3-319-43742-2_14.
- [59] Sebastian Schmidl, Phillip Wenig και Thorsten Papenbrock. "Anomaly Detection in Time Series: A Comprehensive Evaluation". Στο: *Proceedings of the VLDB Endowment*. Τόμ. 15. 12. 2022, σσ. 3390–3402.

- [60] Bernhard Schölkopf κ.ά. "Support Vector Method for Novelty Detection". Στο: *Advances in Neural Information Processing Systems*. Επιμέλεια υπό S. Solla, T. Leen και K. Müller. Τόμ. 12. MIT Press, 1999. URL: https://proceedings.neurips.cc/paper_files/paper/1999/file/8725fb777f25776ffa9076e44fcfd776-Paper.pdf.
- [61] Skipper Seabold και Josef Perktold. "statsmodels: Econometric and statistical modeling with python". Στο: *9th Python in Science Conference*. 2010.
- [62] M. Shanker, M.Y. Hu και M.S. Hung. "Effect of data standardization on neural network training". Στο: *Omega* 24.4 (1996), σσ. 385–397. ISSN: 0305-0483. DOI: [https://doi.org/10.1016/0305-0483\(96\)00010-2](https://doi.org/10.1016/0305-0483(96)00010-2). URL: <https://www.sciencedirect.com/science/article/pii/0305048396000102>.
- [63] Ramesh Sharda και Rajendra B. Patil. "Connectionist approach to time series prediction: an empirical test". Στο: *Journal of Intelligent Manufacturing* 3.5 (Οκτ. 1992), σσ. 317–323. ISSN: 1572-8145. DOI: 10.1007/bf01577272. URL: <http://dx.doi.org/10.1007/BF01577272>.
- [64] Dominique T Shipmon κ.ά. "Time Series Anomaly Detection: Detection of Anomalous Drops with Limited Features and Sparse Examples in Noisy Highly Periodic Data". Στο: *arXiv preprint arXiv:1708.03665* (2017).
- [65] Robert H. Shumway και David S. Stoffer. *Time Series Analysis and Its Applications: With R Examples*. 5th. Springer, 2023. ISBN: 978-3-031-29642-8.
- [66] Ravid Shwartz-Ziv και Amitai Armon. "Tabular Data: Deep Learning is Not All You Need". Στο: *CoRR* abs/2106.03253 (2021). arXiv: 2106.03253. URL: <https://arxiv.org/abs/2106.03253>.
- [67] Nidhi Singh και Craig Olinsky. "Demystifying Numenta anomaly benchmark". Στο: *2017 International Joint Conference on Neural Networks (IJCNN)*. 2017, σσ. 1570–1577. DOI: 10.1109/IJCNN.2017.7966038.
- [68] Wadie Skaf και Tomas Horvath. "Denoising architecture for unsupervised anomaly detection in time-series". Στο: *International Conference on Artificial Intelligence and Soft Computing*. Springer, 2022, σσ. 370–381.
- [69] Eugen Slutsky. "The summation of random causes as the source of cyclic processes". Στο: *Econometrica* 5.2 (1937), σσ. 105–146.
- [70] Petre Stoica και Randolph L. Moses. *Spectral Analysis of Signals*. Prentice Hall, 2005. ISBN: 9780131139560.
- [71] Zaiyong Tang και Paul A. Fishwick. "Feedforward Neural Nets as Models for Time Series Forecasting". Στο: *ORSA Journal on Computing* 5.4 (Νοέ. 1993), σσ. 374–385. ISSN: 2326-3245. DOI: 10.1287/ijoc.5.4.374. URL: <http://dx.doi.org/10.1287/ijoc.5.4.374>.
- [72] Guido Van Rossum και Fred L. Drake. *Python 3 Reference Manual*. Scotts Valley, CA: CreateSpace, 2009. ISBN: 1441412697.

- [73] V. N. Vapnik και A. Ya. Chervonenkis. "A class of algorithms for pattern recognition learning". Στο: *Avtomat. i Telemekh.* 25.6 (1964), σσ. 937–945. URL: <http://mi.mathnet.ru/at11678>.
- [74] Pauli Virtanen κ.ά. "SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python". Στο: *Nature Methods* 17 (2020), σσ. 261–272. DOI: 10.1038/s41592-019-0686-2.
- [75] Xiaoyue Wang κ.ά. "Experimental Comparison of Representation Methods and Distance Measures for Time Series Data". Στο: *CoRR* abs/1012.2789 (2010). arXiv: 1012.2789. URL: <http://arxiv.org/abs/1012.2789>.
- [76] Michael L. Waskom. "seaborn: statistical data visualization". Στο: *Journal of Open Source Software* 6.60 (2021), σ. 3021. DOI: 10.21105/joss.03021. URL: <https://doi.org/10.21105/joss.03021>.
- [77] Yahoo! Webscope. *S5- A Labeled Anomaly Detection Dataset, version 1.0*. URL: <https://webscope.sandbox.yahoo.com/catalog.php?datatype=s.&guccounter=1>.
- [78] Peter Whittle. *Hypothesis Testing in Time Series Analysis*. Hafner Publishing Company, 1951.
- [79] Frank Wilcoxon. "Individual Comparisons by Ranking Methods". Στο: *Biometrics Bulletin* 1.6 (1945), σσ. 80–83. DOI: 10.2307/3001968. URL: <https://doi.org/10.2307/3001968>.
- [80] Peter R. Winters. "Forecasting Sales by Exponentially Weighted Moving Averages". Στο: *Management Science* 6.3 (1960), σσ. 324–342. DOI: 10.1287/mnsc.6.3.324.
- [81] Renjie Wu και Eamonn J. Keogh. "Current Time Series Anomaly Detection Benchmarks are Flawed and are Creating the Illusion of Progress". Στο: *CoRR* abs/2009.13807 (2020). arXiv: 2009.13807. URL: <https://arxiv.org/abs/2009.13807>.
- [82] Chin-Chia Michael Yeh κ.ά. "Matrix Profile I: All Pairs Similarity Joins for Time Series: A Unifying View That Includes Motifs, Discords and Shapelets". Στο: *2016 IEEE 16th International Conference on Data Mining (ICDM)*. IEEE, Δεκ. 2016, σσ. 1317–1322. DOI: 10.1109/icdm.2016.0179. URL: <http://dx.doi.org/10.1109/ICDM.2016.0179>.
- [83] G. Udny Yule. "On a method of investigating periodicities in disturbed series, with special reference to Wolfer's sunspot numbers". Στο: *Philosophical Transactions of the Royal Society of London. Series A* 226.636--646 (1927), σσ. 267–298.
- [84] G.Peter Zhang και Min Qi. "Neural network forecasting for seasonal and trend time series". Στο: *European Journal of Operational Research* 160.2 (2005). Decision Support Systems in the Internet Age, σσ. 501–514. ISSN: 0377-2217. DOI: <https://doi.org/10.1016/j.ejor.2003.08.037>. URL: <https://www.sciencedirect.com/science/article/pii/S0377221703005484>.
- [85] Yan Zhu κ.ά. "Matrix Profile II: Exploiting a Novel Algorithm and GPUs to Break the One Hundred Million Barrier for Time Series Motifs and Joins". Στο: *2016 IEEE 16th International Conference on Data Mining (ICDM)*. IEEE, Δεκ. 2016, σσ. 739–748. DOI: 10.1109/icdm.2016.0085. URL: <http://dx.doi.org/10.1109/ICDM.2016.0085>.